

Algorytmy Zaawansowane

Wersja z wyróżnieniami

Opracowane na podstawie wykładów Michała Tuczyńskiego

Fragmenty wyróżnione tłem

wskazują materiał, który trzeba znać szczególnie dobrze — twierdzenia wraz z dowodami obowiązkowymi na egzaminie.

Spis treści

1	Dziel i zwyciężaj	2
1.1	Notacja asymptotyczna — przypomnienie	2
1.2	Strategia typu <i>Dziel i Zwyciężaj</i> (<i>Divide and Conquer</i>)	3
1.3	Algorytm Strasiera	4
1.4	Własność optymalnej podstruktury	5
1.5	Znajdywanie pary najbliższych punktów	5
2	Programowanie dynamiczne	9
2.1	Algorytm mnożenia macierzy	10
2.2	Problem mnożenia ciągu macierzy	11
2.3	Problem najdłuższego wspólnego podciągu	17
3	Algorytmy zachłanne	20
3.1	Kody Huffmana	23
3.2	Algorytm Huffmana	24
3.3	Dowód optymalności algorytmu Huffmana	27
3.4	Szeregowanie zadań	28
3.5	Matroidy	30
3.6	Problem szeregowania zadań	32
4	Algorytmy aproksymacyjne	34
4.1	Problem pokrycia wierzchołkowego	35
4.2	Problem pokrycia zbioru	37
4.3	Schematy aproksymacyjne	40
4.4	Problem sumy podzbiorów	40
4.5	NP-zupełność problemu sumy podzbiorów	43
4.6	Problem sumy podzbioru	44
5	Skojarzenia w grafach	47

Dziel i zwyciężaj

Notacja asymptotyczna — przypomnienie

$$f, g : \mathbb{N} \rightarrow \mathbb{R}_+$$

$$g(n) = \mathcal{O}(f(n)) \Leftrightarrow \exists_{c \in \mathbb{R}_+} \exists_{n_0 \in \mathbb{N}_+} \forall_{n > n_0} g(n) \leq c \cdot f(n)$$

$$g(n) = \Omega(f(n)) \Leftrightarrow \exists_{c \in \mathbb{R}_+} \exists_{n_0 \in \mathbb{N}_+} \forall_{n > n_0} c \cdot f(n) \leq g(n)$$

$$g(n) = \Theta(f(n)) \Leftrightarrow \exists_{c_1, c_2 \in \mathbb{R}_+} \exists_{n_0 \in \mathbb{N}_+} \forall_{n > n_0} c_1 \cdot f(n) \leq g(n) \leq c_2 \cdot f(n)$$

$$g(n) = \mathcal{O}(f(n)) \Leftrightarrow f(n) = \Omega(g(n))$$

$$g(n) = \Theta(f(n)) \Leftrightarrow (g(n) = \mathcal{O}(f(n)) \wedge g(n) = \Omega(f(n)))$$

$$n^a = \mathcal{O}(n^b) \text{ gdy } 0 < a \leq b$$

$$\log n = \mathcal{O}(n^\epsilon) \text{ gdy } \epsilon > 0$$

$$n^a = \mathcal{O}(b^n) \text{ gdy } 1 < a \leq b$$

$$\log_a n = \Theta(\log_b n) \text{ gdy } a, b > 1$$

$$n^a = \mathcal{O}(b^n) \text{ gdy } 0 < a, b > 1$$

$$T(n) = 5n^3 + 2n^2 + 100n \log n \underset{n \rightarrow \infty}{\approx} 5n^3 = \Theta(n^3)$$

Procedura rekurencyjna

$$n! = \begin{cases} 1 & \text{gdy } n = 0 \\ n \cdot (n-1)! & \text{gdy } n \geq 1 \end{cases}$$

$$\text{Oczywiste jest, że } n! = \prod_{i=1}^n i$$

Ciąg Fibonacciego F_n - ciąg Fibonacciego.

$$F_n = \begin{cases} 0 & \text{gdy } n = 0 \\ 1 & \text{gdy } n = 1 \\ F_{n-1} + F_{n-2} & \text{gdy } n \geq 2 \end{cases}$$

Algorytm 1: Rekurencyjna konstrukcja ciągu Fibonacciego

```
function FIBB(n)
1:  if n = 0 then return 0
2:  if n = 1 then return 1
3:  return FIBB(n-1) + FIBB(n-2)
```

Wywołanie rekurencyjne dla (typowo łatwiejszych i mniejszych) instancji tego samego problemu.

Strategia typu *Dziel i Zwyciężaj* (Divide and Conquer)

Algorytm typu *dziel i zwyciężaj* składa się z trzech części

1. *Dziel* – problem jest dzielony na mniejsze podproblemy
2. *Zwyciężaj* – podproblemy są rozwiązywane rekurencyjnie
3. *Połącz* – rozwiązanie całego problemu jest konstruowane z rozwiązań podproblemów

Zakładamy, że (zazwyczaj) w fazie *dziel* problem jest dzielony na co najmniej dwa podproblemy i podproblemy są rozłączne.

Przykład 1.1 (Mnożenie liczb n -cyfrowych).

x, y – liczby naturalne n -cyfrowe.

Aby policzyć $x \cdot y$ można użyć mnożenia pisemnego (jak na kartce). Tym sposobem musimy wykonać $\mathcal{O}(n^2)$ mnożeń cyfr. Spróbujemy znaleźć lepszą metodę. Dzielimy x i y na „dwie połowy”. Zakładamy, dla uproszczenia, że n jest parzyste.

$$x = x_1 x_2 \cdots x_n = \underbrace{x_1 x_2 \cdots x_{n/2}}_{x_L} \underbrace{x_{n/2+1} \cdots x_n}_{x_R} = 10^{n/2} x_L + x_R$$

podobnie dla y :

$$y = \cdots = 10^{n/2} y_L + y_R$$

Wymnażamy:

$$x \cdot y = (10^{n/2} x_L + x_R) \cdot (10^{n/2} y_L + y_R) = 10^n x_L y_L + 10^{n/2} (x_L y_R + x_R y_L) + x_R y_R$$

Złożoność czasowa algorytmu – ozn. $T(n)$.

- Podział x, y na x_L, x_R, y_L, y_R zajmie $\mathcal{O}(n)$ czasu.
- Dodanie liczb n -cyfrowych zajmie $\mathcal{O}(n)$ czasu.
- Mnożenie przez 10^n jest równoważne dopisaniu n zer więc też $\mathcal{O}(n)$.

$$T(n) = 4 \cdot T(n/2) + \Theta(n)$$

Można lepiej, bo możemy zauważyć, że $x_L y_R + x_R y_L = (x_L - x_R) \cdot (y_R - y_L) + x_L y_L + x_R y_R$, więc potrzebujemy policzyć tylko 3 iloczyny: $x_L y_L$, $x_R y_R$, $(x_L - x_R) \cdot (y_R - y_L)$. To daje $T(n) = 3 \cdot T\left(\frac{n}{2}\right) + \Theta(n)$

Twierdzenie 1.2 (CLRS - Uniwersalne Twierdzenie o Rekurencji).

Niech $a \geq 1$, $b > 1$ będą stałymi, $f(n)$ funkcją i $T(n) = a \cdot T\left(\frac{n}{b}\right) + f(n)$ (gdzie $\frac{n}{b}$ znaczy $\left\lfloor \frac{n}{b} \right\rfloor$ lub $\left\lceil \frac{n}{b} \right\rceil$). Wtedy

$$T(n) = \begin{cases} \Theta(n^{\log_b a}) & \text{gdy } f(n) = \mathcal{O}(n^{\log_b a - \epsilon}) \text{ dla pewnego } \epsilon > 0 \\ \Theta(n^{\log_b a} \log n) & \text{gdy } f(n) = \Theta(n^{\log_b a}) \\ \Theta(f(n)) & \text{gdy } \begin{matrix} f(n) = \Omega(n^{\log_b a + \epsilon}) \text{ dla pewnego } \epsilon > 0 \\ a \cdot f(n/b) \leq c \cdot f(n) \text{ dla pewnej stałej } c < 1 \text{ dla dużych } n \end{matrix} \end{cases}$$

Lemat 1.3. Niech $a \geq 1$, $b > 1$ będą stałymi i niech $f(n)$ będzie nieujemną funkcją zdefiniowaną dla potęg b . Jeśli

$$T(n) = \begin{cases} \Theta(1) & \text{gdy } n = 1 \\ a \cdot T\left(\frac{n}{b}\right) + f(n) & \text{gdy } n = b^i, i \geq 1 \end{cases}$$

to

$$T(n) = \Theta\left(n^{\log_b a}\right) + \sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right)$$

Przeprowadzimy teraz dowód uniwersalnego twierdzenia o rekurencji (1.2). Ograniczymy się do przypadku, gdy n jest potęgą b . Pozostały przypadek jest bardziej techniczny.

Wniosek 1.4. Niech $a \geq 1$, $b > 1$ będą stałymi, a $f(n)$ funkcją taką, że $f(n) = \Theta(n^k)$. Niech $T(n) = a \cdot T\left(\frac{n}{b}\right) + f(n)$ (gdzie $\frac{n}{b}$ znaczy $\left\lfloor \frac{n}{b} \right\rfloor$ lub $\left\lceil \frac{n}{b} \right\rceil$). Wtedy

$$T(n) = \begin{cases} \Theta(n^{\log_b a}) & \text{gdy } f(n) = \mathcal{O}(n^{\log_b a - \epsilon}) \implies k < \log_b a \iff b^k < a \\ \Theta(n^k \log n) & \text{gdy } f(n) = \Theta(n^{\log_b a}) \implies k = \log_b a \iff b^k = a \\ \Theta(n^k) & \text{gdy } f(n) = \Omega(n^{\log_b a + \epsilon}) \implies k > \log_b a \iff b^k > a \end{cases}$$

Wróćmy teraz do naszego problemu mnożenia liczb n -cyfrowych. Drugi algorytm ma złożoność:

$$T(n) = 4 \cdot T\left(\frac{n}{2}\right) + \Theta(n^1) \quad a = 4, b = 2, k = 1$$

$$4 > 2^1 \Rightarrow T(n) = \Theta(n^{\log_2 4}) = \Theta(n^2)$$

Trzeci algorytm ma złożoność:

$$T(n) = 3 \cdot T\left(\frac{n}{2}\right) + \Theta(n^1) \quad a = 3, b = 2, k = 1$$

$$3 > 2^1 \Rightarrow T(n) = \Theta(n^{\log_2 3}) = \Theta(n^{1.59})$$

Przykład 1.5 (Mnożenie macierzy).

A, B - macierze $n \times n$

$$A \cdot B = C = ?$$

Najpopularniejszy sposób mnożenia dwóch macierzy $n \times n$ działa w czasie $\mathcal{O}(n^3)$. Musimy obliczyć n^2 wartości i obliczenie każdej zajmuje liniowy czas.

$$B = \begin{bmatrix} \vdots \\ \vdots \end{bmatrix} \quad A = \begin{bmatrix} \cdots \end{bmatrix} \begin{bmatrix} \times \\ \times \end{bmatrix} = C$$

Algorytm Strasiery

Zakładamy, że n jest potęgą 2 (dla przejrzystości). Dzielimy A i B na 4 macierze $\frac{n}{2} \times \frac{n}{2}$:

$$A = \left[\begin{array}{c|c} A_{11} & A_{12} \\ \hline A_{21} & A_{22} \end{array} \right], \quad B = \left[\begin{array}{c|c} B_{11} & B_{12} \\ \hline B_{21} & B_{22} \end{array} \right]$$

$$A \cdot B = \left[\begin{array}{c|c} A_{11} & A_{12} \\ \hline A_{21} & A_{22} \end{array} \right] \cdot \left[\begin{array}{c|c} B_{11} & B_{12} \\ \hline B_{21} & B_{22} \end{array} \right] = \left[\begin{array}{c|c} C_{11} & C_{12} \\ \hline C_{21} & C_{22} \end{array} \right]$$

$$C_{11} = A_{11}B_{11} + A_{12}B_{21}$$

$$C_{12} = A_{11}B_{12} + A_{12}B_{22}$$

$$C_{21} = A_{21}B_{11} + A_{22}B_{21}$$

$$C_{22} = A_{21}B_{12} + A_{22}B_{22}$$

Zamieniliśmy 1 mnożenie macierzy $n \times n$ na 8 mnożeń macierzy $\frac{n}{2} \times \frac{n}{2}$ + podział i dodawanie ($\mathcal{O}(n^2)$). Stąd mamy zależność rekurencyjną:

$$T(n) = 8 \cdot T\left(\frac{n}{2}\right) + \Theta(n^2) \quad a = 8, \quad b = 2, \quad k = 2$$

$$8 > 2^2 \Rightarrow T(n) = \Theta(n^{\log_2 8}) = \Theta(n^3)$$

Strassen zauważył, że jeśli obliczymy

$$M_1 = (A_{12} - A_{22}) \cdot (B_{21} + B_{22})$$

$$M_2 = (A_{11} + A_{22}) \cdot (B_{11} + B_{22})$$

$$M_3 = (A_{11} - A_{21}) \cdot (B_{11} + B_{12})$$

$$M_4 = (A_{11} + A_{12}) \cdot B_{22}$$

$$M_5 = A_{11} \cdot (B_{12} - B_{22})$$

$$M_6 = A_{22} \cdot (B_{21} - B_{11})$$

$$M_7 = (A_{21} + A_{22}) \cdot B_{11}$$

$$\text{to } C_{11} = M_1 + M_2 - M_4 + M_6$$

$$C_{12} = M_4 + M_5$$

$$C_{21} = M_6 + M_7$$

$$C_{22} = M_2 - M_3 + M_5 - M_7$$

Zatem

$$T(n) = 7 \cdot T\left(\frac{n}{2}\right) + \Theta(n^2) \quad a = 7, \quad b = 2, \quad k = 2$$

$$7 > 2^2 \Rightarrow T(n) = \Theta(n^{\log_2 7}) = \Theta(n^{2.81})$$

Własność optymalnej podstruktury

Optymalne rozwiązanie problemu jest funkcją optymalnych rozwiązań podproblemów (optymalne rozwiązanie można skonstruować z optymalnych rozwiązań podproblemów). Żeby metoda *dziel i zwyciężaj* działała dobrze muszą być spełnione dwa warunki (przez problem i algorytm):

1. własność optymalnej podstruktury
2. podproblemy są rozłączne

Znajdywanie pary najbliższych punktów

Q - zbiór $n \geq 2$ punktów na płaszczyźnie

$$p_1 = (x_1, y_1) \quad p_2 = (x_2, y_2) \quad d(p_1, p_2) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$


Problem: znaleźć parę punktów w najmniejszej odległości. Algorytm siłowy (*brute force*), który sprawdza wszystkie pary punktów działa w czasie $\Theta(n^2)$, bo mamy $\binom{n}{2} = \frac{n(n-1)}{2} = \Theta(n^2)$ par punktów. Pokażemy algorytm typu *dziel i zwyciężaj*, który działa w czasie $\mathcal{O}(n \log n)$.

W każdym wywołaniu rekurencyjnym wejście składa się z 3 rzeczy: zbioru $P \subset Q$ i dwóch tablic X i Y które zawierają wszystkie punkty z P . W tablicy X punkty są posortowane w porządku niemalejącym względem pierwszej współrzędnej, a w tablicy Y po drugiej współrzędnej.

Opis algorytmu:

Jeśli $|P| \leq 3$, sprawdzamy wszystkie pary. W przeciwnym razie ($|P| > 3$) postępujemy następująco:

Dziel: Dzielimy punkty P pionową prostą l na dwa podzbiory P_L i P_R na lewo i na prawo od l tak, że $|P_L| = \left\lceil \frac{|P|}{2} \right\rceil$, $|P_R| = \left\lfloor \frac{|P|}{2} \right\rfloor$. Dzielimy tablicę X na X_L i X_R zawierające punkty odpowiednio P_L i P_R posortowane w porządku niemalejącym względem pierwszej współrzędnej. Podobnie dzielimy Y na Y_L i Y_R zawierające odpowiednio punkty z P_L i P_R posortowane w porządku niemalejącym po drugiej współrzędnej.



Rysunek 1: Podział zbioru P pionową prostą l na podzbiory P_L (na lewo) i P_R (na prawo) o rozmiarach $|P_L| = \left\lceil \frac{|P|}{2} \right\rceil$ oraz $|P_R| = \left\lfloor \frac{|P|}{2} \right\rfloor$.

Uwaga. Prostą l definiuje *mediana współrzędnej x* zbioru P — tak ją zadają Preparata i Shamos (*Computational Geometry: An Introduction*, §5.4), za którymi podąża też CLRS (§33.4). Dla parzystego $|P|$ medianę bierzemy jako średnią dwóch środkowych wartości, $x_l = \frac{1}{2} \left(X\left(\frac{|P|}{2}\right) \cdot x + X\left(\frac{|P|}{2} + 1\right) \cdot x \right)$, co daje $|P_L| = |P_R| = \frac{|P|}{2}$. Sam *algorytm* nie wymaga jednak żadnej wyróżnionej wartości: istotny jest tylko podział na $\lceil |P|/2 \rceil$ i $\lfloor |P|/2 \rfloor$ punktów (dowolna prosta rozdzielająca posortowane połowy działa tak samo), a przy remisach na x rozstrzyga ograniczenie liczności, nie sama wartość x_l . Pierwsze rozwiązanie problemu w czasie $\mathcal{O}(N \log N)$ podali Shamos i Hoey (*Closest-Point Problems*, 1975) inną metodą — przez diagram Woronoja.

Zwycięzaj: Wywołujemy rekurencyjnie algorytm dla wejścia P_L , X_L , Y_L i P_R , X_R , Y_R . Algorytm znajduje pary najbliższych punktów w P_L i P_R . Niech δ_L i δ_R będą najmniejszymi odległościami znalezionymi przez algorytm dla odpowiednio P_L i P_R . Niech δ będzie mniejszą z nich: $\delta = \min(\delta_L, \delta_R)$.

Połącz: Para najbliższych punktów z P składa się z dwóch punktów z P_L lub z dwóch punktów z P_R lub jednego punktu z P_L i jednego z P_R .


Musimy sprawdzić czy istnieje para 3-go typu w odległości mniejszej niż δ . Jeśli taka para istnieje, wtedy jej punkty są w pionowym pasie o szerokości 2δ wokół l .

W celu sprawdzenia czy taka para istnieje wykonujemy następujące czynności:

1. Tworzymy tablicę Y' otrzymaną z Y poprzez usunięcie punktów spoza pasa. Y' jest posortowany w porządku niemalejącym względem drugiej współrzędnej.
2. Dla każdego punktu p z Y' sprawdzamy odległość między p , a p' dla 7 kolejnych punktów p' z Y' . Algorytm oblicza najmniejszą odległość δ' i zapamiętuje ją i odpowiednią parę punktów.


3. Jeśli $\delta' < \delta$ to pionowy pas zawiera parę punktów w mniejszej odległości niż pary znalezione w wywołaniach rekurencyjnych. Algorytm zwraca δ' i odpowiednią parę punktów. Wpp. zwraca δ i odpowiednią parę punktów.

Dowód poprawności. Jedyną rzeczą, która nie jest oczywista jest fakt, że sprawdzamy tylko 7 następnych punktów po p w Y' w fazie połącz. Przypuśćmy, że p, q są parą punktów w najmniejszej odległości w P i $d(p, q) = \delta'$. Niech $p = (x_p, y_p)$, $q = (x_q, y_q)$. Bez straty ogólności założmy $y_p \leq y_q$. Pokażemy, że algorytm znajdzie tę parę punktów. Przypuśćmy, że nie. Wtedy istnieje co najmniej 7 punktów pomiędzy p i q w Y' . Niech $r = (x_r, y_r)$ będzie jednym z nich. Skoro $d(p, q) < \delta$ to $y_q - y_p = |y_q - y_p| \leq \sqrt{(x_p - x_q)^2 + (y_p - y_q)^2} = d(p, q) < \delta$. Ponadto y_r musi być między y_p i y_q : $y_p \leq y_r \leq y_q$, więc $y_r - y_p \leq y_q - y_p < \delta$ zatem co najmniej 9 punktów z P w prostokącie $2\delta \times \delta$ ograniczonym poziomymi liniami $y = y_p$, $y = y_p + \delta$.



Rysunek 2: Prostokąt $2\delta \times \delta$ ograniczony prostymi $y = y_p$ oraz $y = y_p + \delta$. Zacieniowany lewy kwadrat $\delta \times \delta$ zawiera co najmniej 5 punktów z P .

Wtedy w lewym lub prawym kwadracie $\delta \times \delta$ jest przynajmniej 5 punktów z P . Przypuśćmy, że to lewy kwadrat. Zatem istnieje kwadrat $\delta \times \delta$ z 5 punktami z P w P_L . Ale wtedy istnieją dwa punkty w P_L w odległości mniejszej niż δ , bo nie da się umieścić w kwadracie $\delta \times \delta$ 5 punktów dla których odległość między dowolnymi dwoma jest mniejsza niż δ . Sprzeczność (bo najmniejsza odległość w P_L to $\delta_L \geq \delta$).



Rysunek 3: W kwadracie $\delta \times \delta$ nie zmieści się 5 punktów parami oddalonych o co najmniej δ . Najlepsze ułożenie to 4 narożniki; dowolny piąty punkt q jest w odległości co najwyżej $\frac{\delta}{\sqrt{2}} < \delta$ od któregoś z nich (dwa z 5 punktów trafiają do tej samej ćwiartki $\frac{\delta}{2} \times \frac{\delta}{2}$).

Zatem wystarczy sprawdzić tylko 7 następnych punktów po p w Y' . □

Dygresja. Powyższy dowód prowadzimy *nie wprost*, ale tę samą granicę 7 można dostać równie dobrze *wprost*, zliczając punkty. Oba rozumowania korzystają z tego samego faktu geometrycz-

nego (w kwadracie $\delta \times \delta$ mieści się co najwyżej 4 punkty parami oddalone o co najmniej δ) i są równoważne – różnią się jedynie sposobem zliczania.

Wersja wprost. Ustalmy punkt p z Y' . Każdy punkt p' , którego odległość od p chcemy sprawdzić, leży w prostokącie $2\delta \times \delta$ ograniczonym pasem szerokości 2δ wokół l oraz liniami $y = y_p$ i $y = y_p + \delta$ (bo Y' jest posortowane względem y , więc patrzymy tylko w stronę rosnącego y). Podzielmy ten prostokąt prostą l na lewy i prawy kwadrat $\delta \times \delta$. Lewy kwadrat leży w całości w P_L , więc wszystkie jego punkty są parami oddalone o co najmniej $\delta_L \geq \delta$; tak samo prawy w P_R . Stąd w każdym kwadracie jest co najwyżej 4 punkty, czyli w całym prostokącie co najwyżej 8. Jednym z nich jest samo p , więc pozostaje co najwyżej 7 punktów do sprawdzenia.

Zauważmy, że podział prostą l jest tu istotny: gdyby traktować prostokąt $2\delta \times \delta$ jako jeden blok, mógłby on zawierać więcej niż 8 punktów parami oddalonych o $\geq \delta$ (bo punkty z P_L i P_R mogą być blisko siebie). Dopiero rozbiecie na dwa kwadraty $\delta \times \delta$, z których każdy leży po jednej stronie l , gwarantuje ograniczenie 4.

Granice 8 (wprost) i 9 (nie wprost) nie są sprzeczne: w dowodzie nie wprost zakładamy, że algorytm *pomiija* parę p, q , co wymusiłoby co najmniej 9 punktów w prostokącie, a więc ≥ 5 w jednym kwadracie – co jest niemożliwe. Wersja wprost mówi natomiast, że więcej niż 8 (a więc i 9) punktów po prostu się tam nie zmieści.

Analiza złożoności czasowej Na początku musimy posortować tablicę X i Y . To zajmuje $\mathcal{O}(n \log n)$. Jeśli X i Y są już posortowane to podział X na posortowane X_L i X_R oraz Y analogicznie zajmie $\mathcal{O}(n)$.

Algorytm 2: Podział posortowanej tablicy Y na Y_L i Y_R

```

1:  $length(Y_L) \leftarrow length(Y_R) \leftarrow 0$ 
2: for  $i \leftarrow 1$  to  $length(Y)$  do
3:   if  $Y(i) \in P_L$  then
4:      $length(Y_L) \leftarrow length(Y_L) + 1$ 
5:      $Y_L(length(Y_L)) \leftarrow Y(i)$ 
6:   else
7:      $length(Y_R) \leftarrow length(Y_R) + 1$ 
8:      $Y_R(length(Y_R)) \leftarrow Y(i)$ 

```

Mamy dwa wywołania rekurencyjne dla $n/2$ punktów i fazę połącz. Tablicę Y' można otrzymać z Y w czasie $\mathcal{O}(n)$ tak, że Y' jest posortowana. Niech $x = x_L$ będzie równanie prostej l .

Algorytm 3: Wyznaczanie tablicy Y' punktów w pasie 2δ wokół prostej l

```

1:  $length(Y') \leftarrow 0$ 
2: for  $i \leftarrow 1$  to  $length(Y)$  do
3:   if  $x_L - \delta \leq Y(i).x \leq x_L + \delta$  then
4:      $length(Y') \leftarrow length(Y') + 1$ 
5:      $Y'(length(Y')) \leftarrow Y(i)$ 

```

Skoro dla każdego z $\mathcal{O}(n)$ punktów z Y' sprawdzamy odległość tylko co najwyżej 7 punktów, to najmniejsza odległość δ' punktów z Y' znajdziemy w czasie $\mathcal{O}(n)$.

Oznaczmy złożoność algorytmu bez wstępnego sortowania przez $T(n)$. Mamy:

$$T(n) = 2 \cdot T\left(\frac{n}{2}\right) + \Theta(n^1) \qquad a = 2, \quad b = 2, \quad k = 1$$

$$2 = 2^1 \Rightarrow T(n) = \Theta(n \log n)$$

Programowanie dynamiczne

Czasami gdy zaimplementujemy jakąś formę rekurencyjną dostajemy algorytm działający w czasie wykładniczym. Powodem może być to, że jakieś wartości obliczane są wielokrotnie.


Problem 2.1 (liczb Fibonacciego).

$$\begin{cases} F_0 = F_1 = 1 & n = 0, 1 \\ F_n = F_{n-1} + F_{n-2} & n \geq 2 \end{cases} \quad \text{Zadanie: Obliczyć } n\text{-tą liczbę Fibonacciego}$$

Algorytm 4: Algorytm naiwny Fib1

```
function FIB1(n)
1:  if  $n \leq 1$  then return 1
2:  return FIB1(n-1) + FIB1(n-2)
```

Zobaczmy jak jest obliczane np. $FIB1(5)$. W drzewie wywołań poszczególne wartości powtarzają się:



Rysunek 4: Drzewo wywołań rekurencyjnych $FIB1(5)$. Wierzchołki o tym samym kolorze odpowiadają temu samemu podproblemowi, liczonemu wielokrotnie od zera: F_3 jest wyznaczane 2 razy, F_2 – 3 razy, a F_1 – 5 razy.

$F(i)$ jest obliczane razy

(1)	5
(2)	3
(3)	2
(4)	1
(5)	1

Niech $s(n)$ będzie liczbą dodawań wykonanych przez alg. w wywołaniu $FIB1(n)$.

$$\begin{cases} s(0) = s(1) = 0 \\ s(n) = s(n-1) + s(n-2) + 1 & n \geq 2 \end{cases}$$

Niech $f(n) = s(n) + 1$

Wtedy $f(0) = f(1) = 1$

$f(n) = s(n) + 1 =$

$$= s(n-1) + s(n-2) + 1 + 1 =$$

$$= f(n-1) - 1 + f(n-2) - 1 + 1 + 1 =$$

$$= f(n-1) + f(n-2)$$

Zatem $f(n) = F_n$, czyli $f(n)$ jest n -tą liczbą Fibonacciego.

Liczby Fibonacciego rosną jak n -ta potęga złotej liczby, więc

$$f(n) = \Theta(F_n) = \Theta\left(\left(\frac{1+\sqrt{5}}{2}\right)^n\right) = \Omega(1.61^n),$$

gdzie ostatnie oszacowanie jest dolne, bo $1.61 < \frac{1+\sqrt{5}}{2} \approx 1.618$.

Stąd $s(n) = f(n) - 1 = \Omega(1.61^n)$, więc liczba dodawań rośnie wykładniczo.

FIB1 jest algorytmem wykładniczym.

Oto alg. progr. dynamicznego:

Algorytm 5: Algorytm dynamiczny Fib2

```

function FIB2( $n$ )
1:   if  $n \leq 1$  then return 1
2:    $F(0) \leftarrow F(1) \leftarrow 1$ 
3:   for  $i \leftarrow 2$  to  $n$  do
4:      $F(i) \leftarrow F(i-1) + F(i-2)$ 
5:   return  $F(n)$ 

```

▷ F - tablica

Liczba dodawań wykonanych przez FIB2 w wywołaniu FIB2(n) wynosi $n-1$. Złożoność czasowa wynosi $\Theta(n)$.

Algorytm mnożenia macierzy

Przypomnijmy, jak mnoży się macierze. Iloczyn $C = A \cdot B$ macierzy A rozmiaru $p \times q$ oraz B rozmiaru $q \times r$ jest macierzą C rozmiaru $p \times r$, w której element $C(i, j)$ to iloczyn skalarny i -tego wiersza macierzy A oraz j -tej kolumny macierzy B :

$$C(i, j) = \sum_{k=1}^q A(i, k) \cdot B(k, j).$$

Biorąc dla przykładu $p = 2$, $q = 3$, $r = 2$ i obliczając wyróżniony element $C(1, 1)$:

$$\underbrace{\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}}_{A: p \times q} \cdot \underbrace{\begin{bmatrix} 7 & 8 \\ 9 & 10 \\ 11 & 12 \end{bmatrix}}_{B: q \times r} = \underbrace{\begin{bmatrix} 58 & 64 \\ 139 & 154 \end{bmatrix}}_{C: p \times r}$$

$$C(1, 1) = 1 \cdot 7 + 2 \cdot 9 + 3 \cdot 11 = 7 + 18 + 33 = 58.$$

Każdy czynnik i -tego wiersza macierzy A tworzy iloczyn z odpowiadającym mu (tym samym stylem) czynnikiem j -tej kolumny macierzy B ; ich suma po $k = 1, \dots, q$ daje element $C(i, j)$ i jest zarazem wewnętrzną pętlą algorytmu. Każdy z $p \cdot r$ elementów macierzy C wymaga q mnożeń.

Algorytm 6: Naiwne mnożenie macierzy

```

function MATRIXMULTIPLY( $A, B$ )  ▷  $A$  – macierz  $p \times q$ ;  $B$  – macierz  $q \times r$ ;  $C$  – macierz  $p \times r$ 
1:   for  $i \leftarrow 1$  to  $p$  do
2:     for  $j \leftarrow 1$  to  $r$  do
3:        $C(i, j) \leftarrow 0$ 
4:       for  $k \leftarrow 1$  to  $q$  do
5:          $C(i, j) \leftarrow C(i, j) + A(i, k) \cdot B(k, j)$   ▷ operacja dominująca
6:   return  $C$ 
    
```

Operacją dominującą jest mnożenie w linii 5. Mamy $p \cdot q \cdot r$ mnożeń. Złożoność jest $\mathcal{O}(p \cdot q \cdot r)$.

Problem mnożenia ciągu macierzy

Przykład 2.2 (Mnożenie ciągu macierzy).

(A_1, A_2, A_3) gdzie A_1 – macierz 5×10 , A_2 – macierz 10×3 , A_3 – macierz 3×2 . Ile potrzeba mnożeń skalarnych (mnożenia liczb) do obliczenia iloczynu $A_1 \cdot A_2 \cdot A_3$?

$$A_1 \cdot A_2 \cdot A_3 = (A_1 \cdot A_2) \cdot A_3 = A_1 \cdot (A_2 \cdot A_3)$$

I sposób: $(A_1 \cdot A_2) \cdot A_3 = 5 \cdot 10 \cdot 3 + 5 \cdot 3 \cdot 2 = 150 + 30 = 180$

II sposób: $A_1 \cdot (A_2 \cdot A_3) = 10 \cdot 3 \cdot 2 + 5 \cdot 10 \cdot 2 = 60 + 100 = 160$

II sposób jest szybszy.

Problem 2.3 (mnożenia ciągu macierzy).

Dla danego ciągu macierzy $(A_1, A_2, \dots, A_n)$, gdzie A_i jest macierzą $p_{i-1} \times p_i$ (cały ciąg wymiarów zapisujemy jednym ciągiem $p = (p_0, p_1, \dots, p_n)$ – kolejne macierze dzielą wspólny wymiar, więc n macierzy opisuje $n + 1$ liczb), znajdź kolejność wykonywania mnożeń minimalizującą liczbę mnożeń skalarnych użytych do obliczenia iloczynu $A_1 \cdot A_2 \cdot \dots \cdot A_n$.

Ile jest różnych sposobów obliczenia tego iloczynu? Innymi słowy, na ile sposobów możemy poprawnie wstawić nawiasy w iloczynie $A_1 \cdot A_2 \cdot \dots \cdot A_n$?

Przykład 2.4 (Kolejności nawiasowania dla $n = 4$).

$$A_1 \cdot A_2 \cdot A_3 \cdot A_4 \quad (n = 4)$$

- $((A_1 \cdot A_2) \cdot A_3) \cdot A_4$
- $(A_1 \cdot (A_2 \cdot A_3)) \cdot A_4$
- $A_1 \cdot ((A_2 \cdot A_3) \cdot A_4)$
- $A_1 \cdot (A_2 \cdot (A_3 \cdot A_4))$
- $(A_1 \cdot A_2) \cdot (A_3 \cdot A_4)$

Zatem mamy 5 sposobów.

Sprawdźmy czy umiemy rozwiązać ten problem szybko poprzez sprawdzenie wszystkich możliwości. Niech $P(n)$ – liczba sposobów wstawienia nawiasów w iloczynie n macierzy. Załóżmy, że ostatnie mnożenie w ciągu $A_1 \dots A_n$ to mnożenie między A_k i A_{k+1} : $(A_1 \dots A_k)(A_{k+1} \dots A_n)$. W podciągach lewym i prawym nawiasy są rozmieszczane niezależnie od siebie.

Stąd rekurencja:

$$\begin{cases} P(n) = \sum_{k=1}^{n-1} P(k) \cdot P(n-k) \\ P(1) = 1 \end{cases}$$

Jest to znana formuła rekurencyjna a rozwiązanie to przesunięta liczba Catalana:

$$P(n) = C(n-1), \text{ gdzie } C(n) = \frac{1}{n+1} \binom{2n}{n} \text{ jest } n\text{-tą liczbą Catalana.}$$

Wiadomo, że $C(n) = \Omega\left(\frac{4^n}{n^{3/2}}\right)$. Zatem $P(n)$ jest wykładniczy względem n . Chcemy znaleźć szybki algorytm.

Rozwiązanie z optymalną podstrukturą: Zauważmy że jeśli optymalne rozwiązanie jest postaci $(A_1 \dots A_k)(A_{k+1} \dots A_n)$ dla jakiegoś $k \in \{1, \dots, n-1\}$, to w podciągach $A_1 \dots A_k$ i $A_{k+1} \dots A_n$ rozwiązanie nawiasów musi być optymalne. Wpp. lepsze rozmieszczenie nawiasów w $A_1 \dots A_k$ lub $A_{k+1} \dots A_n$ dałoby lepsze rozmieszczenie nawiasów w całym ciągu.

Rozwiązanie optymalne zawiera rozwiązania optymalne podproblemów (własność optymalnej podstruktury). Podproblemami w naszym problemie są problemy optymalnego rozmieszczenia nawiasów w ciągach $A_i A_{i+1} \dots A_j$ dla $1 \leq i \leq j \leq n$.

Niech $m(i, j)$ oznacza minimalną liczbę mnożeń skalarnych potrzebnych do obliczenia tego iloczynu $A_i \dots A_j$ dla $1 \leq i \leq j \leq n$. Chcemy obliczyć $m(1, n)$.

$$m(i, i) = 0$$

Optymalny sposób rozmieszczenia nawiasów jest postaci $(A_i \dots A_k)(A_{k+1} \dots A_j)$ dla pewnego $k \in \{i, \dots, j-1\}$. Stąd mamy zależność:

$$m(i, j) = \min_{i \leq k < j} \{m(i, k) + m(k+1, j) + p_{i-1} \cdot p_k \cdot p_j\} \quad \text{dla } i < j$$

Dygresja. Składnik $p_{i-1} \cdot p_k \cdot p_j$ to koszt *ostatniego* mnożenia, czyli pomnożenia macierzy będącej wynikiem $A_i \dots A_k$ przez macierz będącą wynikiem $A_{k+1} \dots A_j$. Rozmiar iloczynu ciągu macierzy odczytujemy „teleskopowo” – wewnętrzne wymiary (liczba kolumn poprzedniej macierzy = liczba wierszy następnej) skracają się, a zostają jedynie skrajne:

$$\begin{aligned} A_i \dots A_k : & \quad M_{p_{i-1}}^{p_i} \cdot M_{p_i}^{p_{i+1}} \dots M_{p_{k-1}}^{p_k} \longrightarrow M_{p_{i-1}}^{p_k}, \\ A_{k+1} \dots A_j : & \quad M_{p_k}^{p_{k+1}} \cdot M_{p_{k+1}}^{p_{k+2}} \dots M_{p_{j-1}}^{p_j} \longrightarrow M_{p_k}^{p_j}. \end{aligned}$$

Pozostaje pomnożyć macierz $M_{p_{i-1}}^{p_k}$ przez macierz $M_{p_k}^{p_j}$, a to – zgodnie ze wzorem na koszt mnożenia dwóch macierzy – kosztuje

$$\underbrace{p_{i-1} \cdot p_k \cdot p_j}_{\text{wspólny wymiar}}$$

mnożeń skalarnych.

¹ M_a^b – przestrzeń liniowa macierzy o a wierszach i b kolumnach (wymiaru $a \times b$).

Niech $s(i, j)$, dla $1 \leq i < j \leq n$, będzie wartością k , dla którego to minimum jest osiągane (czyli $s(i, j)$ wskazuje miejsce ostatniego mnożenia w optymalnym rozwiązaniu podproblemu $A_i \dots A_j$).

Jeśli zaimplementujemy po prostu tę formułę rekurencyjną otrzymamy alg. wykładniczy. Ale jest tylko $n + \binom{n}{2} = \mathcal{O}(n^2)$ podproblemów, więc rzędu $\mathcal{O}(n^2)$ liczb $m(i, j)$ i każdą z tych liczb wystarczy obliczyć jeden raz.

Pomysł programowania dynamicznego polega więc na zapamiętaniu tych wartości w tablicy zamiast liczenia ich wielokrotnie. Wprowadzamy dwie tablice indeksowane parą (i, j) , $1 \leq i \leq j \leq n$ (a ponieważ rozważamy tylko $i \leq j$, wypełniona zostaje jedynie górna połowa każdej z nich – jak w przykładzie poniżej):

- $m(i, j)$ – **koszt**: minimalna liczba mnożeń skalarnych dla podproblemu $A_i \dots A_j$. Ostateczną odpowiedzią jest $m(1, n)$.
- $s(i, j)$ – **cięcie**: miejsce k ostatniego mnożenia, na którym ten minimalny koszt jest osiągany. Sama tablica m podaje tylko *ile* mnożeń wystarczy, ale nie *jak* ustawić nawiasy; to s pozwala odtworzyć optymalne nawiasowanie (wykorzysta ją algorytm MATRIXCHAIN-MULTIPLY dalej).

Algorytm 7: Algorytm Matrix Chain Order

```

function MATRIXCHAINORDER( $p$ )
1:   $n \leftarrow \text{length}(p) - 1$ 
2:  for  $i \leftarrow 1$  to  $n$  do
3:     $m(i, i) \leftarrow 0$ 
4:    for  $l \leftarrow 2$  to  $n$  do
5:      for  $i \leftarrow 1$  to  $n - l + 1$  do
6:         $j \leftarrow i + l - 1$ 
7:         $m(i, j) \leftarrow \infty$ 
8:        for  $k \leftarrow i$  to  $j - 1$  do
9:           $q \leftarrow m(i, k) + m(k + 1, j) + p_{i-1} \cdot p_k \cdot p_j$ 
10:         if  $q < m(i, j)$  then
11:            $m(i, j) \leftarrow q$ 
12:            $s(i, j) \leftarrow k$ 
13:  return  $m, s$ 

```

$\triangleright p = (p_0, p_1, \dots, p_n)$ - ciąg rozmiarów
 $\triangleright A_i$ - macierz $p_{i-1} \times p_i$
 $\triangleright l$ - liczba macierzy w podproblemie
 $\triangleright l = 2$: $A_1 A_2, A_2 A_3, \dots, A_{n-1} A_n$
 $\triangleright l = 3$: $A_1 A_2 A_3, A_2 A_3 A_4, \dots, A_{n-2} A_{n-1} A_n$
 $\triangleright l = n$: $A_1 \dots A_n$

Dygresja. Algorytm wypełnia tablicę m od dołu: zaczyna od najmniejszych podproblemów i rośnie. Kluczowa jest kolejność, w jakiej wypełnimy komórki – tak dobrana, by w chwili liczenia $m(i, j)$ wszystkie potrzebne mniejsze wartości były już policzone.

- **Pierwsza pętla (po i)** ustawia przekątną $m(i, i) = 0$: pojedyncza macierz nie wymaga żadnego mnożenia.
- **Zmienna l** to *długość* podproblemu, czyli liczba macierzy w ciągu $A_i \dots A_j$. Wzór $m(i, j) = \min_k \{ m(i, k) + m(k+1, j) + \dots \}$ odwołuje się wyłącznie do podciągów *krótszych* niż $A_i \dots A_j$ (bo $k < j$ oraz $k+1 > i$). Dlatego idziemy po $l = 2, 3, \dots, n$: gdy liczymy ciągi długości l , wszystkie ciągi długości $< l$ są już w tablicy.
- **Przy ustalonym l** przesuwamy okno długości l wzdłuż ciągu: i to początek okna, a koniec wyznacza $j = i + l - 1$. Górna granica $i \leq n - l + 1$ pilnuje, by okno nie wyszło poza A_n (komentarze obok pętli pokazują, jak dla kolejnych l przesuwa się okno).
- **Wewnętrzna pętla po k** próbuje każdego miejsca ostatniego mnożenia $A_i \dots A_k \mid A_{k+1} \dots A_j$ i zostawia to o najmniejszym koszcie q . Przy każdej poprawie zapamiętujemy

nie tylko koszt w $m(i, j)$, ale i zwycięskie cięcie w $s(i, j)$ – to ono pozwoli później odtworzyć nawiasowanie.

Innymi słowy: l mówi *jak duży* podproblem liczymy, i (a z nim j) *który* to podproblem, a k przeszukuje wszystkie sposoby jego rozcięcia.

Mamy 3 pętle (po l, i, k) i liczbę iteracji każdej z tych pętli można ograniczyć przez n , zatem złożoność czasowa to $\mathcal{O}(n^3)$.

Przykład 2.5 (Optymalna kolejność mnożenia macierzy dla $n = 5$).

$p = (4, 5, 2, 1, 2, 3)$.

$A_1 - 4 \times 5$, $A_2 - 5 \times 2$, $A_3 - 2 \times 1$, $A_4 - 1 \times 2$, $A_5 - 2 \times 3$.

$$m \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & 0 & 40 & 30 & 38 & 48 \\ 2 & \times & 0 & 10 & 20 & 31 \\ 3 & \times & \times & 0 & 4 & 12 \\ 4 & \times & \times & \times & 0 & 6 \\ 5 & \times & \times & \times & \times & 0 \end{bmatrix}$$

$$s \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & \times & 1 & 1 & 3 & 3 \\ 2 & \times & \times & 2 & 3 & 3 \\ 3 & \times & \times & \times & 3 & 3 \\ 4 & \times & \times & \times & \times & 4 \\ 5 & \times & \times & \times & \times & \times \end{bmatrix}$$

Prześledźmy, jak rosną obie tablice. Algorytm wypełnia je *przekątnymi*: najpierw $L = 1$ (przekątna główna), potem $L = 2$, $L = 3$, Komórki dopisane w danym kroku wyróżniono na **pomarańczowo**; puste pola to podproblemy jeszcze nieobliczone, a $\times$ – pola nieużywane ($i \geq j$ dla s , $i > j$ dla m).

Stan początkowy ($L = 1$, pojedyncze macierze, koszt 0):

$$m \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & 0 & & & & \\ 2 & \times & 0 & & & \\ 3 & \times & \times & 0 & & \\ 4 & \times & \times & \times & 0 & \\ 5 & \times & \times & \times & \times & 0 \end{bmatrix}$$

$$s \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & \times & & & & \\ 2 & \times & \times & & & \\ 3 & \times & \times & \times & & \\ 4 & \times & \times & \times & \times & \\ 5 & \times & \times & \times & \times & \times \end{bmatrix}$$

i	0	1	2	3	4	5
p_i	4	5	2	1	2	3

 $A_i = p_{i-1} \times p_i$

$L = 2$:

$m(1, 2) = 4 \cdot 5 \cdot 2 = 40$

$m(2, 3) = 5 \cdot 2 \cdot 1 = 10$

$m(3, 4) = 2 \cdot 1 \cdot 2 = 4$

$m(4, 5) = 1 \cdot 2 \cdot 3 = 6$

po $L = 2$ (pary sąsiednich macierzy):

$$m \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & 0 & 40 & & & \\ 2 & \times & 0 & 10 & & \\ 3 & \times & \times & 0 & 4 & \\ 4 & \times & \times & \times & 0 & 6 \\ 5 & \times & \times & \times & \times & 0 \end{bmatrix}$$

$$s \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & \times & 1 & & & \\ 2 & \times & \times & 2 & & \\ 3 & \times & \times & \times & 3 & \\ 4 & \times & \times & \times & \times & 4 \\ 5 & \times & \times & \times & \times & \times \end{bmatrix}$$

i	0	1	2	3	4	5
p_i	4	5	2	1	2	3

 $A_i = p_{i-1} \times p_i$

$$\begin{aligned}
 L = 3 : \quad m(1,3) &= \min \begin{cases} m(1,1) + m(2,3) + 4 \cdot 5 \cdot 1 \\ m(1,2) + m(3,3) + 4 \cdot 2 \cdot 1 \end{cases} = \min \begin{cases} 0 + 10 + 20 \\ 40 + 0 + 8 \end{cases} = \min \begin{cases} 30 \\ 48 \end{cases} = 30 \\
 m(2,4) &= \min \begin{cases} m(2,2) + m(3,4) + 5 \cdot 2 \cdot 2 \\ m(2,3) + m(4,4) + 5 \cdot 1 \cdot 2 \end{cases} = \min \begin{cases} 0 + 4 + 20 \\ 10 + 0 + 10 \end{cases} = \min \begin{cases} 24 \\ 20 \end{cases} = 20 \\
 m(3,5) &= \min \begin{cases} m(3,3) + m(4,5) + 2 \cdot 1 \cdot 3 \\ m(3,4) + m(5,5) + 2 \cdot 2 \cdot 3 \end{cases} = \min \begin{cases} 0 + 6 + 6 \\ 4 + 0 + 12 \end{cases} = \min \begin{cases} 12 \\ 16 \end{cases} = 12
 \end{aligned}$$

po $L = 3$:

m	$i \setminus j$	1	2	3	4	5
	1	0	40	30		
	2	×	0	10	20	
	3	×	×	0	4	12
	4	×	×	×	0	6
	5	×	×	×	×	0

s	$i \setminus j$	1	2	3	4	5
	1	×	1	1		
	2	×	×	2	3	
	3	×	×	×	3	3
	4	×	×	×	×	4
	5	×	×	×	×	×

i	0	1	2	3	4	5
p_i	4	5	2	1	2	3

 $A_i = p_{i-1} \times p_i$

$$\begin{aligned}
 L = 4 : \quad m(1,4) &= \min \begin{cases} m(1,1) + m(2,4) + 4 \cdot 5 \cdot 2 \\ m(1,2) + m(3,4) + 4 \cdot 2 \cdot 2 \\ m(1,3) + m(4,4) + 4 \cdot 1 \cdot 2 \end{cases} = \min \begin{cases} 0 + 20 + 40 \\ 40 + 4 + 16 \\ 30 + 0 + 8 \end{cases} = \min \begin{cases} 60 \\ 60 \\ 38 \end{cases} = 38 \\
 m(2,5) &= \min \begin{cases} m(2,2) + m(3,5) + 5 \cdot 2 \cdot 3 \\ m(2,3) + m(4,5) + 5 \cdot 1 \cdot 3 \\ m(2,4) + m(5,5) + 5 \cdot 2 \cdot 3 \end{cases} = \min \begin{cases} 0 + 12 + 30 \\ 10 + 6 + 15 \\ 20 + 0 + 30 \end{cases} = \min \begin{cases} 42 \\ 31 \\ 50 \end{cases} = 31
 \end{aligned}$$

po $L = 4$:

m	$i \setminus j$	1	2	3	4	5
	1	0	40	30	38	
	2	×	0	10	20	31
	3	×	×	0	4	12
	4	×	×	×	0	6
	5	×	×	×	×	0

s	$i \setminus j$	1	2	3	4	5
	1	×	1	1	3	
	2	×	×	2	3	3
	3	×	×	×	3	3
	4	×	×	×	×	4
	5	×	×	×	×	×

i	0	1	2	3	4	5
p_i	4	5	2	1	2	3

 $A_i = p_{i-1} \times p_i$

$$L = 5 : \quad m(1,5) = \min \begin{cases} m(1,1) + m(2,5) + 4 \cdot 5 \cdot 3 \\ m(1,2) + m(3,5) + 4 \cdot 2 \cdot 5 \\ m(1,3) + m(4,5) + 4 \cdot 1 \cdot 3 \\ m(1,4) + m(5,5) + 4 \cdot 2 \cdot 3 \end{cases} = \min \begin{cases} 0 + 31 + 60 \\ 40 + 12 + 24 \\ 30 + 6 + 12 \\ 38 + 0 + 24 \end{cases} = \min \begin{cases} 91 \\ 76 \\ 48 \\ 62 \end{cases} = 48$$

po $L = 5$ (cały ciąg – ostatnia komórka):

m	$i \backslash j$	1	2	3	4	5
	1	0	40	30	38	48
	2	×	0	10	20	31
	3	×	×	0	4	12
	4	×	×	×	0	6
	5	×	×	×	×	0

s	$i \backslash j$	1	2	3	4	5
	1	×	1	1	3	3
	2	×	×	2	3	3
	3	×	×	×	3	3
	4	×	×	×	×	4
	5	×	×	×	×	×

Każdy przebieg pętli po l dopisuje dokładnie jedną przekątną: w komórce $m(i, j)$ łąduje koszt, a w bliźniaczej $s(i, j)$ – zwycięskie cięcie k . Ostatnią obliczoną wartością jest $m(1, 5) = 48$ w prawym górnym rogu – szukany koszt całego ciągu.

Oto algorytm znajdowania optymalnego rozwiązania:

Algorytm 8: Algorithm Matrix Chain Multiply

```

function MATRIXCHAINMULTIPLY( $A, s, i, j$ )                                ▷  $A = (A_1, \dots, A_n)$ 
1:   if  $j = i$  then
2:     return  $A_i$ 
3:    $X \leftarrow$  MATRIXCHAINMULTIPLY( $A, s, i, s(i, j)$ )
4:    $Y \leftarrow$  MATRIXCHAINMULTIPLY( $A, s, s(i, j) + 1, j$ )
5:   return MATRIXMULTIPLY( $X, Y$ )

```

W celu znalezienia rozwiązania wywołujemy: $\text{MATRIXCHAINMULTIPLY}(A, s, 1, n)$

$$A_1 \cdot A_2 \cdot A_3 \cdot A_4 \cdot A_5$$

$$s(1, 5) = 3 \implies (A_1 \cdot A_2 \cdot A_3)(A_4 \cdot A_5)$$

$$s(1, 3) = 1 \implies (A_1 \cdot (A_2 \cdot A_3))(A_4 \cdot A_5) \quad s(4, 5) = 4 \implies \text{bez zmian}$$

$$s(2, 3) = 2 \implies (A_1 \cdot (A_2 \cdot A_3))(A_4 \cdot A_5)$$

Aby algorytm zadziałał dobrze, problem musi spełniać warunki:

1. Własność optymalnej podstruktury – optymalne rozwiązanie problemu można skonstruować z optymalnych rozwiązań podproblemów.
2. Własność wspólnych podproblemów – sytuacja, gdy prosty algorytm rekurencyjny obliczałby rozwiązania tych samych podproblemów wielokrotnie. Liczba podproblemów powinna być „mała”.

W klasycznej metodzie programowania dynamicznego rozwiązanie jest budowane od dołu do góry – od podproblemów najmniejszych do największych. Jest też podejście, w którym rozwiązanie jest budowane od góry do dołu, podobnie jak w prostym algorytmie rekurencyjnym, ale z tą różnicą, że unikamy obliczania tych samych podproblemów wielokrotnie. To podejście nazywa się spamiętywaniem (*memoization*).

Problem mnożenia ciągu macierzy ze spamiętywaniem Algorytm oblicza tablice m i s jak poprzednio, ale w inny sposób. Dopóki podproblem nie jest rozwiązany, $m(i, j)$ przechowuje ∞ . Po rozwiązaniu podproblemu (i, j) umieszczamy w $m(i, j)$ odpowiednią wartość i od tej pory używamy jej bez obliczania.

Algorytm 9: Algorytm Lookup Chain

function LOOKUPCHAIN(p, i, j) $\triangleright p = (p_0, \dots, p_n)$ - ciąg wymiarów; A_i - macierz $p_{i-1} \times p_i$

```

1:  if  $m(i, j) < \infty$  then
2:    return  $m(i, j), s(i, j)$ 
3:  if  $i = j$  then
4:     $m(i, j) \leftarrow 0$ 
5:  else
6:    for  $k \leftarrow i$  to  $j - 1$  do
7:       $q \leftarrow \text{LOOKUPCHAIN}(p, i, k) + \text{LOOKUPCHAIN}(p, k + 1, j) + p_{i-1} \cdot p_k \cdot p_j$ 
8:      if  $q < m(i, j)$  then
9:         $m(i, j) \leftarrow q$ 
10:        $s(i, j) \leftarrow k$ 
11:  return  $(m(i, j), s(i, j))$ 

```

Algorytm 10: Algorytm Memoized Matrix Chain

function MEMOIZEDMATRIXCHAIN(p)

```

1:   $n \leftarrow \text{length}(p) - 1$ 
2:  for  $i \leftarrow 1$  to  $n$  do
3:    for  $j \leftarrow i$  to  $n$  do
4:       $m(i, j) \leftarrow \infty$ 
5:  return LOOKUPCHAIN( $p, 1, n$ )

```

Złożoność czasowa:

- Linie 1–4 w MEMOIZEDMATRIXCHAIN zajmują $\Theta(n^2)$.
- Każdy z $\mathcal{O}(n^2)$ elementów tablicy m jest modyfikowany raz, później odczytanie wartości $m(i, j)$ zajmuje czas stały.
- Modyfikacja $m(i, j)$ zajmuje $\mathcal{O}(n)$ czasu (pętla w liniach 5–9 w LOOKUPCHAIN).

Ostatecznie złożoność algorytmu wynosi $\mathcal{O}(n^3)$.

Problem najdłuższego wspólnego podciągu

Niech $X = (x_1, \dots, x_m)$ – ciąg.

$Z = (z_1, \dots, z_k)$ jest podciągiem X , jeśli istnieje rosnący ciąg indeksów $1 \leq i_1 < i_2 < \dots < i_k \leq m$ takich, że dla każdego $j \in \{1, \dots, k\}$, $z_j = x_{i_j}$.

Przykład 2.6 (Podciąg).

$X = (A, B, C, B, D, A, B)$, $Z = (B, C, D, B)$. Indeksy: (2, 3, 5, 7).

Problem 2.7 (najdłuższego wspólnego podciągu).


Dane są ciągi $X = (x_1, \dots, x_m)$ oraz $Y = (y_1, \dots, y_n)$. Należy znaleźć najdłuższy wspólny podciąg (LCS – *Longest Common Subsequence*) X i Y , czyli najdłuższy ciąg, który jest podciągiem zarówno X , jak i Y .

Wszystkich podciągów X jest 2^m , więc algorytm sprawdzający wszystkie podciągi X działa w czasie wykładniczym.

Niech $X_i = (x_1, \dots, x_i)$ dla $i \in \{1, \dots, m\}$ i dodatkowo $X_0 = ()$ (ciąg pusty). Analogicznie dla Y .

Lemat 2.8. Niech $X = (x_1, \dots, x_m)$, $Y = (y_1, \dots, y_n)$ i niech $Z = (z_1, \dots, z_k)$ będzie LCS X i Y .

1. Jeśli $x_m = y_n$, to $z_k = x_m = y_n$ i Z_{k-1} jest LCS X_{m-1} i Y_{n-1} .
2. Jeśli $x_m \neq y_n$ i $z_k \neq x_m$, to Z jest LCS X_{m-1} i Y .
3. Jeśli $x_m \neq y_n$ i $z_k \neq y_n$, to Z jest LCS X i Y_{n-1} .



Rysunek 5: Trzy przypadki lematu o optymalnej podstrukturze LCS. Żółta komórka – dopasowany ostatni element ($x_m = y_n$), który wchodzi do LCS; szara, przekreślona komórka – element odrzucony, nienależący do tego LCS; przerywana pomarańczowa ramka – podproblem(y), do których redukuje się zadanie.

Rozwiązanie dla problemu (X, Y) można skonstruować z rozwiązań podproblemów (X_{m-1}, Y_{n-1}) , (X_{m-1}, Y) i (X, Y_{n-1}) – **własność optymalnej podstruktury**. Podproblem (X_{m-1}, Y_{n-1}) jest zawarty w podproblemach (X_{m-1}, Y) i (X, Y_{n-1}) – **własność wspólnych podproblemów**.

Niech $c(i, j)$ oznacza długość LCS ciągów X_i i Y_j .

$$c(i, j) = \begin{cases} 0 & \text{jeśli } i = 0 \text{ lub } j = 0 \\ c(i-1, j-1) + 1 & \text{jeśli } i, j > 0 \text{ i } x_i = y_j \\ \max\{c(i-1, j), c(i, j-1)\} & \text{jeśli } i, j > 0 \text{ i } x_i \neq y_j \end{cases}$$

Będziemy też używać tablicy $b(i, j)$, aby znaleźć sam podciąg LCS. Tablica c ma wymiary $(m+1) \times (n+1)$ (indeksowana od 0), a b – $m \times n$ (indeksowana od 1). Wartości w tablicy kierunków to $b(i, j) \in \{\nwarrow, \uparrow, \leftarrow\}$.

Algorytm 11: Algorytm obliczający długość LCS

```

function LCS( $X, Y$ )
1:   $m \leftarrow \text{length}(X)$ 
2:   $n \leftarrow \text{length}(Y)$ 
3:  for  $i \leftarrow 0$  to  $m$  do
4:     $c(i, 0) \leftarrow 0$ 
5:  for  $j \leftarrow 0$  to  $n$  do
6:     $c(0, j) \leftarrow 0$ 
7:  for  $i \leftarrow 1$  to  $m$  do
8:    for  $j \leftarrow 1$  to  $n$  do
9:      if  $x_i = y_j$  then
10:          $c(i, j) \leftarrow c(i-1, j-1) + 1$ 
11:          $b(i, j) \leftarrow \text{"}\nwarrow\text{"}$ 
12:      else if  $c(i-1, j) \geq c(i, j-1)$  then
13:          $c(i, j) \leftarrow c(i-1, j)$ 
14:          $b(i, j) \leftarrow \text{"}\uparrow\text{"}$ 
15:      else
16:          $c(i, j) \leftarrow c(i, j-1)$ 
17:          $b(i, j) \leftarrow \text{"}\leftarrow\text{"}$ 

```

```
18:   return (c, b)
```

Przykład: $X = (A, B, C, B, D, A, B)$, $Y = (B, D, C, A, B, A)$.
 $m = 7$, $n = 6$.

Tablica kosztów c :

	j	0	1	2	3	4	5	6
i		y_j	B	D	C	A	B	A
0	x_i	0	0	0	0	0	0	0
1	A	0	0	0	0	1	1	1
2	B	0	1	1	1	1	2	2
3	C	0	1	1	2	2	2	2
4	B	0	1	1	2	2	3	3
5	D	0	1	2	2	2	3	3
6	A	0	1	2	2	3	3	4
7	B	0	1	2	2	3	4	4

Tablica strzałek b :

	j	0	1	2	3	4	5	6
i		y_j	B	D	C	A	B	A
0	x_i							
1	A		↑	↑	↑	↖	←	↖
2	B		↖	←	←	↑	↖	←
3	C		↑	↑	↖	←	↑	↑
4	B		↖	↑	↑	↑	↖	←
5	D		↑	↖	↑	↑	↑	↑
6	A		↑	↑	↑	↖	↑	↖
7	B		↖	↑	↑	↑	↖	↑

Dygresja. Pełne wypełnienie tablicy to $7 \cdot 6 = 42$ powtórzenia tej samej reguły, więc prześledźmy tylko po jednej komórce na każdą z gałęzi rekurencji (pozostałe liczymy analogicznie). Indeksowanie: $X = (x_1, \dots, x_7)$, $Y = (y_1, \dots, y_6)$.

- **Dopasowanie** (↖). Komórka $c(2, 1)$: $x_2 = B$, $y_1 = B$, więc $x_i = y_j$. Bierzymy wartość z przekątnej i dodajemy 1: $c(2, 1) = c(1, 0) + 1 = 0 + 1 = 1$. Ostatnie znaki się zgadzają, więc element wchodzi do LCS i strzałka wskazuje ↖.
- **Brak dopasowania, w górę** (↑). Komórka $c(3, 1)$: $x_3 = C$, $y_1 = B$, więc $x_i \neq y_j$. Porównujemy sąsiadów: $c(2, 1) = 1$ (góra) oraz $c(3, 0) = 0$ (lewo). Ponieważ $c(i-1, j) \geq c(i, j-1)$, bierzemy $c(3, 1) = c(2, 1) = 1$ i strzałkę ↑.
- **Brak dopasowania, w lewo** (←). Komórka $c(2, 2)$: $x_2 = B$, $y_2 = D$, więc $x_i \neq y_j$. Sąsiedzi: $c(1, 2) = 0$ (góra) oraz $c(2, 1) = 1$ (lewo). Tym razem $c(i-1, j) < c(i, j-1)$, więc $c(2, 2) = c(2, 1) = 1$ i strzałka ←.
- **Remis.** Komórka $c(1, 1)$: $x_1 = A \neq B = y_1$, a obaj sąsiedzi są równi: $c(0, 1) = c(1, 0) = 0$. Warunek $c(i-1, j) \geq c(i, j-1)$ jest spełniony (równość), więc algorytm wybiera ↑ – remis rozstrzygamy zawsze na korzyść góry.

Algorytm 12: Wypisywanie najdłuższego wspólnego podciągu

```
function PRINTLCS(b, X, Y, i, j)
1:   if i = 0 lub j = 0 then
2:     return ε
3:   if b(i, j) = „↖” then
4:     PRINTLCS(b, X, Y, i - 1, j - 1)
5:     print xi
6:   else if b(i, j) = „↑” then
7:     PRINTLCS(b, X, Y, i - 1, j)
8:   else
9:     PRINTLCS(b, X, Y, i, j - 1)
```

▷ ciąg pusty

Podejście programowania dynamicznego Definiujemy zbiory zajęć:

$$S_{ij} = \{z_k \in S : t_i \leq s_k < t_k \leq s_j\}$$

(zbiór zajęć zaczynających się po czasie zakończenia zajęcia z_i i kończących się przed czasem rozpoczęcia zajęcia z_j).

Dodajemy 2 sztuczne zajęcia: z_0 z czasem $t_0 = 0$ i z_{n+1} z czasem $s_{n+1} = \infty$. Wtedy $S = S_{0,n+1}$. Jeśli $i \geq j$, to $S_{ij} = \emptyset$, bo $s_j < t_j \leq t_i$ (bo zajęcia są posortowane).

Dygresja. Pokażmy dokładniej, dlaczego $S_{ij} = \emptyset$ dla $i \geq j$. Przypuśćmy, że istnieje $z_k \in S_{ij}$. Z definicji S_{ij} mamy wtedy $t_i \leq s_k < t_k \leq s_j$, a ponieważ zajęcia są posortowane i $i \geq j$, to $t_j \leq t_i$, skąd $s_j < t_j \leq t_i$. Łącząc obie nierówności, otrzymujemy $s_j < t_i \leq s_k < t_k \leq s_j$, czyli $s_j < s_j$ – sprzeczność.

Problem: znaleźć podzbiór o największej liczności zbioru S_{ij} składający się z parami zgodnych zajęć dla $0 \leq i \leq j \leq n+1$.

Niech A_{ij} będzie jakimkolwiek podzbiorem największej liczności składającym się z parami zgodnych zajęć zbioru S_{ij} oraz niech $c(i, j) = |A_{ij}|$.

Podproblem S_{ij} : Załóżmy, że $z_k \in S_{ij}$. Jeśli wybierzemy z_k do zbioru rozwiązania, to otrzymamy dwa zbiory (podproblemy):

- S_{ik} (zbiór zajęć, które zaczynają się po zakończeniu zajęcia z_i i kończą się przed rozpoczęciem zajęcia z_k),
- S_{kj} (zbiór zajęć, które zaczynają się po zakończeniu zajęcia z_k i kończą przed rozpoczęciem zajęcia z_j).

Rozwiązanie dla S_{ij} będzie sumą rozwiązań dla S_{ik} oraz S_{kj} oraz elementu $\{z_k\}$.

Własność optymalnej podstruktury: Załóżmy, że $z_k \in A_{ij}$. Wtedy $A_{ij} = A_{ik} \cup \{z_k\} \cup A_{kj}$. Gdyby istniało rozwiązanie A'_{ik} dla S_{ik} takie, że $|A'_{ik}| > |A_{ik}|$, to zbiór $A'_{ij} = A'_{ik} \cup \{z_k\} \cup A_{kj}$ byłby rozwiązaniem dla S_{ij} takim, że $|A'_{ij}| > |A_{ij}|$. Sprzeczność. Analogicznie dla S_{kj} . Zatem A_{ik} oraz A_{kj} muszą być rozwiązaniami optymalnymi dla odpowiednio S_{ik} i S_{kj} .

Stąd wzór rekurencyjny:

$$\begin{cases} c(i, j) = 0 & \text{dla } i \geq j \\ c(i, j) = \max_{i < k < j} \{c(i, k) + c(k, j) + 1\} \end{cases}$$

Używając tego wzoru rekurencyjnego możemy skonstruować algorytm programowania dynamicznego. Mamy $\mathcal{O}(n^2)$ podproblemów. Dla $j > i$ mamy $j - i - 1$ wartości k do sprawdzenia, czyli rozwiązanie jednego podproblemu zajmie czas liniowy. Otrzymujemy algorytm o złożoności $\mathcal{O}(n^3)$.

Algorytm zachłanny

Lemat 3.4. Niech $z_m \in S_{ij}$ będzie zajęciem takim, że $t_m = \min\{t_k : z_k \in S_{ij}\}$. Wtedy:

1. Istnieje podzbiór o największej liczności składający się z parami zgodnych zajęć zbioru S_{ij} zawierający z_m .
2. $S_{im} = \emptyset$ (zatem po wybraniu z_m do zbioru rozwiązania zostaje co najwyżej 1 niepusty podproblem do rozwiązania – S_{mj}).

Z lematu wynika, że nie musimy sprawdzać $j - i - 1$ wartości k , możemy wybrać zajęcie o najmniejszym czasie zakończenia $z_m \in S_{ij}$. Żeby rozwiązać podproblem S_{ij} możemy dodać z_m do zbioru rozwiązania a następnie dodać do zbioru rozwiązania rozwiązanie optymalne podproblemu S_{mj} . Zaczynamy z $S = S_{0,n+1}$ i $t_0 = 0$. W pierwszym kroku algorytm wybiera z_1 .

Algorytm 13: Zachłanny wybór zajęć

```

function GREEDYACTIVITYSELECTOR( $s, t$ )    ▷ zajęcia są posortowane po czasie zakończeń
1:    $n \leftarrow \text{length}(s)$ 
2:    $A \leftarrow \{z_1\}$                                 ▷  $A$  - zbiór rozwiązań
3:    $j \leftarrow 1$ 
4:   for  $i \leftarrow 2$  to  $n$  do
5:     if  $s_i \geq t_j$  then
6:        $A \leftarrow A \cup \{z_i\}$ 
7:        $j \leftarrow i$ 
8:   return  $A$ 

```

Algorytm zachłanny w każdym kroku wybiera zajęcie zgodne ze wszystkimi zajęciami poprzednio wybranymi, o najmniejszym czasie zakończenia, aby zostawić jak najwięcej miejsca dla zajęć następnych (algorytm zachłanny). Skoro one są posortowane, jeśli $j < k$ i z_k jest zgodne z z_j , to z_k jest też zgodne z z_i dla każdego $1 \leq i < j$.

Analiza poprawności: Algorytm zwraca zbiór parami zgodnych zajęć, bo dodaje do zbioru rozwiązania zajęcie tylko jeśli jest zgodne ze wszystkimi zajęciami dodanymi wcześniej.

Pokażemy przez indukcję po n , że algorytm znajduje rozwiązanie optymalne.

- Dla $n = 1$ oczywiste ✓
- Niech $n > 1$. Z lematu istnieje optymalne rozwiązanie A_1 takie, że $z_1 \in A_1$.
Rozważmy problem dla $S' = \{z_i \in S : s_i \geq t_1\}$. Oczywiście zachodzi $|S'| < |S|$.
Dla każdego $z_j \in A_1 \setminus \{z_1\}$, mamy $z_j \in S'$, bo $s_j \geq t_1$, co wynika z faktu, że A_1 jest rozwiązaniem dla S .
Pokażemy, że $A_1 \setminus \{z_1\}$ jest rozwiązaniem optymalnym dla S' .
Przypuśćmy, że istnieje rozwiązanie B dla S' takie, że $|B| > |A_1 \setminus \{z_1\}|$. Wtedy $\{z_1\} \cup B$ byłoby rozwiązaniem dla S takim, że:

$$|\{z_1\} \cup B| = 1 + |B| > 1 + |A_1 \setminus \{z_1\}| = |A_1|$$

Otrzymujemy sprzeczność, bo A_1 jest z założenia rozwiązaniem optymalnym.

Z założenia indukcyjnego nasz algorytm znajduje rozwiązanie optymalne B' dla S' . Wtedy $|B'| = |A_1 \setminus \{z_1\}| = |A_1| - 1$.

Zbiór $\{z_1\} \cup B'$ jest rozwiązaniem znalezionym przez algorytm dla S i:

$$|\{z_1\} \cup B'| = 1 + |B'| = 1 + |A_1| - 1 = |A_1|$$

Więc $\{z_1\} \cup B'$ jest rozwiązaniem optymalnym.

Złożoność czasowa

- linia 1 – $\mathcal{O}(n)$
- linia 2 – $\mathcal{O}(1)$
- iteracji pętli w linii 3 jest $n - 1$
- wewnątrz pętli zajmuje czas $\mathcal{O}(1)$

Całość zajmuje $\Theta(n)$, jeśli zajęcia są już posortowane po czasie zakończenia. Ostatecznie złożoność algorytmu wynosi (uwzględniając początkowe sortowanie):

$$\mathcal{O}(n \log n) + \Theta(n) = \mathcal{O}(n \log n)$$

Kody Huffmana

Często znaki są reprezentowane przy użyciu 8 bitów (np. ASCII). Skoro częstość znaków się różni, lepiej reprezentować znaki występujące często przy użyciu krótszych ciągów bitów, a znaki występujące rzadko przy użyciu dłuższych ciągów bitów.

częstość = liczba wystąpień

Przykład W pliku jest 58 znaków. Każdy znak jest elementem zbioru $\{a, e, i, s, t, r, n\}$.

		<i>a</i>	<i>e</i>	<i>i</i>	<i>s</i>	<i>t</i>	<i>r</i>	<i>n</i>
	częstość	10	15	12	3	4	13	1
kod 1	stała długość słowa kodowego	000	001	010	011	100	101	110
kod 2	zmienna długość słowa kodowego	001	01	10	00000	0001	11	00001
kod 3	zmienna długość słowa kodowego	001	01	10	00010	0001	11	00001

Jeśli użyjemy kodu o stałej długości słowa kodowego (kod 1) to zakodowany plik ma: $58 \cdot 3 = 174$ bity.

Jeśli użyjemy kodu o zmiennej długości słowa kodowego (kod 2 lub kod 3) to zakodowany plik ma:

$$10 \cdot 3 + 15 \cdot 2 + 12 \cdot 2 + 3 \cdot 5 + 4 \cdot 4 + 13 \cdot 2 + 1 \cdot 5 = 146 \text{ bitów.}$$

Jeśli używamy kodu o zmiennej długości słowa kodowego, to chcemy aby spełniony był warunek: **żadne słowo kodowe nie jest prefixem innego słowa kodowego.**


Takie kody nazywa się kodami prefixowymi (choć powinno być bezprefixowe).

Rozważmy kod 3. Ciąg 0001001 można odkodować na dwa sposoby:

- 00010 01 $\Rightarrow$ *s e*
- 0001 001 $\Rightarrow$ *t a*

Tutaj 0001 jest prefixem 00010, czyli słowo kodowe znaku *t* jest prefixem słowa kodowego znaku *s*.

Reprezentacja drzewowa kodów Słowo kodowe znaku jest ciągiem etykiet krawędzi na ścieżce od korzenia do wierzchołka zaetykietowanego tym znakiem.



Uwaga. Żadne słowo kodowe nie jest prefixem innego słowa kodowego $\iff$ wszystkie znaki są reprezentowane przez liście w reprezentacji drzewowej kodu.

Etykietujemy wierzchołki w następujący sposób: każdy wierzchołek v dostaje etykietę będącą sumą wystąpień znaków, które są reprezentowane przez liście poddrzewa ukorzenionego w v .

Niech C będzie alfabetem, $f : C \rightarrow \mathbb{N}_+$, $f(c)$ = częstość znaku $c \in C$.

$d_T(c)$ – głębokość liścia reprezentującego znak $c \in C$ w drzewie T

$d_T(c)$ = długość słowa kodowego znaku $c \in C$ w kodzie reprezentowanym przez drzewo T

Liczba bitów w zakodowanym pliku (kod reprezentowany przez drzewo T) wynosi:

$$B(T) = \sum_{c \in C} f(c) \cdot d_T(c)$$

Kod prefixowy reprezentowany przez drzewo T nazywamy optymalnym, jeśli $B(T)$ jest najmniejsze możliwe.

Drzewo ukorzenione nazywamy binarnym, jeśli każdy wierzchołek ma co najwyżej dwoje dzieci.

Drzewo binarne nazywamy regularnym, jeśli każdy wierzchołek wewnętrzny ma dokładnie dwoje dzieci.

Twierdzenie 3.5. *Drzewo binarne reprezentujące optymalny kod jest regularne.*

Algorytm Huffmana

Algorytm konstruuje drzewo reprezentujące optymalny kod prefixowy dla (C, f) . Zaczynamy od $|C|$ wierzchołków izolowanych (które staną się liśćmi) i wykonujemy $|C| - 1$ operacji łączenia

zaczynając od najrzadszych znaków (będą miały największą głębokość w drzewie).

Będziemy używać kolejki priorytetowej z kluczem $f(c)$. Kolejkę priorytetową możemy zaimplementować używając kopca binarnego. Wtedy koszty operacji wynoszą:

- INSERT – $\mathcal{O}(\log n)$
- EXTRACT_MIN – $\mathcal{O}(\log n)$
- CREATE – $\mathcal{O}(n)$

gdzie n jest liczbą elementów w kolejce.

Algorytm 14: Algorytm Huffmana

```

function HUFFMAN( $C, f$ )
1:   $n \leftarrow |C|$ 
2:   $Q \leftarrow \text{CREATE}(C, f)$ 
3:  for  $i \leftarrow 1$  to  $n - 1$  do
4:       $z \leftarrow \text{NEW\_NODE}$ 
5:       $x \leftarrow \text{LEFT}(z) \leftarrow \text{EXTRACT\_MIN}(Q)$ 
6:       $y \leftarrow \text{RIGHT}(z) \leftarrow \text{EXTRACT\_MIN}(Q)$ 
7:       $f(z) \leftarrow f(x) + f(y)$ 
8:      INSERT( $Q, z$ )
9:  return EXTRACT_MIN( $Q$ )

```

▷ Q - kolejka priorytetowa

Algorytm konstruuje drzewo binarne. z - wierzchołek, *left, right* - dzieci.

Dygresja. Intuicyjnie algorytm działa zachłannie, budując drzewo *od dołu*. Każdy znak $c \in C$ jest na początku osobnym, izolowanym wierzchołkiem; będzie on liściem gotowego drzewa. Kolejka priorytetowa Q przechowuje korzenie wszystkich dotąd zbudowanych poddrzew, uporządkowane wg ich łącznej częstości f (im rzadszy znak, tym wcześniej zostanie wyjęty).

W każdej z $n - 1$ iteracji pętli wykonujemy jeden krok łączenia:

- EXTRACT_MIN(Q) dwukrotnie wybiera dwa korzenie o *najmniejszej* częstości (x oraz y);
- tworzymy nowy wierzchołek z i podpinamy x, y jako jego lewe i prawe dziecko;
- częstość nowego wierzchołka ustalamy jako $f(z) = f(x) + f(y)$, po czym wkładamy z z powrotem do kolejki przez INSERT(Q, z).

Łącząc zawsze dwa najrzadsze poddrzewa, spychamy najrzadsze znaki najgłębiej w drzewie – to one dostaną najdłuższe kody, a znaki częste pozostaną blisko korzenia i otrzymają kody krótkie. Każde łączenie zmniejsza liczbę poddrzew w Q o jeden (dwa wyjęcia, jedno wstawienie), więc po $n - 1$ iteracjach zostaje dokładnie jeden korzeń – całe drzewo kodu, które zwracamy.

Złożoność czasowa

- linia 1 – $\mathcal{O}(1)$
- linia 2 – $\mathcal{O}(n)$
- wewnątrz pętli z linii 3 wykona się $n - 1$ razy:
 - linia 4 – $\mathcal{O}(1)$
 - linie 5, 6 – $\mathcal{O}(\log n)$
 - linia 7 – $\mathcal{O}(1)$
 - linia 8 – $\mathcal{O}(\log n)$

Wewnątrz pętli zajmuje łącznie czas $\mathcal{O}(\log n)$.

$$\mathcal{O}(n) + (n - 1) \cdot \mathcal{O}(\log n) = \mathcal{O}(n \log n)$$

Złożoność czasowa algorytmu wynosi $\mathcal{O}(n \log n)$.


Przykład 3.6 (Konstrukcja drzewa Huffmana).

Zaczynamy ze zbiorem wierzchołków: $(n, 1), (s, 3), (t, 4), (a, 10), (i, 12), (r, 13), (e, 15)$.

1. Łączymy n i s .

Zostają:


$(t, 4), (a, 10), (i, 12), (r, 13), (e, 15)$.



2. Łączymy 4 i t .


Zostają:

$(a, 10), (i, 12), (r, 13), (e, 15)$.




3. Łączymy 8 i a .

Zostają: $(i, 12), (r, 13), (e, 15)$.




4. Łączymy i i r .


Zostaje: $(e, 15)$.



5. Łączymy e i 18.



6. Łączymy 25 i 33.
(ostateczne drzewo kodów)



Odczytany kod z drzewa w kroku 6:

$i \Rightarrow 00$
 $r \Rightarrow 01$
 $e \Rightarrow 10$
 $n \Rightarrow 11000$
 $s \Rightarrow 11001$
 $t \Rightarrow 1101$
 $a \Rightarrow 111$

Dowód optymalności algorytmu Huffmana

Kody prefiksowe $\iff$ regularne drzewa binarne.

C – alfabet, $f : C \rightarrow \mathbb{N}$ funkcja częstości, $d_T(c)$ – głębokość liścia reprezentującego c w drzewie T reprezentującym kod prefiksowy.


$$B(T) = \sum_{c \in C} f(c) \cdot d_T(c) \longleftarrow \min$$

Lemat 3.7. Niech x i y będą najrzadziej występującymi znakami z C . Istnieje optymalny kod prefiksowy, w którym słowa kodowe x i y mają tę samą długość i różnią się tylko na ostatnim bicie.

Z lematu 3.7 wynika, że można zacząć konstrukcję optymalnego drzewa połączeniem dwóch symboli o najmniejszej częstości. **Zachłanny wybór** – w każdym kroku algorytm łączy dwa wierzchołki o najmniejszych kluczach.

Lemat 3.8. Niech A będzie alfabetem z funkcją częstości $f : A \rightarrow \mathbb{N}$, a $x, y \in A$ – dwoma znakami o najmniejszych częstościach. Zdefiniujmy zredukowany alfabet $A' = (A \setminus \{x, y\}) \cup \{z\}$, gdzie $z \notin A$, z funkcją częstości f' taką, że $f'(c) = f(c)$ dla $c \neq z$ oraz $f'(z) = f(x) + f(y)$.

Jeśli T' jest optymalnym drzewem kodu prefiksowego dla (A', f') , to drzewo T powstałe z T' przez zastąpienie liścia z wewnętrznym węzłem z dziećmi x i y jest optymalnym drzewem kodu prefiksowego dla (A, f) .



Twierdzenie 3.9. *Algorytm Huffmana konstruuje drzewo reprezentujące optymalny kod prefiksowy.*

Szeregowanie zadań

Problem 3.10 (Szeregowanie zadań – jeden procesor).

Jak uszeregować zadania tak, aby średni czas ukończenia był jak najmniejszy?

Przykład 3.11 (Szeregowanie zadań – jeden procesor).

i	zadanie	t_i
1	z_1	15
2	z_2	8
3	z_3	3
4	z_4	10

Rozważmy uszeregowanie z_1, z_2, z_3, z_4 :

$$\frac{15 + (15 + 8) + (15 + 8 + 3) + (15 + 8 + 3 + 10)}{4} = \frac{15 + 23 + 26 + 36}{4} = \frac{100}{4} = 25$$

Rozważmy uszeregowanie z_3, z_2, z_4, z_1 :

$$\frac{3 + (3 + 8) + (3 + 8 + 10) + (3 + 8 + 10 + 15)}{4} = \frac{3 + 11 + 21 + 36}{4} = 17\frac{3}{4}$$

Rozwiązanie: Uszereguj zadania od najkrótszego do najdłuższego.

Problem 3.12 (Szeregowanie zadań – 3 procesory).

Mamy 3 procesory. Pytanie jak poprzednio (por. 3.11).

Przykład 3.13 (Szeregowanie zadań – trzy procesory).

Zadanie	z_1	z_2	z_3	z_4	z_5	z_6	z_7	z_8	z_9
t_i	3	5	6	10	11	14	15	18	20

Rozwiązanie: Przydzielaj zadania do pierwszego wolnego procesora w kolejności od najkrótszego do najdłuższego.

	3	5	6	13	16	20	28	34	40
P_1	z_1		z_4			z_7			
P_2	z_2		z_5			z_8			
P_3	z_3		z_6				z_9		

W problemie 3.11 dla uszeregowania $z_{i_1}, z_{i_2}, \dots, z_{i_n}$ suma zakończeń zadań wynosi:

$$\begin{aligned} \sum_{j=1}^n \sum_{k=1}^j t_{i_k} &= t_{i_1} + (t_{i_1} + t_{i_2}) + (t_{i_1} + t_{i_2} + t_{i_3}) + \dots + (t_{i_1} + \dots + t_{i_n}) = \\ &= n \cdot t_{i_1} + (n-1)t_{i_2} + (n-2)t_{i_3} + \dots + 1 \cdot t_{i_n} = \sum_{j=1}^n (n+1-j)t_{i_j} \end{aligned}$$

W problemie 3.12 (dla $3 \mid n$) dla uszeregowania $z_{i_1}, z_{i_2}, \dots, z_{i_n}$ suma czasów zakończeń wynosi:

$$\begin{aligned} &\underbrace{t_{i_1} + t_{i_2} + t_{i_3}} + \underbrace{(t_{i_1} + t_{i_4}) + (t_{i_2} + t_{i_5}) + (t_{i_3} + t_{i_6})}_{+ \dots + (t_{i_1} + t_{i_4} + \dots + t_{i_{n-2}})} + \underbrace{(t_{i_1} + t_{i_4} + t_{i_7}) + (t_{i_2} + t_{i_5} + t_{i_8}) + (t_{i_3} + t_{i_6} + t_{i_9})}_{+ \dots + (t_{i_1} + t_{i_4} + \dots + t_{i_{n-2}})} + \\ &= \frac{n}{3}(t_{i_1} + t_{i_2} + t_{i_3}) + \left(\frac{n}{3} - 1\right)(t_{i_4} + t_{i_5} + t_{i_6}) + \left(\frac{n}{3} - 2\right)(t_{i_7} + t_{i_8} + t_{i_9}) + \\ &+ \dots + 1 \cdot (t_{i_{n-2}} + t_{i_{n-1}} + t_{i_n}) = \\ &= \sum_{j=1}^n \left(\frac{n}{3} - \left\lfloor \frac{j-1}{3} \right\rfloor\right) t_{i_j} = \sum_{j=1}^n \left\lceil \frac{n+1-j}{3} \right\rceil \cdot t_{i_j} \end{aligned}$$

Lemat 3.14. Niech $A_1 \geq A_2 \geq \dots \geq A_n$. Dla dowolnej permutacji $\Pi = (i_1, \dots, i_n)$ zbioru $[n]$ niech $f(\Pi) = \sum_{j=1}^n A_j \cdot t_{i_j}$. Wtedy f osiąga minimum na każdej permutacji ustawiającej czasy niemalejąco, tzn. takiej, że $t_{i_1} \leq t_{i_2} \leq \dots \leq t_{i_n}$.

Dygresja. Współczynniki $A_1 \geq \dots \geq A_n$ są ustalone i zadane malejąco — są to wagi pozycji. Permutacja Π decyduje, który czas t_{i_j} trafi na pozycję j (o wadze A_j). Lemat to przypadek nierówności o przestawieniach: aby zminimalizować $\sum_j A_j t_{i_j}$, największą wagę łączymy z najmniejszym czasem, czyli ustawiamy czasy rosnąco względem malejących wag.

Dla naszych problemów współczynnikiem przy t_{i_j} jest $n+1-j$ (str. wcześniej) lub $\left\lceil \frac{n+1-j}{3} \right\rceil$ — oba maleją z j , więc odgrywają rolę A_j . Stąd minimalizacja sumy czasów zakończeń sprowadza się do szeregowania zadań od najkrótszego. „Każda” permutacja w tezie — bo przy remisach czasów istnieje kilka równie optymalnych uporządkowań.

Wniosek 3.15. *Nasze algorytmy szeregowania zadań są poprawne.*

Matroidy

Definicja 3.16. Matroid to para $M = (S, \mathcal{I})^2$ taka, że:

1. S – niepusty zbiór skończony,
2. $\mathcal{I} \subseteq 2^S$ i $\mathcal{I} \neq \emptyset$ – czyli $\mathcal{I}$ to niepusta rodzina podzbiorów S ,
3. $\forall A, B \subseteq S \quad A \in \mathcal{I} \wedge B \subseteq A \implies B \in \mathcal{I}$,
4. własność wymiany:

$$\forall A, B \subseteq S \quad A, B \in \mathcal{I} \wedge |B| > |A| \implies \text{istnieje } x \in B \setminus A \text{ taki, że } A \cup \{x\} \in \mathcal{I}.$$

$\mathcal{I}$ – rodzina zbiorów niezależnych matroidu M , elementy $\mathcal{I}$ – zbiory niezależne matroidu M .

Zbiór niezależny $A \in \mathcal{I}$ nazywamy maksymalnym (lub bazą matroidu M), jeśli nie da się go powiększyć, pozostając niezależnym, tzn. dla każdego $x \in S \setminus A$ zachodzi $A \cup \{x\} \notin \mathcal{I}$.

Dygresja. Matroid to abstrakcja i uogólnienie pojęcia liniowej niezależności z przestrzeni wektorowych. Aksjomaty są dokładnie tymi własnościami niezależności, które przetrwają, gdy zapomnimy o samych wektorach i zostawimy jedynie rodzinę „dozwolonych” (niezależnych) podzbiorów: dziedziczność (wł. 3) odpowiada temu, że podzbiór wektorów liniowo niezależnych nadal jest niezależny, a własność wymiany (wł. 4) to nic innego jak lemat Steinitza o wymianie: jeśli $\{u_1, \dots, u_m\}$ jest liniowo niezależny i leży w przestrzeni rozpiętej przez $\{w_1, \dots, w_n\}$, to $m \leq n$ oraz można wymienić m spośród wektorów w_i na $u_1, \dots, u_m$, nie zmieniając rozpiętej przestrzeni — mniejszy zbiór niezależny zawsze da się „dopełnić” wektorami z większego rozpinającego. To właśnie ta zdolność dokładania elementów uogólnia się do własności wymiany matroidu. Stąd słownictwo teorii matroidów — „niezależny”, „baza”, „rząd” — pożyczone wprost z algebry liniowej (oraz z teorii grafów, por. matroid grafowy).

Przykład 3.17.1 (matroid wektorowy) jest pierwowzorem; przykład 3.17.2 pokazuje, że ta sama struktura opisuje też acykliczność w grafach — te dwa źródła, algebra liniowa i teoria grafów, dały początek całej teorii.

Przykład 3.17.


1. A – macierz, S – zbiór wierszy A , $\mathcal{I} = \{R \subseteq S : R \text{ tworzy zbiór liniowo niezależny}\}$.
Wtedy $(S, \mathcal{I})$ to matroid.
2. $G = (V, E)$ – graf, $\mathcal{I} = \{F \subseteq E : G[F] \text{ jest acykliczny}\}$.
Wtedy $(E, \mathcal{I})$ to matroid zwany matroidem grafowym.

Z definicji $\emptyset \in \mathcal{I}$.


Dygresja. Wspólna intuicja obu przykładów: S to zbiór „kawałków”, a $\mathcal{I}$ wyróżnia te podzbiory, w których *nie ma nadmiarowości*. Dla macierzy nadmiarowość to liniowa zależność wierszy, dla grafu — cykl (krawędź, którą można usunąć bez rozpójniania tego, co już połączone). Dziedziczność (wł. 3) mówi, że usunięcie kawałka z niezależnego zbioru nie tworzy nadmiarowości; własność wymiany (wł. 4) — że mniejszy zbiór niezależny zawsze da się powiększyć o element z większego.

²Oznaczenia za CLRS: S (*set*) – zbiór bazowy, $\mathcal{I}$ (*independent*) – rodzina zbiorów niezależnych. Uwaga: „niezależność” jest tu cechą *pojedynczego* zbioru ($A \in \mathcal{I}$ znaczy, że A jest sam w sobie niezależny), a nie relacją między zbiorami – dziedziczność (wł. 3) mówi tylko, że podzbiór zbioru niezależnego też jest niezależny.

Dla matroidu grafowego: zbiór krawędzi jest niezależny dokładnie wtedy, gdy tworzy las (jest acykliczny). Po lewej — niezależny zbiór (las, krawędzie wyróżnione); po prawej — ten sam zbiór z dołożoną krawędzią e_3 zamykającą cykl abc , więc już zależny:



Ten sam obraz dla matroidu wektorowego (przykład 3.17.1) w $\mathbb{R}^2$: $S = \{v_1, v_2, v_3\}$, niezależność = liniowa niezależność. Dwa niewspółliniowe wektory są niezależne, ale dowolne trzy wektory w $\mathbb{R}^2$ są już zależne — każdy zbiór ≥ 3 elementów jest zależny, więc bazami są wszystkie pary niewspółliniowe (rzęd 2):



Lemat 3.18. Niech $M = (S, \mathcal{I})$. Wszystkie maksymalne zbiory niezależne M mają tę samą licznosc.

Problem 3.19. $M = (S, \mathcal{I})$ – matroid, $w : S \rightarrow \mathbb{R}_+$ – funkcja wagi.

Dla $A \subseteq S$ niech $w(A) = \sum_{x \in A} w(x)$ – waga A .

Znaleźć zbiór niezależny o maksymalnej wadze w M .

$S = \{x_1, x_2, \dots, x_n\}$.

Algorytm 15: Algorytm Greedy

```

function GREEDY( $M, w$ )
1:   $n \leftarrow |S|$ 
2:   $A \leftarrow \emptyset$   $\triangleright A$  – rozwiązanie
3:  posortuj  $S$  w porządku nierosnącym względem wagi, tak żeby  $w(x_1) \geq w(x_2) \geq \dots \geq w(x_n)$ 
4:  for  $i \leftarrow 1$  to  $n$  do
5:    if  $A \cup \{x_i\} \in \mathcal{I}$  then
6:       $A \leftarrow A \cup \{x_i\}$ 
7:  return  $A$ 

```

Dygresja. Idea jest możliwie najprostsza: skoro chcemy dużej wagi, bierzmy elementy od najcięższego do najlżejszego i dokładamy każdy z nich do rozwiązania, o ile tylko nie psuje to niezależności (warunek z linii 5). Raz dodanego elementu nigdy nie wycofujemy — stąd nazwa *zachłanny*: na każdym kroku podejmujemy lokalnie najlepszą decyzję i się jej trzymamy, nie martwiąc się o przyszłość.

Dla dowolnej rodziny $\mathcal{F}$ taka krótkowzroczność zwykle zawodzi, bo wczesny ciężki wybór może zablokować dwa lepsze późniejsze. To, co ratuje algorytm tutaj, to struktura matroidu. Własność wymiany (wł. 4) gwarantuje, że zachłanny wybór nigdy nas nie „zamknie” w gorszym rozwiązaniu: jeśli istnieje cięższy zbiór niezależny, to zawsze da się go wykorzystać do ulepszenia bieżącego — dokładnie ten argument napędza dowód twierdzenia 3.20. Co więcej, działa to też w drugą stronę: zachłanność daje optimum dla każdej funkcji wagi *wtedy i tylko wtedy*, gdy rodzina $\mathcal{F}$ jest matroidem — to właśnie czyni matroidy „naturalnym” środowiskiem dla algorytmów zachłannych.

Twierdzenie 3.20 (Rado, Edmonds).

Algorytm Greedy znajduje zbiór niezależny o maksymalnej wadze.

Złożoność czasowa algorytmu Greedy $n = |S|$

- linia 1: $\mathcal{O}(1)$
- linia 2: $\mathcal{O}(1)$
- linia 3: $\mathcal{O}(n \log n)$
- liczba iteracji pętli z linii 4 wynosi n
- linia 5: $f(n)$ – czas sprawdzenia warunku z linii 5
- linia 6: $\mathcal{O}(1)$
- linia 7: $\mathcal{O}(1)$

Pętla wykonuje n iteracji, a każda kosztuje $f(n) + \mathcal{O}(1)$, co daje koszt pętli $\mathcal{O}(n \cdot f(n))$. Łącznie z sortowaniem otrzymujemy

$$\mathcal{O}(n \log n + n \cdot f(n)),$$

gdzie $f(n)$ to czas sprawdzenia niezależności $A \cup \{x_i\} \in \mathcal{F}$ (linia 5). Złożoność zależy więc od reprezentacji matroidu: dla matroidów, w których test niezależności jest wielomianowy, cały algorytm działa w czasie wielomianowym.

Problem szeregowania zadań

- $S = \{z_1, z_2, \dots, z_n\}$ – zbiór zadań o jednostkowym czasie wykonania
- $d_1, d_2, \dots, d_n$ – deadlines, $d_i \in \{1, \dots, n\}$ dla $i \in [n]$
- $w_1, w_2, \dots, w_n$ – kary, $w_i \geq 0$ dla $i \in [n]$

Płacimy karę w_i za zadanie z_i , jeżeli nie jest skończone w momencie d_i .

Problem 3.21 (szeregowania zadań z karami).

Znaleźć kolejność wykonania zadań minimalizującą sumę kar.

Założmy, że mamy pewien harmonogram. Zadanie z_i nazywamy terminowym w tym harmonogramie, jeśli jest zakończone do chwili d_i , w przeciwnym razie nazywamy je spóźnionym.

Nie płacimy kar za zadania terminowe, płacimy kary za zadania spóźnione.

Lemat 3.22. *Każdy harmonogram można przetransformować na harmonogram z taką samą sumą kar, w którym wszystkie zadania terminowe poprzedzają wszystkie zadania spóźnione oraz zadania terminowe są posortowane w kolejności niemalejącej względem deadline'ów.*

Przypomnijmy, że $S = \{z_1, \dots, z_n\}$ to zbiór wszystkich n zadań, czyli $n = |S|$.

Zbiór $A \subseteq S$ nazywamy wolnym od kar, jeśli istnieje harmonogram zbioru A , w którym wszystkie zadania są terminowe.

Dla $t \in \{0, 1, \dots, n\}$ niech

$$N_t(A) = |\{z_i \in A : d_i \leq t\}|$$

– liczba zadań w A o deadline $\leq t$.

Lemat 3.23. Niech $A \subseteq S$. Następujące warunki są równoważne:

1. A jest wolny od kar.
2. $N_t(A) \leq t$ dla każdego $t \in \{1, 2, \dots, n\}$.
3. Jeśli zadania z A są posortowane w kolejności niemalejącej ze względu na deadline, to żadne zadanie nie jest spóźnione.

Twierdzenie 3.24. Niech S – zbiór zadań o jednostkowym czasie wykonania, a $\mathcal{F}$ – rodzina zbiorów wolnych od kar. Wtedy $(S, \mathcal{F})$ jest matroidem.

Dowód. Sprawdzamy własności z definicji matroidu (Definicja 3.16):

(wł. 1) Oczywiście. ✓

(wł. 2) Dla każdego $i \in [n]$ zachodzi $\{z_i\} \in \mathcal{F}$, więc $\mathcal{F} \neq \emptyset$. ✓

(wł. 3) Niech $A \in \mathcal{F}$ (czyli A jest wolny od kar) i $B \subseteq A$. Z definicji istnieje harmonogram zbioru A , w którym wszystkie zadania są terminowe. Usuwając z tego harmonogramu zadania należące do $A \setminus B$, otrzymujemy harmonogram zbioru B , w którym wszystkie zadania nadal są terminowe (usunięcie zadań nie opóźnia pozostałych). Zatem B jest wolny od kar, czyli $B \in \mathcal{F}$.

(wł. 4) Niech $A, B \in \mathcal{F}$, $|B| > |A|$.

Niech $k \in \{0, 1, \dots, n\}$ będzie największą liczbą t taką, że $N_t(B) \leq N_t(A)$.

k jest dobrze zdefiniowane, bo $N_0(B) = 0 = N_0(A)$.

Mamy $N_n(B) = |B| > |A| = N_n(A)$, więc $k < n$.

Dla $j \in \{k+1, k+2, \dots, n\}$ mamy $N_j(B) > N_j(A)$, więc $N_j(B) \geq N_j(A) + 1$.

$$\left. \begin{array}{l} N_{k+1}(B) > N_{k+1}(A) \\ N_k(B) \leq N_k(A) \end{array} \right\} \implies \text{istnieje zadanie } z \in B \setminus A \text{ o deadline } = k+1$$

Niech $A' = A \cup \{z\}$. Pokażemy, że A' jest wolny od kar, używając lematu 3.23.

- Dla $t \in \{1, 2, \dots, k\}$: $N_t(A') = N_t(A) \leq t$, bo A jest wolny od kar.
- Dla $t \in \{k+1, k+2, \dots, n\}$: $N_t(A') = N_t(A) + 1 \leq N_t(B) \leq t$, bo B jest wolny od kar.

Zatem A' jest wolny od kar.

Pokazaliśmy, że $(S, \mathcal{F})$ jest matroidem. □

Możemy do rozwiązania problemu szeregowania zadań użyć algorytmu Greedy (Algorytm 15) dla matroidu $(S, \mathcal{F})$ maksymalizującego $\sum_{z_i \in A} w_i$ (czyli minimalizującego sumę kar zadań spóźnionych).

Z twierdzenia 3.20 (Rado, Edmonds) algorytm Greedy użyty do tego problemu zwraca rozwiązanie optymalne. Warunek z linii 5 algorytmu Greedy (tzn. czy $A \cup \{x_i\} \in \mathcal{F}$) można sprawdzić w czasie $\mathcal{O}(n)$ – lemat 3.23, warunek 3.

Złożoność czasowa algorytmu wynosi:

$$\mathcal{O}(n \log n + n \cdot n) = \mathcal{O}(n^2)$$

Przykład 3.25 (Szeregowanie zadań z deadlineami).

Rozważmy zadania o następujących deadlineach i karach:

i	1	2	3	4	5	6	7	8
d_i	3	2	2	3	1	4	6	5
w_i	80	70	60	50	40	30	20	10

Zadania są już posortowane w porządku nierosnącym względem wagi ($w_1 \geq w_2 \geq \dots \geq w_8$). Kolejne iteracje algorytmu Greedy (poniżej A wypisane w kolejności niemalejącej po deadlineach; po prawej profil $N(A) = (N_1, \dots, N_8)$, który musi spełniać $N_t \leq t$, czyli nie przekraczać $(1, 2, \dots, 8)$):

- | | |
|---|-----------------------------------|
| 1. $A = (z_1)$ | $N(A) = (0, 0, 1, 1, 1, 1, 1, 1)$ |
| 2. $A = (z_2, z_1)$ | $N(A) = (0, 1, 2, 2, 2, 2, 2, 2)$ |
| 3. $A = (z_2, z_3, z_1)$ | $N(A) = (0, 2, 3, 3, 3, 3, 3, 3)$ |
| 4. $A = (z_2, z_3, z_1)$ (z_4 nie dodajemy, bo $N_3(A \cup \{z_4\}) = 4 > 3$) | |
| 5. $A = (z_2, z_3, z_1)$ (z_5 nie dodajemy, bo $N_2(A \cup \{z_5\}) = 3 > 2$) | |
| 6. $A = (z_2, z_3, z_1, z_6)$ | $N(A) = (0, 2, 3, 4, 4, 4, 4, 4)$ |
| 7. $A = (z_2, z_3, z_1, z_6, z_7)$ | $N(A) = (0, 2, 3, 4, 4, 5, 5, 5)$ |
| 8. $A = (z_2, z_3, z_1, z_6, z_7, z_8, z_7)$ | $N(A) = (0, 2, 3, 4, 5, 6, 6, 6)$ |

Harmonogram (zadania terminowe posortowane po deadlineach, potem zadania spóźnione):

$(z_2, z_3, z_1, z_6, z_8, z_7, z_4, z_5)$

Suma kar = $w_4 + w_5 = 50 + 40 = 90$

Algorytmy aproksymacyjne

Algorytmy aproksymacyjne stosuje się do problemów, dla których jest mała szansa na znalezienie algorytmu dokładnego (np. wielomianowego). Zamiast szukać rozwiązania optymalnego, szukamy rozwiązania „prawie optymalnego”.

Niech Π – problem optymalizacyjny znalezienia maksimum lub minimum pewnej funkcji celu f .

- D_Π – zbiór instancji problemu Π .
- $I \in D_\Pi$ – instancja Π .
- $S(I)$ – zbiór rozwiązań dopuszczalnych dla instancji I .
- $f : \bigcup_{I \in D_\Pi} S(I) \rightarrow \mathbb{R}$ – funkcja celu. Możemy założyć, że

$$\forall I \in D_\Pi \quad \forall s \in S(I) \quad f(s) > 0$$

czyli każde rozwiązanie dopuszczalne każdej instancji ma dodatni koszt. Założenie to nie ogranicza ogólności: jakość aproksymacji mierzymy ilorazem $c(I)/c^*(I)$ (poniżej), a iloraz ma sens tylko dla wartości tego samego znaku i niezerowych. Dla typowych problemów (np. minimalizacja długości trasy, liczby maszyn czy rozmiaru pokrycia) koszt jest z natury dodatni, więc warunek jest spełniony automatycznie.

Niech $c^*(I)$ oznacza wartość rozwiązania optymalnego instancji I , $c^*(I) > 0$.

A – algorytm aproksymacyjny rozwiązujący Π .

$c(I)$ – wartość rozwiązania znalezionej przez algorytm A dla instancji I , $c(I) > 0$.

Definicja 4.1. Mówimy, że algorytm A ma współczynnik aproksymacji $\rho(n)$, jeśli dla każdej instancji $I \in D_{\Pi}$ rozmiaru n zachodzi

$$\max \left\{ \frac{c(I)}{c^*(I)}, \frac{c^*(I)}{c(I)} \right\} \leq \rho(n)$$

Wtedy A nazywamy algorytmem $\rho(n)$ -aproksymacyjnym.

Zauważmy, że:

$$\left. \begin{array}{l} \text{dla problemu maksymalizacji: } 0 < c(I) \leq c^*(I) \\ \text{dla problemu minimalizacji: } 0 < c^*(I) \leq c(I) \end{array} \right\} \Rightarrow \max \left\{ \frac{c(I)}{c^*(I)}, \frac{c^*(I)}{c(I)} \right\} \geq 1$$

Niech $\rho = \sup_{n \in \mathbb{N}} \{\rho(n)\}$. Wtedy mówimy, że współczynnik aproksymacji algorytmu A wynosi ρ i A nazywamy algorytmem ρ -aproksymacyjnym.

Problem pokrycia wierzchołkowego


Definicja 4.2. Niech $G = (V, E)$ – graf. Pokryciem wierzchołkowym (Vertex Cover, VC) grafu G nazywamy zbiór $W \subseteq V$ taki, że dla każdej krawędzi $e \in E$ zachodzi $W \cap e \neq \emptyset$ – czyli każda krawędź G ma co najmniej jeden koniec w W .

Problem 4.3 (pokrycia wierzchołkowego).

- Instancja: graf G .
- Problem: znaleźć pokrycie wierzchołkowe grafu G o minimalnej liczbie wierzchołków.

Przykład 4.4 (Pokrycie wierzchołkowe).

Rozważmy graf G przedstawiony poniżej:



$W = \{a, e, d, f\}$ jest pokryciem wierzchołkowym powyższego grafu G (zaznaczone wyróżnione wierzchołki).

Algorytm Approx Vertex Cover

Algorytm 16: Approx Vertex Cover

```

function AVC( $G$ )
1:   $C \leftarrow \emptyset$ 
2:   $F \leftarrow E(G)$ 
3:  while  $F \neq \emptyset$  do
4:    wybierz dowolną krawędź  $uv \in F$ 
5:     $C \leftarrow C \cup \{u, v\}$ 
6:    usuń z  $F$  wszystkie krawędzie incydentne z  $u$  lub z  $v$ 
7:  return  $C$ 
    
```

▷ C – rozwiązanie
▷ F – zbiór dotychczas niepokrytych krawędzi


Przykład 4.5 (Algorytm AVC – przykład).

Rozważmy graf z poprzedniego przykładu.

Pierwszy przebieg algorytmu może wybrać kolejno krawędzie ab i cd :

- Po wybraniu ab usuwamy z F krawędzie ab, ac, ae, bd, be , zostają cd, de, df .
- Po wybraniu cd usuwamy z F krawędzie cd, de, df – $F = \emptyset$.


Algorytm zwraca $C = \{a, b, c, d\}$.



Inny przebieg algorytmu może wybrać kolejno krawędzie df , be i ac :

- Po wybraniu df usuwamy z F krawędzie df, de, bd, cd .
- Po wybraniu be usuwamy z F krawędzie be, ae, ab .
- Po wybraniu ac usuwamy ostatnią krawędź ac – $F = \emptyset$.

Algorytm zwraca $C = \{d, f, e, b, a, c\}$.



Złożoność czasowa algorytmu AVC $n = |V(G)|$, $m = |E(G)|$.

- linia 1: $\mathcal{O}(1)$
- linia 2: $\mathcal{O}(m)$
- pętlę z linii 3–6 można zaimplementować, żeby działała w czasie $\mathcal{O}(m)$
- linia 7: $\mathcal{O}(1)$

Złożoność czasowa AVC wynosi $\mathcal{O}(m)$.

Twierdzenie 4.6. *AVC jest algorytmem 2-aproksymacyjnym.*

Dowód. Niech G – graf wejściowy.

$c^*(G)$ – najmniejsza liczba wierzchołków w pokryciu wierzchołkowym G .

$c(G)$ – liczba wierzchołków w pokryciu wierzchołkowym znalezionym przez AVC.

Niech B będzie zbiorem krawędzi wybranych przez AVC w linii 4.

B jest skojarzeniem (czyli zbiorem parami rozłącznych krawędzi), bo po wybraniu krawędzi uv algorytm usuwa z F wszystkie krawędzie incydentne z u lub v .


Żeby pokryć krawędzie z B potrzeba co najmniej $|B|$ wierzchołków. Stąd $c^*(G) \geq |B|$.

$c(G) = 2|B|$, bo algorytm dodaje do C oba końce każdej krawędzi z B .

$$c(G) = 2|B| \leq 2 \cdot c^*(G) \implies \frac{c(G)}{c^*(G)} \leq 2$$

□

Pokażemy, że ograniczenie 2 jest osiągnięte. Rozważmy graf złożony z m rozłącznych krawędzi:



AVC zwraca pokrycie złożone z $2m$ wierzchołków, natomiast optymalne pokrycie ma rozmiar m (po jednym końcu z każdej krawędzi). Stąd $\frac{c(G)}{c^*(G)} = 2$.


Problem pokrycia zbioru

Definicja 4.7. Niech X – zbiór skończony, $|X| = n$, $\mathcal{F} \subseteq 2^X$ – rodzina podzbiorów zbioru X taka, że $\bigcup_{S \in \mathcal{F}} S = X$ (każdy element X należy do co najmniej jednego zbioru z $\mathcal{F}$).

Rodzina $\mathcal{C} \subseteq \mathcal{F}$ jest pokryciem³ zbioru X , jeśli $\bigcup_{S \in \mathcal{C}} S = X$.

Przykład 4.8 (Pokrycie zbioru).

Rozważmy zbiór X i rodzinę podzbiorów przedstawione poniżej:



$\mathcal{F} = \{S_1, S_2, S_3, S_4, S_5, S_6\}$. $\{S_1, S_2, S_3\}$ – pokrycie.

Problem 4.9 (pokrycia zbioru).

- Instancja: $(X, \mathcal{F})$, gdzie X – zbiór skończony, $|X| = n$, $\mathcal{F} \subseteq 2^X$ taki, że $\bigcup_{S \in \mathcal{F}} S = X$.
- Problem: znaleźć pokrycie $\mathcal{C} \subseteq \mathcal{F}$ minimalizujące $|\mathcal{C}|$.

Uwaga. VC jest szczególnym przypadkiem problemu pokrycia zbiorów. Dla $G = (V, E)$ kładziemy $X = E$, $\mathcal{F} = \{E(v) : v \in V\}$, gdzie $E(v) = \{e \in E : v \in e\}$.

Algorytm Greedy Set Cover

³Oznaczenia za CLRS: X – zbiór bazowy, $\mathcal{F}$ (family) – rodzina dostępnych podzbiorów, $\mathcal{C}$ (cover) – wybrane pokrycie.

Algorytm 17: Greedy Set Cover

```

function GSC( $X, \mathcal{F}$ )
1:    $U \leftarrow X$ 
2:    $\mathcal{C} \leftarrow \emptyset$ 
3:   while  $U \neq \emptyset$  do
4:     wybierz  $S \in \mathcal{F}$  maksymalizujący  $|S \cap U|$ 
5:      $\mathcal{C} \leftarrow \mathcal{C} \cup \{S\}$ 
6:      $U \leftarrow U \setminus S$ 
7:   return  $\mathcal{C}$ 

```

$\triangleright U$ – zbiór jeszcze niepokrytych elementów
 $\triangleright \mathcal{C}$ – rozwiązanie

Dygresja. Idea jest zachłanna: w każdym kroku patrzymy wyłącznie na bieżący stan i dokładamy do rozwiązania ten zbiór $S \in \mathcal{F}$, który pokrywa najwięcej spośród jeszcze niepokrytych elementów (maksymalizuje $|S \cap U|$), nie przejmując się skutkami dla kolejnych kroków. Zmienna U trzyma elementy pozostające do pokrycia: startuje od całego X , a po każdym wyborze odejmujemy od niej wybrany zbiór ($U \leftarrow U \setminus S$), więc kryterium $|S \cap U|$ premiuje zbiory wnoszące jak najwięcej *nowych* elementów. Pętla kręci się, aż U opustoszeje, czyli aż $\mathcal{C}$ pokryje całe X . Zachłanność nie gwarantuje rozwiązania optymalnego (do tego wrócimy przy analizie współczynnika aproksymacji), ale daje pokrycie szybko i prosto.

Poprawność Pętla wykonuje się, dopóki istnieją niepokryte elementy, a w każdej iteracji co najmniej jeden z nich zostaje pokryty, więc po skończonej liczbie kroków U pustoszeje.

Złożoność czasowa

- linia 1: $\mathcal{O}(n)$
- linia 2: $\mathcal{O}(1)$
- liczba iteracji pętli 3–6 jest $\leq |X|$ i $\leq |\mathcal{F}|$, więc jest $\leq \min\{|X|, |\mathcal{F}|\}$. Wnętrze pętli:
 - linia 4: $\mathcal{O}(|X| \cdot |\mathcal{F}|)$
 - linia 5: $\mathcal{O}(1)$
 - linia 6: $\mathcal{O}(|X|)$
 łącznie $\mathcal{O}(|X| \cdot |\mathcal{F}|)$.
- linia 7: $\mathcal{O}(1)$

Ostatecznie złożoność GSC wynosi $\mathcal{O}(|X| \cdot |\mathcal{F}| \cdot \min\{|X|, |\mathcal{F}|\})$.

Twierdzenie 4.10. *GSC jest algorytmem $H(\max\{|S| : S \in \mathcal{F}\})$ -aproksymacyjnym, gdzie*

$$H(0) = 0, \quad H(m) = 1 + \frac{1}{2} + \frac{1}{3} + \dots + \frac{1}{m} \quad \text{dla } m \geq 1$$

Dowód. Niech $(X, \mathcal{F})$ będzie instancją wejściową.

$\mathcal{C}^*$ – optymalne pokrycie dla $(X, \mathcal{F})$.

$\mathcal{C}$ – pokrycie dla $(X, \mathcal{F})$ znalezione przez GSC.

Niech S_i będzie zbiorem wybranym przez algorytm w linii 4 w i -tej iteracji pętli. Przyznajemy koszt

$$c_x = \frac{1}{|S_i \setminus (S_1 \cup S_2 \cup \dots \cup S_{i-1})|}$$

każdemu elementowi $x \in S_i \setminus (S_1 \cup \dots \cup S_{i-1})$ ($S_i \setminus (S_1 \cup \dots \cup S_{i-1})$ to zbiór elementów pokrytych po raz pierwszy w i -tej iteracji pętli). Całkowity koszt przyznany podczas jednej iteracji wynosi 1, a ponieważ $|\mathcal{C}|$ jest liczbą iteracji pętli, to

$$|\mathcal{C}| = \sum_{x \in X} c_x$$

Rozważmy sumę $\sum_{S \in \mathcal{C}^*} \sum_{x \in S} c_x$. Skoro $\mathcal{C}^*$ jest pokryciem, każdy $x \in X$ występuje w tej sumie co najmniej raz, więc

$$\sum_{S \in \mathcal{C}^*} \sum_{x \in S} c_x \geq \sum_{x \in X} c_x = |\mathcal{C}| \quad (\dagger)$$

Pokażemy, że $\sum_{x \in S} c_x \leq H(|S|)$ dla każdego $S \in \mathcal{F}$.

Niech $S \in \mathcal{F}$. Dla $i \in \{1, 2, \dots, |\mathcal{C}|\}$ niech $n_i = |S \setminus (S_1 \cup \dots \cup S_i)|$ (liczba elementów w S , które nie są pokryte po i -tej iteracji pętli) i niech $n_0 = |S|$.

Niech k będzie najmniejszą liczbą taką, że $n_k = 0$. Wtedy S jest pokryty przez $S_1 \cup S_2 \cup \dots \cup S_k$. Oczywiście $n_{i-1} \geq n_i$ dla $i \in [k]$, a $n_{i-1} - n_i$ to liczba elementów z S pokrytych po raz pierwszy przez S_i .

Zatem

$$\sum_{x \in S} c_x = \sum_{i=1}^k (n_{i-1} - n_i) \cdot \frac{1}{|S_i \setminus (S_1 \cup \dots \cup S_{i-1})|}$$

Dygresja. To tylko przegrupowanie sumy $\sum_{x \in S} c_x$. Zamiast sumować po kolejnych elementach, grupujemy elementy S według iteracji, w której zostały pokryte po raz pierwszy. Każdy $x \in S$ dostaje swój koszt c_x w momencie pierwszego pokrycia: jeśli stało się to w i -tej iteracji, to $c_x = 1/|S_i \setminus (S_1 \cup \dots \cup S_{i-1})|$ – a ten ułamek zależy *tylko* od i , nie od konkretnego x . Elementów S pokrytych po raz pierwszy w i -tej iteracji jest dokładnie $n_{i-1} - n_i$, więc ich łączny wkład do sumy wynosi $(n_{i-1} - n_i) \cdot 1/|S_i \setminus (S_1 \cup \dots \cup S_{i-1})|$. Sumujemy po i od 1 do k , bo po k -tej iteracji całe S jest już pokryte ($n_k = 0$), więc dalsze iteracje nie wnoszą nowych elementów S .

Na podstawie wyboru zachłannego w linii 4, dla każdego $S \in \mathcal{F} \setminus \{S_1, \dots, S_{i-1}\}$ mamy

$$|S_i \setminus (S_1 \cup \dots \cup S_{i-1})| \geq |S \setminus (S_1 \cup \dots \cup S_{i-1})| = n_{i-1} \quad (*)$$

Mamy:

$$\begin{aligned} \sum_{x \in S} c_x &= \sum_{i=1}^k (n_{i-1} - n_i) \cdot \frac{1}{|S_i \setminus (S_1 \cup \dots \cup S_{i-1})|} \stackrel{(*)}{\leq} \sum_{i=1}^k (n_{i-1} - n_i) \cdot \frac{1}{n_{i-1}} \\ &\stackrel{(1)}{=} \sum_{i=1}^k \sum_{j=n_i+1}^{n_{i-1}} \frac{1}{n_{i-1}} \stackrel{(2)}{\leq} \sum_{i=1}^k \sum_{j=n_i+1}^{n_{i-1}} \frac{1}{j} \stackrel{(3)}{=} \sum_{i=1}^k \left(\sum_{j=1}^{n_{i-1}} \frac{1}{j} - \sum_{j=1}^{n_i} \frac{1}{j} \right) \\ &= \sum_{i=1}^k (H(n_{i-1}) - H(n_i)) \\ &= (H(n_0) - H(n_1)) + (H(n_1) - H(n_2)) + \dots + (H(n_{k-1}) - H(n_k)) \\ &= H(n_0) - H(n_k) = H(|S|) - H(0) = H(|S|). \end{aligned} \quad (\ddagger)$$

gdzie kolejne przejścia:

- (1) suma wewnętrzna ma $n_{i-1} - (n_i + 1) + 1 = n_{i-1} - n_i$ jednakowych składników $\frac{1}{n_{i-1}}$, więc obie strony są równe;
- (2) w zakresie sumowania $j \leq n_{i-1}$, zatem $\frac{1}{n_{i-1}} \leq \frac{1}{j}$;
- (3) rozbiecie sumy harmonicznego: $\sum_{j=n_i+1}^{n_{i-1}} \frac{1}{j} = \sum_{j=1}^{n_{i-1}} \frac{1}{j} - \sum_{j=1}^{n_i} \frac{1}{j}$.

Ostatecznie mamy:

$$|\mathcal{C}| = \sum_{x \in X} c_x \stackrel{(\dagger)}{\leq} \sum_{S \in \mathcal{C}^*} \sum_{x \in S} c_x \stackrel{(\ddagger)}{\leq} \sum_{S \in \mathcal{C}^*} H(|S|) \leq \sum_{S \in \mathcal{C}^*} \max\{H(|S|) : S \in \mathcal{C}^*\}$$

$$= |\mathcal{C}^*| \cdot \max\{H(|S|) : S \in \mathcal{C}^*\}$$

$$\stackrel{\mathcal{C}^* \subseteq \mathcal{F}}{\leq} |\mathcal{C}^*| \cdot \max\{H(|S|) : S \in \mathcal{F}\} = |\mathcal{C}^*| \cdot H(\max\{|S| : S \in \mathcal{F}\}),$$

$$\text{więc } \frac{|\mathcal{C}|}{|\mathcal{C}^*|} \leq H(\max\{|S| : S \in \mathcal{F}\}).$$

□

Wniosek 4.11. *GSC jest algorytmem $(\ln |X| + 1)$ -aproksymacyjnym.*

Dowód. $H(n) \leq \ln n + 1$, więc

$$H(\max\{|S| : S \in \mathcal{F}\}) \leq H(|X|) \leq \ln |X| + 1$$

□

Dygresja. Oszacowanie $H(n) \leq \ln n + 1$ wynika z porównania sumy z całką: $\sum_{j=2}^n 1/j \leq \int_1^n 1/x \, dx = \ln n$, więc $H(n) = 1 + \sum_{j=2}^n 1/j \leq 1 + \ln n$.

VC jest szczególnym przypadkiem problemu pokrycia zbiorów. Dla $G = (V, E)$ kładziemy $X = E$, $\mathcal{F} = \{E(v) : v \in V\}$, gdzie $E(v) = \{e \in E : v \in e\}$, $|E(v)| = d(v)$. Wtedy $\max\{|E(v)| : E(v) \in \mathcal{F}\} = \Delta(G)$, więc GSC zastosowany do VC ma współczynnik aproksymacji $H(\Delta(G))$.

Dla grafów o maksymalnym stopniu ≤ 3 ($H(3) < 2 < H(4)$) oszacowanie współczynnika aproksymacyjnego GSC jest lepsze niż oszacowanie dla AVC.

Schematy aproksymacyjne

Niech Π – problem (NP-trudny).

Definicja 4.12. Algorytm A jest schematem aproksymacyjnym dla Π , jeśli dla dowolnego wejścia (I, ϵ) , gdzie I jest instancją Π i $\epsilon > 0$, A jest algorytmem $(1 + \epsilon)$ -aproksymacyjnym.

Definicja 4.13. Schemat aproksymacyjny A nazywamy wielomianowym schematem aproksymacyjnym, jeśli jego złożoność czasowa może być ograniczona wielomianową funkcją względem $|I|$ dla każdego ustalonego $\epsilon > 0$.

Złożoność czasowa wielomianowego schematu aproksymacyjnego może wynosić np. $\Theta(2^{1/\epsilon} \cdot n^2)$, gdzie $n = |I|$. Wtedy zmniejszanie precyzji (czyli zmniejszanie ϵ) jest kosztowne czasowo.

Definicja 4.14. Schemat aproksymacyjny A nazywamy w pełni wielomianowym schematem aproksymacyjnym, jeśli jego złożoność czasowa może być ograniczona funkcją wielomianową względem $|I|$ i $\frac{1}{\epsilon}$.

Problem sumy podzbiorów

Problem 4.15 (sumy podzbiorów (Subset-Sum)).

Instancja: $S = \{x_1, x_2, \dots, x_n\} \subseteq \mathbb{N}$, $t \in \mathbb{N}$.

- *Wersja decyzyjna:* czy istnieje $S' \subseteq S$ takie, że $\sum_{x_i \in S'} x_i = t$?
- *Wersja optymalizacyjna:* znaleźć $S' \subseteq S$ takie, że $\sum_{x_i \in S'} x_i$ jest największą możliwą liczbą $\leq t$.

Dla zbioru $P \subseteq \mathbb{N}$ i $x \in \mathbb{N}$ oznaczamy $P + x = \{s + x : s \in P\}$.

np. dla $P = \{1, 2, 3, 6\}$ i $x = 2$: $P + x = \{3, 4, 5, 8\}$.

Dla listy L liczb naturalnych i $x \in \mathbb{N}$ przez $L + x$ oznaczamy listę powstałą z L przez dodanie x do każdego elementu.

np. $L = (3, 5, 8)$ i $x = 3$: $L + x = (6, 8, 11)$.

Lemat 4.16. *Niech $S = \{x_1, \dots, x_n\} \subseteq \mathbb{N}$. Niech $P_0 = \{0\}$ i $P_i = P_{i-1} \cup (P_{i-1} + x_i)$ dla $i \in [n]$. Zbiór P_n składa się ze wszystkich możliwych sum podzbiorów zbioru S .*

Lemat 4.16 podsuwa algorytm: wystarczy liczyć kolejne zbiory P_i . Reprezentujemy je posortowanymi listami L_i bez duplikatów, a rekurencję $P_i = P_{i-1} \cup (P_{i-1} + x_i)$ realizujemy scalaniem list. Dodatkowo z L_i usuwamy elementy $> t$ – żadna suma większa od t nie może być rozwiązaniem, więc nie wpływa to na wynik.

Założmy, że mamy procedurę $\text{MERGE}(L, L')$, która dla posortowanych list liczb naturalnych L, L' zwraca posortowaną listę elementów z L i L' i usuwa duplikaty. Złożoność czasowa $\text{MERGE}(L, L')$ wynosi $\Theta(|L| + |L'|)$.

Algorytm 18: Exact Subset Sum

```

function EXACTSUBSETSUM( $S, t$ )
1:   $n \leftarrow |S|$ 
2:   $L_0 \leftarrow (0)$ 
3:  for  $i \leftarrow 1$  to  $n$  do
4:     $L_i \leftarrow \text{MERGE}(L_{i-1}, L_{i-1} + x_i)$ 
5:    usuń z  $L_i$  wszystkie liczby  $> t$ 
6:  return największy element  $L_n$ 
    
```

Poprawność: indukcyjnie L_i to posortowana lista tych elementów P_i , które są $\leq t$. Na mocy lematu 4.16 P_n zawiera wszystkie sumy podzbiorów S , więc największy element L_n jest największą taką sumą $\leq t$ – czyli rozwiązaniem wersji optymalizacyjnej.

Złożoność czasowa Długość listy L_i może być wykładnicza względem i , nawet 2^i . Dla $I = (S, t)$:

$$|I| = \Theta\left(\log t + \sum_{i=1}^n \log x_i\right)$$

Jeśli liczby t i x_i są n -cyfrowe, to $\log t, \log x_i = \Theta(n)$ i wtedy $|I| = \Theta(n + n^2) = \Theta(n^2)$. Skoro L_n może mieć długość 2^n , to EXACTSUBSETSUM (Algorytm 18) jest algorytmem wykładniczym.

Jeśli liczba t jest ograniczona przez funkcję wielomianową od $n = |S|$, czyli $t = \mathcal{O}(n^p)$ dla jakiegoś $p \in \mathbb{N}$, to długość L_i jest ograniczona przez $\mathcal{O}(t) = \mathcal{O}(n^p)$ i w tym przypadku algorytm działa w czasie wielomianowym.

Schemat aproksymacyjny Pokażemy w pełni wielomianowy schemat aproksymacyjny dla problemu sumy podzbiorów (Problem 4.15).

Pomysł: będziemy skracać listy L_i . Dla $0 < \delta < 1$ z listy L robimy krótszą listę L' taką, że dla każdego elementu y usuniętego z L istnieje element z w L' , który jest blisko niego, dokładnie $\frac{y}{1+\delta} \leq z \leq y$.

Przykład 4.17 (Procedura Trim).

$L = (15, 16, 17, 25, 27, 28, 35, 36, 37)$, $\delta = 0,1$ (czyli próg $1 + \delta = 1,1$).

Idziemy po liście od lewej; ostatni zachowany element nazwijmy z . Kolejny y zachowujemy tylko wtedy, gdy $y > z \cdot 1,1$ – w przeciwnym razie y jest na tyle blisko z , że z go reprezentuje ($\frac{y}{1,1} \leq z \leq y$).

- 15 – pierwszy element, zachowujemy; $z = 15$.
- $16 \leq 15 \cdot 1,1 = 16,5$ – usuwamy, reprezentuje je 15.
- $17 > 16,5$ – zachowujemy; $z = 17$.
- $25 > 17 \cdot 1,1 = 18,7$ – zachowujemy; $z = 25$.
- $27 \leq 25 \cdot 1,1 = 27,5$ – usuwamy, reprezentuje je 25.
- $28 > 27,5$ – zachowujemy; $z = 28$.
- $35 > 28 \cdot 1,1 = 30,8$ – zachowujemy; $z = 35$.
- $36 \leq 35 \cdot 1,1 = 38,5$ – usuwamy, reprezentuje je 35.
- $37 \leq 38,5$ – usuwamy, reprezentuje je 35.

Stąd $L' = (15, 17, 25, 28, 35)$.

Następująca procedura $\text{TRIM}(L, \delta)$ realizuje ten pomysł.

$L = (y_1, \dots, y_m)$ – posortowana rosnąco lista, $0 < \delta < 1$.

Algorytm 19: Trim

```

function TRIM( $L, \delta$ )
1:   $m \leftarrow |L|$ 
2:   $L' \leftarrow (y_1)$ 
3:   $last \leftarrow y_1$ 
4:  for  $i \leftarrow 2$  to  $m$  do
5:    if  $y_i > last \cdot (1 + \delta)$  then
6:      dołącz  $y_i$  na koniec  $L'$ 
7:       $last \leftarrow y_i$ 
8:  return  $L'$ 

```

Czas działania $\text{TRIM}(L, \delta)$ wynosi $\Theta(|L|)$.

Oto schemat aproksymacyjny:

Algorytm 20: Approx Subset Sum

```

function APPROXSUBSETSUM( $\mathcal{S}, t, \epsilon$ )
1:   $n \leftarrow |\mathcal{S}|$ 
2:   $L_0 \leftarrow (0)$ 
3:  for  $i \leftarrow 1$  to  $n$  do
4:     $L_i \leftarrow \text{MERGE}(\mathcal{L}_{i-1}, L_{i-1} + x_i)$ 
5:    usuń z  $L_i$  liczby  $> t$ 
6:     $L_i \leftarrow \text{TRIM}(L_i, \frac{\epsilon}{2^n})$ 
7:  return największy element  $z \in L_n$ 

```

$\triangleright \delta = \frac{\epsilon}{2^n}$
 $\triangleright z^*$

Pełny przykład działania schematu wraz z dowodem poprawności i analizą złożoności przedstawimy w podrozdziale 4.6 (następny wykład). Najpierw – nieco na marginesie – pokazujemy NP-zupełność problemu sumy podzbiorów.

NP-zupełność problemu sumy podzbiorów

Twierdzenie 4.18. *Problem sumy podzbiorów (Problem 4.15) jest NP-zupełny.*

Przykład 4.19 (Redukcja 3-SAT do SUBSET-SUM).

$$C_1 = (x_1 \vee \overline{x_2} \vee \overline{x_3}), \quad C_2 = (\overline{x_1} \vee \overline{x_2} \vee \overline{x_3}),$$

$$C_3 = (\overline{x_1} \vee \overline{x_2} \vee x_3), \quad C_4 = (x_1 \vee x_2 \vee x_3).$$

$$\Phi = C_1 \wedge C_2 \wedge C_3 \wedge C_4. \quad n = 3, m = 4.$$

Wszystkie liczby są 7-cyfrowe: 3 pozycje zmiennych i 4 pozycje klauzul. Cel:

	x_1	x_2	x_3	C_1	C_2	C_3	C_4
t	1	1	1	4	4	4	4

Liczby zmiennych. Para r_i, r'_i ma 1 na pozycji x_i (więc do sumy 1 trafia dokładnie jedna z nich). Na pozycjach klauzul 1 pojawia się tam, gdzie odpowiedni literal występuje w klauzuli – np. r_1 (x_1) ma 1 w C_1 i C_4 , bo $x_1 \in C_1, C_4$.

	x_1	x_2	x_3	C_1	C_2	C_3	C_4
r_1	1	0	0	1	0	0	1
r'_1	1	0	0	0	1	1	0
r_2	0	1	0	0	0	0	1
r'_2	0	1	0	1	1	1	0
r_3	0	0	1	0	0	1	1
r'_3	0	0	1	1	1	0	0

Liczby dopełniające. Para s_j, s'_j ma niezerowe cyfry (1 i 2) tylko na pozycji C_j – służy do dobicia tej pozycji do 4.

	x_1	x_2	x_3	C_1	C_2	C_3	C_4
s_1	0	0	0	1	0	0	0
s'_1	0	0	0	2	0	0	0
s_2	0	0	0	0	1	0	0
s'_2	0	0	0	0	2	0	0
s_3	0	0	0	0	0	1	0
s'_3	0	0	0	0	0	2	0
s_4	0	0	0	0	0	0	1
s'_4	0	0	0	0	0	0	2

Pełny obraz. Weźmy spełniające wartościowanie $x_1 = 1, x_2 = 0, x_3 = 0$: bierzemy r_1 (bo $x_1 = 1$) oraz r'_2, r'_3 (bo $x_2 = x_3 = 0$), a na każdej pozycji klauzuli dobieramy s_j, s'_j tak, by uzbierać 4. Wybrane liczby (S') zaznaczono; ostatni wiersz to ich suma.

	x_1	x_2	x_3	C_1	C_2	C_3	C_4
t	1	1	1	4	4	4	4
r_1	1	0	0	1	0	0	1
r'_1	1	0	0	0	1	1	0
r_2	0	1	0	0	0	0	1
r'_2	0	1	0	1	1	1	0
r_3	0	0	1	0	0	1	1
r'_3	0	0	1	1	1	0	0
s_1	0	0	0	1	0	0	0
s'_1	0	0	0	2	0	0	0
s_2	0	0	0	0	1	0	0
s'_2	0	0	0	0	2	0	0
s_3	0	0	0	0	0	1	0
s'_3	0	0	0	0	0	2	0
s_4	0	0	0	0	0	0	1
s'_4	0	0	0	0	0	0	2
Σ	1	1	1	4	4	4	4

Suma wybranych liczb równa się t , więc $S' = \{r_1, r'_1, r'_2, s_1, s'_1, s_2, s_3, s'_3, s_4, s'_4\}$ jest rozwiązaniem.

Problem sumy podzbioru

Kontynuujemy analizę w pełni wielomianowego schematu aproksymacyjnego dla problemu sumy podzbiorów (Problem 4.15). Przypomnijmy schemat APPROXSUBSETSUM (Algorytm 20) wraz z procedurą TRIM (Algorytm 19); ustalamy $\delta = \frac{\varepsilon}{2n}$. Pokażemy najpierw przykład jego działania, a następnie dowód poprawności i analizę złożoności.

Przykład 4.20 (Aproksymacja sumy podzbioru).

$S = \{205, 203, 400, 200\}$ (w tej kolejności $x_1, \dots, x_4$), $t = 650$, $\varepsilon = 0,4$. Wtedy $n = 4$ i próg przycinania to $\delta = \frac{\varepsilon}{2n} = \frac{0,4}{8} = 0,05$ (mnożnik $1 + \delta = 1,05$). Startujemy z $L_0 = (0)$.

W każdej iteracji najpierw skalamy L_{i-1} z $L_{i-1} + x_i$, potem usuwamy elementy $> t = 650$, a na końcu przycinamy. Przy przycinaniu zachowujemy element y , gdy $y > last \cdot 1,05$, gdzie $last$ to ostatnio zachowany element.

- $i = 1$, $x_1 = 205$.
 scalenie: $(0) \cup (205) = (0, 205)$;
 po usunięciu > 650 : $(0, 205)$;
 przycinanie:
 0 zachowane, $last = 0$
 $205 > 0 \cdot 1,05 = 0$ zachowane, $last = 205$
 $L_1 = (0, 205)$.
- $i = 2$, $x_2 = 203$.
 scalenie: $(0, 205) \cup (203, 408) = (0, 203, 205, 408)$;
 po usunięciu > 650 : bez zmian;
 przycinanie:

- | | | |
|-----|--------------------------------|------------------------------|
| 0 | | <i>zachowane, last = 0</i> |
| 203 | > 0 | <i>zachowane, last = 203</i> |
| 205 | $\leq 203 \cdot 1,05 = 213,15$ | <i>usunięte</i> |
| 408 | > 213,15 | <i>zachowane, last = 408</i> |
- $L_2 = (0, 203, 408)$.
- $i = 3, x_3 = 400$.
 scalenie: $(0, 203, 408) \cup (400, 603, 808) = (0, 203, 400, 408, 603, 808)$;
 po usunięciu > 650: $(0, 203, 400, 408, 603)$;
 przycinanie:

0		<i>zachowane, last = 0</i>
203	> 0	<i>zachowane, last = 203</i>
400	> $203 \cdot 1,05 = 213,15$	<i>zachowane, last = 400</i>
408	$\leq 400 \cdot 1,05 = 420$	<i>usunięte</i>
603	> 420	<i>zachowane, last = 603</i>

 $L_3 = (0, 203, 400, 603)$.
 - $i = 4, x_4 = 200$.
 scalenie: $(0, 203, 400, 603) \cup (200, 403, 600, 803) = (0, 200, 203, 400, 403, 600, 603, 803)$;
 po usunięciu > 650: $(0, 200, 203, 400, 403, 600, 603)$;
 przycinanie:

0		<i>zachowane, last = 0</i>
200	> 0	<i>zachowane, last = 200</i>
203	$\leq 200 \cdot 1,05 = 210$	<i>usunięte</i>
400	> 210	<i>zachowane, last = 400</i>
403	$\leq 400 \cdot 1,05 = 420$	<i>usunięte</i>
600	> 420	<i>zachowane, last = 600</i>
603	$\leq 600 \cdot 1,05 = 630$	<i>usunięte</i>

 $L_4 = (0, 200, 400, 600)$.

Zwracamy największy element $z = 600$ (podzbiór $\{400, 200\}$). Optimum to $z^* = 608$ (podzbiór $\{205, 203, 200\}$). Iloraz $\frac{z^*}{z} = \frac{608}{600} \approx 1,013 \leq 1 + \varepsilon = 1,4$ – zgodnie z gwarancją.

Przykład 4.21 (Aproksymacja sumy podzbioru).

$S = \{104, 102, 201, 101\}$ (w tej kolejności $x_1, \dots, x_4$), $t = 308$, $\varepsilon = 0,4$. Wtedy $n = 4$ i próg przycinania to $\delta = \frac{\varepsilon}{2n} = \frac{0,4}{8} = 0,05$ (czyli mnożnik $1 + \delta = 1,05$). Startujemy z $L_0 = (0)$.

W każdej iteracji najpierw scalamy L_{i-1} z $L_{i-1} + x_i$, potem usuwamy elementy $> t = 308$, a na końcu przycinamy. Przy przycinaniu zachowujemy element y , gdy $y > last \cdot 1,05$, gdzie $last$ to ostatnio zachowany element.

- $i = 1, x_1 = 104$.
 scalenie: $(0) \cup (104) = (0, 104)$;
 po usunięciu > 308: $(0, 104)$;
 przycinanie:

0		<i>zachowane, last = 0</i>
104	> $0 \cdot 1,05 = 0$	<i>zachowane, last = 104</i>

 $L_1 = (0, 104)$.
- $i = 2, x_2 = 102$.
 scalenie: $(0, 104) \cup (102, 206) = (0, 102, 104, 206)$;
 po usunięciu > 308: bez zmian;
 przycinanie:

- | | | |
|-----|-------------------------------|------------------------------|
| 0 | | <i>zachowane, last = 0</i> |
| 102 | > 0 | <i>zachowane, last = 102</i> |
| 104 | $\leq 102 \cdot 1,05 = 107,1$ | <i>usunięte</i> |
| 206 | > 107,1 | <i>zachowane, last = 206</i> |
- $L_2 = (0, 102, 206)$.
- $i = 3, x_3 = 201$.
 scalenie: $(0, 102, 206) \cup (201, 303, 407) = (0, 102, 201, 206, 303, 407)$;
 po usunięciu > 308 : $(0, 102, 201, 206, 303)$;
 przycinanie:

0		<i>zachowane, last = 0</i>
102	> 0	<i>zachowane, last = 102</i>
201	> $102 \cdot 1,05 = 107,1$	<i>zachowane, last = 201</i>
206	$\leq 201 \cdot 1,05 = 211,05$	<i>usunięte</i>
303	> 211,05	<i>zachowane, last = 303</i>

 $L_3 = (0, 102, 201, 303)$.
 - $i = 4, x_4 = 101$.
 scalenie: $(0, 102, 201, 303) \cup (101, 203, 302, 404) = (0, 101, 102, 201, 203, 302, 303, 404)$;
 po usunięciu > 308 : $(0, 101, 102, 201, 203, 302, 303)$;
 przycinanie:

0		<i>zachowane, last = 0</i>
101	> 0	<i>zachowane, last = 101</i>
102	$\leq 101 \cdot 1,05 = 106,05$	<i>usunięte</i>
201	> 106,05	<i>zachowane, last = 201</i>
203	$\leq 201 \cdot 1,05 = 211,05$	<i>usunięte</i>
302	> 211,05	<i>zachowane, last = 302</i>
303	$\leq 302 \cdot 1,05 = 317,1$	<i>usunięte</i>

 $L_4 = (0, 101, 201, 302)$.

Zwracamy największy element $z = 302$ (podzbiór $\{201, 101\}$). Optimum to $z^* = 307$ (podzbiór $\{104, 102, 101\}$), wycięte przez przycinanie w iteracji $i = 4$. Iloraz $\frac{z^*}{z} = \frac{307}{302} \approx 1,017 \leq 1 + \varepsilon = 1,4$ – zgodnie z gwarancją.

Twierdzenie 4.22. *Algorytm APPROXSUBSETSUM jest w pełni wielomianowym schematem aproksymacyjnym dla problemu sumy podzbioru.*

Pokażemy, że algorytm działa w czasie wielomianowym względem $|I| = \Theta(\log t + \sum_{i=1}^n \log x_i)$ i $\frac{1}{\varepsilon}$.

Na każdej liście L_i po linii 6 elementy $z_0 = 0, z_1, \dots, z_k$ spełniają warunek $z_{j+1} > z_j \left(1 + \frac{\varepsilon}{2n}\right)$ dla $j \geq 1$. Ile różnych liczb naturalnych $z_1, \dots, z_k$ spełniających ten warunek może się tu zmieścić w przedziale $[1, t]$?

Przez indukcję po i mamy, że $z_{i+1} > z_1 \left(1 + \frac{\varepsilon}{2n}\right)^i$ dla $1 \leq i \leq k-1$. Zatem

$$z_1 \left(1 + \frac{\varepsilon}{2n}\right)^{k-1} < z_k \leq t$$

Skoro $z_1 \geq 1$, to

$$\left(1 + \frac{\varepsilon}{2n}\right)^{k-1} \leq t \quad \left| \ln \right.$$

$$(k-1) \ln \left(1 + \frac{\epsilon}{2n}\right) \leq \ln t$$

$$k-1 \leq \frac{\ln t}{\ln \left(1 + \frac{\epsilon}{2n}\right)} \Big| + 2$$

$$\begin{aligned} k+1 &\leq \frac{\ln t}{\ln \left(1 + \frac{\epsilon}{2n}\right)} + 2 \stackrel{\text{Fakt ??}}{\leq} \frac{\ln t \cdot \left(1 + \frac{\epsilon}{2n}\right)}{\frac{\epsilon}{2n}} + 2 \\ &= \frac{2n + \epsilon}{2n} \cdot \frac{2n}{\epsilon} \ln t + 2 \leq \frac{3n \ln t}{\epsilon} + 2 \end{aligned}$$

Skoro długość L_i po linii 6 wynosi $k+1 \leq \frac{3n \ln t}{\epsilon} + 2$, a po $(i+1)$ -szej linii 4 może być co najwyżej 2 razy dłuższa i $|I| = \Omega(\ln t + n)$, to złożoność czasowa algorytmu jest wielomianowa względem $|I|$ i $\frac{1}{\epsilon}$.

Skojarzenia w grafach

Najliczniejsze skojarzenie w grafach dwudzielnych $G = (V, E)$ – graf.

G jest dwudzielny jeśli istnieje podział V na dwa niepuste podzbiory V_1, V_2 takie, że dla każdej krawędzi $e = v_1 v_2 \in E$ mamy $v_1 \in V_1$ i $v_2 \in V_2$. Oznaczamy to jako $G = (V_1, V_2, E)$.

Skojarzenie w G to zbiór parami rozłącznych krawędzi.


Skojarzenie jest najliczniejsze jeśli ma największą liczbę.

Problem 5.1 (najliczniejszego skojarzenia w grafie dwudzielnym).

Instancja: graf dwudzielny $G = (V_1, V_2; E)$.

Znaleźć: najliczniejsze skojarzenie w G .

Przykład 5.2.




Przykładowe skojarzenie: $\{ae, df, bc\}$

Jeśli M jest skojarzeniem, to każdy wierzchołek należy do co najwyżej jednej krawędzi z M .


Niech M będzie ustalonym skojarzeniem w G .

- wierzchołek jest skojarzony jeśli należy do jakiejś krawędzi z M (mówimy też, że M pokrywa ten wierzchołek),
- wierzchołek jest wolny jeśli nie jest skojarzony,
- krawędź jest skojarzona jeśli należy do M ,
- krawędź jest wolna jeśli nie należy do M .

Ścieżka powiększająca (względem M) to naprzemienna ścieżka składająca się z wolnych i skojarzonych krawędzi o wolnych końcach.



$$M' = M \div E(P) = (M - E(P)) \cup (E(P) - M)$$



Możemy użyć ścieżki powiększającej i różnicy symetrycznej do zwiększenia liczności skojarzenia.

Twierdzenie 5.3 (Berge'a).

Niech $G = (V, E)$ – graf, M – skojarzenie w G .

M jest najliczniejszym skojarzeniem w $G \iff$ nie istnieje ścieżka powiększająca względem M .

Dowód.

$\implies$ Przypuśćmy, że istnieje ścieżka powiększająca P względem M .

Wtedy $M' = M \div E(P)$ jest skojarzeniem i $|M'| > |M|$, więc M nie jest skojarzeniem najliczniejszym.

$\impliedby$ Przypuśćmy, że M nie jest najliczniejszym skojarzeniem w G .

Niech M' będzie skojarzeniem takim, że $|M'| > |M|$.

Niech H będzie podgrafem G indukowanym przez $M' \div M$, czyli $H = (V(G), M' \div M)$.

M, M' to skojarzenia, więc stopień wierzchołka $d_H(v) \leq 2$ dla każdego $v \in V(G)$.

Każda składowa H jest ścieżką lub cyklem.

M, M' to skojarzenia, więc nie ma cykli nieparzystych w H .

Każda składowa H jest ścieżką lub cyklem parzystym.

Skoro $|M'| > |M|$, to istnieje składowa H , która jest ścieżką zawierającą więcej krawędzi z M' niż z M , więc ta ścieżka zaczyna się i kończy krawędzią z M' . Ta ścieżka jest ścieżką powiększającą względem M . $\square$

Przedstawimy teraz algorytm znajdujący najliczniejsze skojarzenie w grafie dwudzielnym (Problem 5.1).

Niech M będzie skojarzeniem w G .

Definiujemy graf skierowany $G_M = (V_1 \cup V_2, E_M)$, gdzie

$$E_M = \{(u, v) : uv \in E - M, u \in V_1, v \in V_2\} \cup \{(v, u) : uv \in M, u \in V_1, v \in V_2\}.$$

Innymi słowy, krawędzie wolne kierujemy z V_1 do V_2 , a krawędzie skojarzone z V_2 do V_1 .

Przykład 5.4.



Procedura do znajdowania ścieżki powiększającej — *Augmenting Path Search* (APS).

Algorytm 21: Augmenting Path Search

function APS(G, M) 1: $V'_1 \leftarrow$ zbiór wierzchołków wolnych z V_1 2: $V'_2 \leftarrow$ zbiór wierzchołków wolnych z V_2 3: skonstruuj graf skierowany $G_M = (V_1 \cup V_2, E_M)$ 4: znajdź ścieżkę $\vec{P}$ z V'_1 do V'_2 w G_M 5: if $\vec{P}$ istnieje then 6: return P 7: else 8: return NULL	$\triangleright G = (V_1, V_2; E), M$ – skojarzenie w G $\triangleright P$ – nieskierowana $\vec{P}$
--	---

Lemat 5.5. Procedura APS zwraca ścieżkę $P \iff$ istnieje ścieżka powiększająca względem M w G . Ponadto ścieżka P zwrócona przez APS jest ścieżką powiększającą względem M .

Algorytm znajdowania najliczniejszego skojarzenia — *Maximum Matching* (MM).

Algorytm 22: Maximum Matching

function MM(G) 1: $M \leftarrow \emptyset$ 2: repeat 3: $P \leftarrow$ APS(G, M) 4: if $P \neq \text{NULL}$ then 5: $M \leftarrow M \div E(P)$ 6: until $P = \text{NULL}$ 7: return M	$\triangleright G = (V_1, V_2; E)$
--	------------------------------------

Poprawność Wynika z twierdzenia Berge’a.

Złożoność czasowa Złożoność czasowa APS:

- Linie 1, 2: $\mathcal{O}(|V|)$.
- Linia 3: $\mathcal{O}(|E|)$.
- Linia 4: $\mathcal{O}(|E|)$ (używamy algorytmu BFS).
- Linie 5–8: $\mathcal{O}(|V|)$.

Złożoność APS wynosi zatem $\mathcal{O}(|E|)$.


Złożoność czasowa MM:

- Linia 1: $\mathcal{O}(1)$.
- Pętla 2–6 wykona się co najwyżej $\frac{|V|}{2}$ razy, bo w każdej iteracji $|M|$ zwiększa się o 1, a maksymalna liczność skojarzenia jest $\leq \frac{|V|}{2}$.
- Wnętrze pętli:
 - Linia 3: $\mathcal{O}(|E|)$.
 - Linia 5: $\mathcal{O}(|V|)$.
Razem $\mathcal{O}(|E|)$.
- Linia 7: $\mathcal{O}(|V|)$.


Ostateczna złożoność MM wynosi $\mathcal{O}(|V| \cdot |E|)$.

Przykład 5.6 (Działanie algorytmu Maximum Matching).


Prześledźmy działanie algorytmu MM na poniższym grafie G . W każdej iteracji po lewej G_M ze ścieżką powiększającą (na różowo, różowy pierścień to wierzchołek startowy), po prawej graf G z bieżącym skojarzeniem M (wyróżnionym).




Iteracja 1:




Iteracja 2:



Iteracja 3:



Iteracja 4:



Iteracja 5:

