

Algorytmy Zaawansowane

Opracowane na podstawie wykładów Michała Tuczyńskiego

Spis treści

1	Dziel i zwyciężaj	2
1.1	Notacja asymptotyczna — przypomnienie	2
1.2	Strategia typu <i>Dziel i Zwyciężaj</i> (<i>Divide and Conquer</i>)	3
1.3	Algorytm Strasiera	6
1.4	Własność optymalnej podstruktury	7
1.5	Znajdywanie pary najbliższych punktów	7
2	Programowanie dynamiczne	10
2.1	Algorytm mnożenia macierzy	12
2.2	Problem mnożenia ciągu macierzy	12
2.3	Problem najdłuższego wspólnego podciągu	18
3	Algorytmy zachłanne	21
3.1	Kody Huffmana	24
3.2	Algorytm Huffmana	26
3.3	Dowód optymalności algorytmu Huffmana	29
3.4	Szeregowanie zadań	31
3.5	Matroidy	33
3.6	Problem szeregowania zadań	35
4	Algorytmy aproksymacyjne	37
4.1	Problem pokrycia wierzchołkowego	38
4.2	Problem pokrycia zbioru	39
4.3	Schematy aproksymacyjne	42
4.4	Problem sumy podzbiorów	43
4.5	NP-zupełność problemu sumy podzbiorów	45
4.6	Problem sumy podzbioru	46
5	Skojarzenia w grafach	49

Dziel i zwyciężaj

Notacja asymptotyczna — przypomnienie

$$f, g : \mathbb{N} \rightarrow \mathbb{R}_+$$

$$g(n) = \mathcal{O}(f(n)) \Leftrightarrow \exists_{c \in \mathbb{R}_+} \exists_{n_0 \in \mathbb{N}_+} \forall_{n > n_0} g(n) \leq c \cdot f(n)$$

$$g(n) = \Omega(f(n)) \Leftrightarrow \exists_{c \in \mathbb{R}_+} \exists_{n_0 \in \mathbb{N}_+} \forall_{n > n_0} c \cdot f(n) \leq g(n)$$

$$g(n) = \Theta(f(n)) \Leftrightarrow \exists_{c_1, c_2 \in \mathbb{R}_+} \exists_{n_0 \in \mathbb{N}_+} \forall_{n > n_0} c_1 \cdot f(n) \leq g(n) \leq c_2 \cdot f(n)$$

$$g(n) = \mathcal{O}(f(n)) \Leftrightarrow f(n) = \Omega(g(n))$$

$$g(n) = \Theta(f(n)) \Leftrightarrow (g(n) = \mathcal{O}(f(n)) \wedge g(n) = \Omega(f(n)))$$

$$n^a = \mathcal{O}(n^b) \text{ gdy } 0 < a \leq b$$

$$\log n = \mathcal{O}(n^\epsilon) \text{ gdy } \epsilon > 0$$

$$n^a = \mathcal{O}(b^n) \text{ gdy } 1 < a \leq b$$

$$\log_a n = \Theta(\log_b n) \text{ gdy } a, b > 1$$

$$n^a = \mathcal{O}(b^n) \text{ gdy } 0 < a, b > 1$$

$$T(n) = 5n^3 + 2n^2 + 100n \log n \underset{n \rightarrow \infty}{\approx} 5n^3 = \Theta(n^3)$$

Procedura rekurencyjna

$$n! = \begin{cases} 1 & \text{gdy } n = 0 \\ n \cdot (n-1)! & \text{gdy } n \geq 1 \end{cases}$$

$$\text{Oczywiste jest, że } n! = \prod_{i=1}^n i$$

Ciąg Fibonacciego F_n - ciąg Fibonacciego.

$$F_n = \begin{cases} 0 & \text{gdy } n = 0 \\ 1 & \text{gdy } n = 1 \\ F_{n-1} + F_{n-2} & \text{gdy } n \geq 2 \end{cases}$$

Algorytm 1: Rekurencyjna konstrukcja ciągu Fibonacciego

```
function FIBB(n)
1:  if n = 0 then return 0
2:  if n = 1 then return 1
3:  return FIBB(n-1) + FIBB(n-2)
```

Wywołanie rekurencyjne dla (typowo łatwiejszych i mniejszych) instancji tego samego problemu.

Strategia typu *Dziel i Zwyciężaj* (Divide and Conquer)

Algorytm typu *dziel i zwyciężaj* składa się z trzech części

1. *Dziel* – problem jest dzielony na mniejsze podproblemy
2. *Zwyciężaj* – podproblemy są rozwiązywane rekurencyjnie
3. *Połącz* – rozwiązanie całego problemu jest konstruowane z rozwiązań podproblemów

Zakładamy, że (zazwyczaj) w fazie *dziel* problem jest dzielony na co najmniej dwa podproblemy i podproblemy są rozłączne.

Przykład 1.1 (Mnożenie liczb n -cyfrowych).

x, y – liczby naturalne n -cyfrowe.

Aby policzyć $x \cdot y$ można użyć mnożenia pisemnego (jak na kartce). Tym sposobem musimy wykonać $\mathcal{O}(n^2)$ mnożeń cyfr. Spróbujemy znaleźć lepszą metodę. Dzielimy x i y na „dwie połowy”. Zakładamy, dla uproszczenia, że n jest parzyste.

$$x = x_1 x_2 \cdots x_n = \underbrace{x_1 x_2 \cdots x_{n/2}}_{x_L} \underbrace{x_{n/2+1} \cdots x_n}_{x_R} = 10^{n/2} x_L + x_R$$

podobnie dla y :

$$y = \cdots = 10^{n/2} y_L + y_R$$

Wymnażamy:

$$x \cdot y = (10^{n/2} x_L + x_R) \cdot (10^{n/2} y_L + y_R) = 10^n x_L y_L + 10^{n/2} (x_L y_R + x_R y_L) + x_R y_R$$

Złożoność czasowa algorytmu – ozn. $T(n)$.

- Podział x, y na x_L, x_R, y_L, y_R zajmie $\mathcal{O}(n)$ czasu.
- Dodanie liczb n -cyfrowych zajmie $\mathcal{O}(n)$ czasu.
- Mnożenie przez 10^n jest równoważne dopisaniu n zer więc też $\mathcal{O}(n)$.

$$T(n) = 4 \cdot T(n/2) + \Theta(n)$$

Można lepiej, bo możemy zauważyć, że $x_L y_R + x_R y_L = (x_L - x_R) \cdot (y_R - y_L) + x_L y_L + x_R y_R$, więc potrzebujemy policzyć tylko 3 iloczyny: $x_L y_L, x_R y_R, (x_L - x_R) \cdot (y_R - y_L)$. To daje $T(n) = 3 \cdot T\left(\frac{n}{2}\right) + \Theta(n)$

Twierdzenie 1.2 (CLRS - Uniwersalne Twierdzenie o Rekurencji).

Niech $a \geq 1, b > 1$ będą stałymi, $f(n)$ funkcją i $T(n) = a \cdot T\left(\frac{n}{b}\right) + f(n)$ (gdzie $\frac{n}{b}$ znaczy $\left\lfloor \frac{n}{b} \right\rfloor$ lub $\left\lceil \frac{n}{b} \right\rceil$). Wtedy

$$T(n) = \begin{cases} \Theta(n^{\log_b a}) & \text{gdy } f(n) = \mathcal{O}(n^{\log_b a - \epsilon}) \text{ dla pewnego } \epsilon > 0 \\ \Theta(n^{\log_b a} \log n) & \text{gdy } f(n) = \Theta(n^{\log_b a}) \\ \Theta(f(n)) & \text{gdy } \begin{matrix} f(n) = \Omega(n^{\log_b a + \epsilon}) \text{ dla pewnego } \epsilon > 0 \\ \text{a } f(n/b) \leq c \cdot f(n) \text{ dla pewnej stałej } c < 1 \text{ dla dużych } n \end{matrix} \end{cases}$$

Lemat 1.3. Niech $a \geq 1$, $b > 1$ będą stałymi i niech $f(n)$ będzie nieujemną funkcją zdefiniowaną dla potęg b . Jeśli

$$T(n) = \begin{cases} \Theta(1) & \text{gdy } n = 1 \\ a \cdot T\left(\frac{n}{b}\right) + f(n) & \text{gdy } n = b^i, i \geq 1 \end{cases}$$

to

$$T(n) = \Theta\left(n^{\log_b a}\right) + \sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right)$$

Dowód.

$$a^{\log_b n} = \left(b^{\log_b a}\right)^{\log_b n} = b^{\log_b a \cdot \log_b n} = b^{\log_b n \cdot \log_b a} = \left(b^{\log_b n}\right)^{\log_b a} = n^{\log_b a} \quad (1)$$

$$\begin{aligned} T(n) &= f(n) + a \cdot T\left(\frac{n}{b}\right) = f(n) + a \left(f\left(\frac{n}{b}\right) + aT\left(\frac{n}{b^2}\right) \right) \\ &= f(n) + af\left(\frac{n}{b}\right) + a^2 T\left(\frac{n}{b^2}\right) = f(n) + af\left(\frac{n}{b}\right) + a^2 \left(f\left(\frac{n}{b^2}\right) + aT\left(\frac{n}{b^3}\right) \right) \\ &= f(n) + af\left(\frac{n}{b}\right) + a^2 f\left(\frac{n}{b^2}\right) + \dots + a^{\log_b n - 1} f\left(\frac{n}{b^{\log_b n}}\right) + a^{\log_b n} T(1) \\ &\stackrel{1}{=} \dots + a^{\log_b n} T(1) = \dots + n^{\log_b a} T(1) = \Theta\left(n^{\log_b a}\right) + \sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right) \end{aligned}$$

□

Przeprowadzimy teraz dowód uniwersalnego twierdzenia o rekurencji (1.2). Ograniczymy się do przypadku, gdy n jest potęgą b . Pozostały przypadek jest bardziej techniczny.

Dowód. Rozważmy wszystkie przypadki:

1. Gdy $f(n) = \mathcal{O}\left(n^{\log_b a - \epsilon}\right)$. Wtedy

$$\begin{aligned} f\left(\frac{n}{b^j}\right) &= \mathcal{O}\left(\left(\frac{n}{b^j}\right)^{\log_b a - \epsilon}\right) \\ \sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right) &= \sum_{j=0}^{\log_b n - 1} a^j \mathcal{O}\left(\left(\frac{n}{b^j}\right)^{\log_b a - \epsilon}\right) = \mathcal{O}\left(\underbrace{\sum_{j=0}^{\log_b n - 1} a^j \left(\frac{n}{b^j}\right)^{\log_b a - \epsilon}}_{\blacktriangle}\right) \\ \blacktriangle &= \sum_{j=0}^{\log_b n - 1} a^j \frac{n^{\log_b a - \epsilon}}{b^{j(\log_b a - \epsilon)}} = n^{\log_b a - \epsilon} \sum_{j=0}^{\log_b n - 1} a^j \frac{b^{j\epsilon}}{b^{j \log_b a}} \\ &= n^{\log_b a - \epsilon} \sum_{j=0}^{\log_b n - 1} \left(\frac{a \cdot b^\epsilon}{\underbrace{b^{\log_b a}}_{=a}}\right)^j = n^{\log_b a - \epsilon} \sum_{j=0}^{\log_b n - 1} b^{\epsilon j} \quad (\text{wzór na ciąg geometryczny}) \end{aligned}$$

$$\begin{aligned}
&= n^{\log_b a - \epsilon} \frac{b^{\epsilon \log_b n} - 1}{b^\epsilon - 1} = n^{\log_b a - \epsilon} \underbrace{\frac{n^\epsilon - 1}{b^\epsilon - 1}}_{\text{stała}} \\
&= n^{\log_b a - \epsilon} \mathcal{O}(n^\epsilon - 1) = \mathcal{O}(n^{\log_b a - \epsilon} \cdot n^\epsilon - 1) = \mathcal{O}(n^{\log_b a})
\end{aligned}$$

Z lematu: $T(n) = \sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right) + \Theta(n^{\log_b a}) = \mathcal{O}(n^{\log_b a}) + \Theta(n^{\log_b a}) = \Theta(n^{\log_b a})$

2. Gdy $f(n) = \Theta(n^{\log_b a})$. Wtedy:

$$\begin{aligned}
f\left(\frac{n}{b^j}\right) &= \Theta\left(\left(\frac{n}{b^j}\right)^{\log_b a}\right) \\
\sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right) &= \sum_{j=0}^{\log_b n - 1} a^j \Theta\left(\left(\frac{n}{b^j}\right)^{\log_b a}\right) = \Theta\left(\sum_{j=0}^{\log_b n - 1} a^j \left(\frac{n}{b^j}\right)^{\log_b a}\right) \\
&= \Theta\left(n^{\log_b a} \sum_{j=0}^{\log_b n - 1} a^j \frac{1}{b^{j \log_b a}}\right) = \Theta\left(n^{\log_b a} \sum_{j=0}^{\log_b n - 1} a^j \underbrace{\frac{1}{b^{\log_b a^j}}}_{=a^j}\right) \\
&= \Theta\left(n^{\log_b a} \sum_{j=0}^{\log_b n - 1} 1\right) = \Theta(n^{\log_b a} \log_b n)
\end{aligned}$$

Z lematu: $T(n) = \sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right) + \Theta(n^{\log_b a}) = \mathcal{O}(n^{\log_b a} \log n) + \Theta(n^{\log_b a}) = \Theta(n^{\log_b a} \log n)$

3. Gdy $f(n) = \Omega(n^{\log_b a + \epsilon})$ oraz $a \cdot f\left(\frac{n}{b}\right) \leq c \cdot f(n)$ dla jakiegoś $c < 1$ i odpowiednio dużych n .

Z założenia $f\left(\frac{n}{b}\right) \leq \frac{c}{a} f(n)$, więc drogą iteracji:

$$\begin{aligned}
f\left(\frac{n}{b^j}\right) &\stackrel{(\star)}{\leq} \left(\frac{c}{a}\right)^j f(n) = \frac{c^j}{a^j} f(n) \\
(\star) \quad f\left(\frac{n}{b^j}\right) &\leq \frac{c}{a} f\left(\frac{n}{b^{j-1}}\right) \leq \left(\frac{c}{a}\right)^2 f\left(\frac{n}{b^{j-2}}\right) \leq \dots \leq \left(\frac{c}{a}\right)^j f(n) \\
\sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right) &\leq \sum_{j=0}^{\log_b n - 1} \cancel{a^j} \frac{c^j}{\cancel{a^j}} f(n) + \mathcal{O}(1) \leq f(n) \sum_{j=0}^{\log_b n - 1} c^j + \mathcal{O}(1) \\
&\leq f(n) \sum_{j=0}^{\infty} c^j + \mathcal{O}(1) \leq f(n) \frac{1}{1-c} + \mathcal{O}(1) \leq f(n) \mathcal{O}(1) = \mathcal{O}(f(n))
\end{aligned}$$

Z drugiej strony: $\sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right) = a^0 f\left(\frac{n}{b^0}\right) + \underbrace{\sum_{j=1}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right)}_{\geq 0} = \Omega(f(n))$

Z lematu: $T(n) = \sum_{j=0}^{\log_b n - 1} a^j f\left(\frac{n}{b^j}\right) + \Theta(n^{\log_b a}) = \Theta(f(n)) + \Theta(n^{\log_b a}) = \Theta(f(n))$

□

Wniosek 1.4. Niech $a \geq 1$, $b > 1$ będą stałymi, a $f(n)$ funkcją taką, że $f(n) = \Theta(n^k)$. Niech $T(n) = a \cdot T\left(\frac{n}{b}\right) + f(n)$ (gdzie $\frac{n}{b}$ znaczy $\left\lfloor \frac{n}{b} \right\rfloor$ lub $\left\lceil \frac{n}{b} \right\rceil$). Wtedy

$$T(n) = \begin{cases} \Theta(n^{\log_b a}) & \text{gdzie } f(n) = \mathcal{O}(n^{\log_b a - \epsilon}) \implies k < \log_b a \iff b^k < a \\ \Theta(n^k \log n) & \text{gdzie } f(n) = \Theta(n^{\log_b a}) \implies k = \log_b a \iff b^k = a \\ \Theta(n^k) & \text{gdzie } f(n) = \Omega(n^{\log_b a + \epsilon}) \implies k > \log_b a \iff b^k > a \end{cases}$$

Wróćmy teraz do naszego problemu mnożenia liczb n -cyfrowych. Drugi algorytm ma złożoność:

$$T(n) = 4 \cdot T\left(\frac{n}{2}\right) + \Theta(n^1) \quad a = 4, b = 2, k = 1$$

$$4 > 2^1 \Rightarrow T(n) = \Theta(n^{\log_2 4}) = \Theta(n^2)$$

Trzeci algorytm ma złożoność:

$$T(n) = 3 \cdot T\left(\frac{n}{2}\right) + \Theta(n^1) \quad a = 3, b = 2, k = 1$$

$$3 > 2^1 \Rightarrow T(n) = \Theta(n^{\log_2 3}) = \Theta(n^{1.59})$$

Przykład 1.5 (Mnożenie macierzy).

A, B - macierze $n \times n$

$$A \cdot B = C = ?$$

Najpopularniejszy sposób mnożenia dwóch macierzy $n \times n$ działa w czasie $\mathcal{O}(n^3)$. Musimy obliczyć n^2 wartości i obliczenie każdej zajmuje liniowy czas.

$$B = \begin{bmatrix} \vdots \end{bmatrix} \quad A = \begin{bmatrix} \cdots \end{bmatrix} \quad \begin{bmatrix} \vdots \\ \times \end{bmatrix} = C$$

Algorytm Strasiera

Zakładamy, że n jest potęgą 2 (dla przejrzystości). Dzielimy A i B na 4 macierze $\frac{n}{2} \times \frac{n}{2}$:

$$A = \left[\begin{array}{c|c} A_{11} & A_{12} \\ \hline A_{21} & A_{22} \end{array} \right], \quad B = \left[\begin{array}{c|c} B_{11} & B_{12} \\ \hline B_{21} & B_{22} \end{array} \right]$$

$$A \cdot B = \left[\begin{array}{c|c} A_{11} & A_{12} \\ \hline A_{21} & A_{22} \end{array} \right] \cdot \left[\begin{array}{c|c} B_{11} & B_{12} \\ \hline B_{21} & B_{22} \end{array} \right] = \left[\begin{array}{c|c} C_{11} & C_{12} \\ \hline C_{21} & C_{22} \end{array} \right]$$

$$C_{11} = A_{11}B_{11} + A_{12}B_{21}$$

$$C_{12} = A_{11}B_{12} + A_{12}B_{22}$$

$$C_{21} = A_{21}B_{11} + A_{22}B_{21}$$

$$C_{22} = A_{21}B_{12} + A_{22}B_{22}$$

Zamieniliśmy 1 mnożenie macierzy $n \times n$ na 8 mnożeń macierzy $\frac{n}{2} \times \frac{n}{2}$ + podział i dodawanie ($\mathcal{O}(n^2)$). Stąd mamy zależność rekurencyjną:

$$T(n) = 8 \cdot T\left(\frac{n}{2}\right) + \Theta(n^2) \quad a = 8, b = 2, k = 2$$

$$8 > 2^2 \Rightarrow T(n) = \Theta(n^{\log_2 8}) = \Theta(n^3)$$

Strassen zauważył, że jeśli obliczymy

$$M_1 = (A_{12} - A_{22}) \cdot (B_{21} + B_{22})$$

$$M_2 = (A_{11} + A_{22}) \cdot (B_{11} + B_{22})$$

$$M_3 = (A_{11} - A_{21}) \cdot (B_{11} + B_{12})$$

$$M_4 = (A_{11} + A_{12}) \cdot B_{22}$$

$$M_5 = A_{11} \cdot (B_{12} - B_{22})$$

$$M_6 = A_{22} \cdot (B_{21} - B_{11})$$

$$M_7 = (A_{21} + A_{22}) \cdot B_{11}$$

$$\text{to } C_{11} = M_1 + M_2 - M_4 + M_6$$

$$C_{12} = M_4 + M_5$$

$$C_{21} = M_6 + M_7$$

$$C_{22} = M_2 - M_3 + M_5 - M_7$$

Zatem

$$T(n) = 7 \cdot T\left(\frac{n}{2}\right) + \Theta(n^2)$$

$$a = 7, \quad b = 2, \quad k = 2$$

$$7 > 2^2 \Rightarrow T(n) = \Theta(n^{\log_2 7}) = \Theta(n^{2.81})$$

Własność optymalnej podstruktury

Optymalne rozwiązanie problemu jest funkcją optymalnych rozwiązań podproblemów (optymalne rozwiązanie można skonstruować z optymalnych rozwiązań podproblemów). Żeby metoda *dziel i zwyciężaj* działała dobrze muszą być spełnione dwa warunki (przez problem i algorytm):

1. własność optymalnej podstruktury
2. podproblemy są rozłączne

Znajdywanie pary najbliższych punktów

$\mathcal{Q}$ - zbiór $n \geq 2$ punktów na płaszczyźnie

$$p_1 = (x_1, y_1) \quad p_2 = (x_2, y_2) \quad d(p_1, p_2) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

Problem: znaleźć parę punktów w najmniejszej odległości. Algorytm siłowy (*brute force*), który sprawdza wszystkie pary punktów działa w czasie $\Theta(n^2)$, bo mamy $\binom{n}{2} = \frac{n(n-1)}{2} = \Theta(n^2)$ par punktów. Pokażemy algorytm typu *dziel i zwyciężaj*, który działa w czasie $\mathcal{O}(n \log n)$.


W każdym wywołaniu rekurencyjnym wejście składa się z 3 rzeczy: zbioru $P \subset \mathcal{Q}$ i dwóch tablic X i Y które zawierają wszystkie punkty z P . W tablicy X punkty są posortowane w porządku niemalejącym względem pierwszej współrzędnej, a w tablicy Y po drugiej współrzędnej.

Opis algorytmu:

jeśli $|P| \leq 3$ sprawdzamy wszystkie pary

jeśli $|P| > 3$

Dziel: Dzielimy punkty P pionową prostą l na dwa podzbiory P_L i P_R na lewo i na prawo od l tak, że $|P_L| = \left\lceil \frac{P}{2} \right\rceil$, $|P_R| = \left\lfloor \frac{P}{2} \right\rfloor$. Dzielimy tablicę X na X_L i X_R zawierające punkty odpowiednio P_L i P_R posortowane w porządku niemalejącym względem pierwszej współrzędnej. Podobnie dzielimy Y na Y_L i Y_R zawierające odpowiednio punkty z P_L i P_R posortowane w porządku niemalejącym po drugiej współrzędnej.



Rysunek 1: Podział zbioru P pionową prostą l na podzbiory P_L (na lewo) i P_R (na prawo) o rozmiarach $|P_L| = \left\lfloor \frac{P}{2} \right\rfloor$ oraz $|P_R| = \left\lfloor \frac{P}{2} \right\rfloor$.

Zwycięzaj: Wywołujemy rekurencyjnie algorytm dla wejścia P_L, X_L, Y_L i P_R, X_R, Y_R . Algorytm znajduje pary najbliższych punktów w P_L i P_R . Niech δ_L i δ_R będą najmniejszymi odległościami znalezionymi przez algorytm dla odpowiednio P_L i P_R . Niech δ będzie mniejszą z nich: $\delta = \min(\delta_L, \delta_R)$.

Połącz: Para najbliższych punktów z P składa się z dwóch punktów z P_L lub z dwóch punktów z P_R lub jednego punktu z P_L i jednego z P_R .

Musimy sprawdzić czy istnieje para 3-go typu w odległości mniejszej niż δ . Jeśli taka para istnieje, wtedy jej punkty są w pionowym pasie o szerokości 2δ wokół l .


W celu sprawdzenia czy taka para istnieje wykonujemy następujące czynności:

1. Tworzymy tablicę Y' otrzymaną z Y poprzez usunięcie punktów spoza pasa. Y' jest posortowany w porządku niemalejącym względem drugiej współrzędnej.
2. Dla każdego punktu p z Y' sprawdzamy odległość między p , a p' dla 7 kolejnych punktów p' z Y' . Algorytm oblicza najmniejszą odległość δ' i zapamiętuje ją i odpowiednią parę punktów.
3. Jeśli $\delta' < \delta$ to pionowy pas zawiera parę punktów w mniejszej odległości niż pary znalezione w wywołaniach rekurencyjnych. Algorytm zwraca δ' i odpowiednią parę punktów. Wpp. zwraca δ i odpowiednią parę punktów.


Dowód poprawności. Jedyną rzeczą, która nie jest oczywista jest fakt, że sprawdzamy tylko 7 następnych punktów po p w Y' w fazie łącz. Przypuśćmy, że p, q są parą punktów w najmniejszej odległości w P i $\delta(p, q) = \delta'$. Niech $p = (x_p, y_p)$, $q = (x_q, y_q)$. Bez straty ogólności załóżmy $y_p \leq y_q$. Pokażemy, że algorytm znajdzie tę parę punktów. Przypuśćmy, że nie. Wtedy istnieje co najmniej 7 punktów pomiędzy p i q w Y' . Niech $r = (x_r, y_r)$ będzie jednym z nich. Skoro $d(p, q) < \delta$ to $y_q - y_p = |y_q - y_p| \leq \sqrt{(x_p - x_q)^2 + (y_p - y_q)^2} = \delta(p, q) \leq \delta$. Ponadto y_r musi być między y_p i y_q : $y_p \leq y_r \leq y_q$, więc $y_r - y_p \leq y_q - y_p < \delta$ zatem co najmniej 9 punktów z P w prostokącie $2\delta \times \delta$ ograniczonym poziomymi liniami $y = y_p$, $y = y_p + \delta$.

Wtedy w lewym lub prawym kwadracie $\delta \times \delta$ jest przynajmniej 5 punktów z P . Przypuśćmy, że to lewy kwadrat. Zatem istnieje kwadrat $\delta \times \delta$ z 5 punktami z P w P_L . Ale wtedy istnieją dwa punkty w P_L w odległości mniejszej niż δ , bo nie da się umieścić w kwadracie $\delta \times \delta$ 5 punktów dla których odległość między dowolnymi dwoma jest mniejsza niż δ . Sprzeczność (bo najmniejsza odległość w P_L to $\delta_L \geq \delta$).

Zatem wystarczy sprawdzić tylko 7 następnych punktów po p w Y' . □



Rysunek 2: Prostokąt $2\delta \times \delta$ ograniczony prostymi $y = y_p$ oraz $y = y_p + \delta$. Zacięniowany lewy kwadrat $\delta \times \delta$ zawiera co najmniej 5 punktów z P .



Rysunek 3: W kwadracie $\delta \times \delta$ nie zmieści się 5 punktów parami oddalonych o co najmniej δ . Najlepsze ułożenie to 4 narożniki; dowolny piąty punkt q jest w odległości co najwyżej $\frac{\delta}{\sqrt{2}} < \delta$ od któregoś z nich (dwa z 5 punktów trafiają do tej samej ćwiartki $\frac{\delta}{2} \times \frac{\delta}{2}$).

Analiza złożoności czasowej Na początku musimy posortować tablicę X i Y . To zajmuje $\mathcal{O}(n \log n)$. Jeśli X i Y są już posortowane to podział X na posortowane X_L i X_R oraz Y analogicznie zajmie $\mathcal{O}(n)$.

Algorytm 2: Podział posortowanej tablicy Y na Y_L i Y_R

```

1:  $length(Y_L) \leftarrow length(Y_R) \leftarrow 0$ 
2: for  $i \leftarrow 1$  to  $length(Y)$  do
3:   if  $Y(i) \in P_L$  then
4:      $length(Y_L) \leftarrow length(Y_L) + 1$ 
5:      $Y_L(length(Y_L)) \leftarrow Y(i)$ 
6:   else
7:      $length(Y_R) \leftarrow length(Y_R) + 1$ 
8:      $Y_R(length(Y_R)) \leftarrow Y(i)$ 

```

Mamy dwa wywołania rekurencyjne dla $n/2$ punktów i fazę połącz. Tablicę Y' można otrzymać z Y w czasie $\mathcal{O}(n)$ tak, że Y' jest posortowana. Niech $x = x_L$ będzie równanie prostej l .

Algorytm 3: Wyznaczanie tablicy Y' punktów w pasie 2δ wokół prostej l

```

1:  $length(Y') \leftarrow 0$ 
2: for  $i \leftarrow 1$  to  $length(Y)$  do

```

```

3:   if  $x_L - \delta \leq Y(i).x \leq x_L + \delta$  then
4:      $length(Y') \leftarrow length(Y') + 1$ 
5:      $Y'(length(Y')) \leftarrow Y(i)$ 

```

Skoro dla każdego z $\mathcal{O}(n)$ punktów z Y' sprawdzamy odległość tylko co najwyżej 7 punktów, to najmniejsza odległość δ' punktów z Y' znajdziemy w czasie $\mathcal{O}(n)$.

Oznaczmy złożoność algorytmu bez wstępnego sortowania przez $T(n)$. Mamy:

$$T(n) = 2 \cdot T\left(\frac{n}{2}\right) + \Theta(n^1) \qquad a = 2, \quad b = 2, \quad k = 1$$

$$2 = 2^1 \Rightarrow T(n) = \Theta(n \log n)$$

Programowanie dynamiczne

Czasami gdy zaimplementujemy jakąś formę rekurencyjną dostajemy algorytm działający w czasie wykładniczym. Powodem może być to, że jakieś wartości obliczane są wielokrotnie.

Problem 2.1 (liczb Fibonacciego).

$$\begin{cases} F_0 = F_1 = 1 & n = 0, 1 \\ F_n = F_{n-1} + F_{n-2} & n \geq 2 \end{cases} \quad \text{Zadanie: Obliczyć } n\text{-tą liczbę Fibonacciego}$$


Algorytm 4: Algorytm naiwny Fib1

```

function FIB1(n)
1:   if  $n \leq 1$  then return 1
2:   return FIB1(n-1) + FIB1(n-2)

```

Zobaczmy jak jest obliczane np. $FIB1(5)$. W drzewie wywołań poszczególne wartości powtarzają się:



Rysunek 4: Drzewo wywołań rekurencyjnych $FIB1(5)$. Wierzchołki o tym samym kolorze odpowiadają temu samemu podproblemowi, liczonemu wielokrotnie od zera: F_3 jest wyznaczane 2 razy, F_2 – 3 razy, a F_1 – 5 razy.

$F(i)$ jest obliczane razy

(1)	5
(2)	3
(3)	2
(4)	1
(5)	1

Niech $s(n)$ będzie liczbą dodawań wykonanych przez alg. w wywołaniu $\text{FIB1}(n)$.

$$\begin{cases} s(0) = s(1) = 0 \\ s(n) = s(n-1) + s(n-2) + 1 \quad n \geq 2 \end{cases}$$

Niech $f(n) = s(n) + 1$

Wtedy $f(0) = f(1) = 1$

$$\begin{aligned} f(n) &= s(n) + 1 = \\ &= s(n-1) + s(n-2) + 1 + 1 = \\ &= f(n-1) - 1 + f(n-2) - 1 + 1 + 1 = \\ &= f(n-1) + f(n-2) \end{aligned}$$

Zatem $f(n) = F_n$, czyli $f(n)$ jest n -tą liczbą Fibonacciego.

Liczby Fibonacciego rosną jak n -ta potęga złotej liczby, więc

$$f(n) = \Theta(F_n) = \Theta\left(\left(\frac{1+\sqrt{5}}{2}\right)^n\right) = \Omega(1.61^n),$$

gdzie ostatnie oszacowanie jest dolne, bo $1.61 < \frac{1+\sqrt{5}}{2} \approx 1.618$.

Stąd $s(n) = f(n) - 1 = \Omega(1.61^n)$, więc liczba dodawań rośnie wykładniczo.

FIB1 jest algorytmem wykładniczym.

Oto alg. progr. dynamicznego:

Algorytm 5: Algorytm dynamiczny Fib2

```

function FIB2( $n$ )
1:   if  $n \leq 1$  then return 1
2:    $F(0) \leftarrow F(1) \leftarrow 1$ 
3:   for  $i \leftarrow 2$  to  $n$  do
4:      $F(i) \leftarrow F(i-1) + F(i-2)$ 
5:   return  $F(n)$ 
    
```

▷ F - tablica

Liczba dodawań wykonanych przez FIB2 w wywołaniu $\text{FIB2}(n)$ wynosi $n-1$. Złożoność czasowa wynosi $\Theta(n)$.

Algorytm mnożenia macierzy

Przypomnijmy, jak mnoży się macierze. Iloczyn $C = A \cdot B$ macierzy A rozmiaru $p \times q$ oraz B rozmiaru $q \times r$ jest macierzą C rozmiaru $p \times r$, w której element $C(i, j)$ to iloczyn skalarny i -tego wiersza macierzy A oraz j -tej kolumny macierzy B :

$$C(i, j) = \sum_{k=1}^q A(i, k) \cdot B(k, j).$$

Biorąc dla przykładu $p = 2$, $q = 3$, $r = 2$ i obliczając wyróżniony element $C(1, 1)$:

$$\underbrace{\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}}_{A: p \times q} \cdot \underbrace{\begin{bmatrix} 7 & 8 \\ 9 & 10 \\ 11 & 12 \end{bmatrix}}_{B: q \times r} = \underbrace{\begin{bmatrix} 58 & 64 \\ 139 & 154 \end{bmatrix}}_{C: p \times r}$$

$$C(1, 1) = 1 \cdot 7 + 2 \cdot 9 + 3 \cdot 11 = 7 + 18 + 33 = 58.$$

Kolorowy wiersz macierzy A i kolorowa kolumna macierzy B dają kolorowy element macierzy C ; sumowanie po $k = 1, \dots, q$ to wewnętrzna pętla algorytmu. Każdy z $p \cdot r$ elementów macierzy C wymaga q mnożeń.

Algorytm 6: Naiwne mnożenie macierzy

```

function MATRIXMULTIPLY( $A, B$ )  ▷  $A$  – macierz  $p \times q$ ;  $B$  – macierz  $q \times r$ ;  $C$  – macierz  $p \times r$ 
1:   for  $i \leftarrow 1$  to  $p$  do
2:     for  $j \leftarrow 1$  to  $r$  do
3:        $C(i, j) \leftarrow 0$ 
4:       for  $k \leftarrow 1$  to  $q$  do
5:          $C(i, j) \leftarrow C(i, j) + A(i, k) \cdot B(k, j)$   ▷ operacja dominująca
6:   return  $C$ 

```

Operacją dominującą jest mnożenie w linii 5. Mamy $p \cdot q \cdot r$ mnożeń. Złożoność jest $\mathcal{O}(p \cdot q \cdot r)$.

Problem mnożenia ciągu macierzy

Przykład 2.2 (Mnożenie ciągu macierzy).

(A_1, A_2, A_3) gdzie A_1 – macierz 5×10 , A_2 – macierz 10×3 , A_3 – macierz 3×2 . Ile potrzeba mnożeń skalarnych (mnożenia liczb) do obliczenia iloczynu $A_1 \cdot A_2 \cdot A_3$?

$$A_1 \cdot A_2 \cdot A_3 = (A_1 \cdot A_2) \cdot A_3 = A_1 \cdot (A_2 \cdot A_3)$$

I sposób: $(A_1 \cdot A_2) \cdot A_3 = 5 \cdot 10 \cdot 3 + 5 \cdot 3 \cdot 2 = 150 + 30 = 180$

II sposób: $A_1 \cdot (A_2 \cdot A_3) = 10 \cdot 3 \cdot 2 + 5 \cdot 10 \cdot 2 = 60 + 100 = 160$

II sposób jest szybszy.

Problem 2.3 (mnożenia ciągu macierzy).

Dla danego ciągu macierzy $(A_1, A_2, \dots, A_n)$, gdzie A_i jest macierzą $p_{i-1} \times p_i$ (cały ciąg wymiarów zapisujemy jednym ciągiem $p = (p_0, p_1, \dots, p_n)$ – kolejne macierze dzielą wspólny wymiar, więc n macierzy opisuje $n + 1$ liczb), znajdź kolejność wykonywania mnożeń minimalizującą liczbę mnożeń skalarnych użytych do obliczenia iloczynu $A_1 \cdot A_2 \cdot \dots \cdot A_n$.

Ile jest różnych sposobów obliczenia tego iloczynu? Innymi słowy, na ile sposobów możemy poprawnie wstawić nawiasy w iloczynie $A_1 \cdot A_2 \cdot \dots \cdot A_n$?

Przykład 2.4 (Kolejności nawiasowania dla $n = 4$).

$$A_1 \cdot A_2 \cdot A_3 \cdot A_4 \quad (n = 4)$$

- $((A_1 \cdot A_2) \cdot A_3) \cdot A_4$
- $(A_1 \cdot (A_2 \cdot A_3)) \cdot A_4$
- $A_1 \cdot ((A_2 \cdot A_3) \cdot A_4)$
- $A_1 \cdot (A_2 \cdot (A_3 \cdot A_4))$
- $(A_1 \cdot A_2) \cdot (A_3 \cdot A_4)$

Zatem mamy 5 sposobów.

Sprawdźmy czy umiemy rozwiązać ten problem szybko poprzez sprawdzenie wszystkich możliwości. Niech $P(n)$ – liczba sposobów wstawienia nawiasów w iloczynie n macierzy. Załóżmy, że ostatnie mnożenie w ciągu $A_1 \dots A_n$ to mnożenie między A_k i A_{k+1} : $(A_1 \dots A_k)(A_{k+1} \dots A_n)$. W podciągach lewym i prawym nawiasy są rozmieszczane niezależnie od siebie.

Stąd rekurencja:

$$\begin{cases} P(n) = \sum_{k=1}^{n-1} P(k) \cdot P(n-k) \\ P(1) = 1 \end{cases}$$

Jest to znana formuła rekurencyjna a rozwiązanie to przesunięta liczba Catalana:

$$P(n) = C(n-1), \text{ gdzie } C(n) = \frac{1}{n+1} \binom{2n}{n} \text{ jest } n\text{-tą liczbą Catalana.}$$

Wiadomo, że $C(n) = \Omega\left(\frac{4^n}{n^{3/2}}\right)$. Zatem $P(n)$ jest wykładniczy względem n . Chcemy znaleźć szybki algorytm.

Rozwiązanie z optymalną podstrukturą: Zauważmy że jeśli optymalne rozwiązanie jest postaci $(A_1 \dots A_k)(A_{k+1} \dots A_n)$ dla jakiegoś $k \in \{1, \dots, n-1\}$, to w podciągach $A_1 \dots A_k$ i $A_{k+1} \dots A_n$ rozwiązanie nawiasów musi być optymalne. Wpp. lepsze rozmieszczenie nawiasów w $A_1 \dots A_k$ lub $A_{k+1} \dots A_n$ dałoby lepsze rozmieszczenie nawiasów w całym ciągu.

Rozwiązanie optymalne zawiera rozwiązania optymalne podproblemów (własność optymalnej podstruktury). Podproblemami w naszym problemie są problemy optymalnego rozmieszczenia nawiasów w ciągach $A_i A_{i+1} \dots A_j$ dla $1 \leq i \leq j \leq n$.

Niech $m(i, j)$ oznacza minimalną liczbę mnożeń skalarnych potrzebnych do obliczenia tego iloczynu $A_i \dots A_j$ dla $1 \leq i \leq j \leq n$. Chcemy obliczyć $m(1, n)$.

$$m(i, i) = 0$$

Optymalny sposób rozmieszczenia nawiasów jest postaci $(A_i \dots A_k)(A_{k+1} \dots A_j)$ dla pewnego $k \in \{i, \dots, j-1\}$. Stąd mamy zależność:

$$m(i, j) = \min_{i \leq k < j} \{m(i, k) + m(k+1, j) + p_{i-1} \cdot p_k \cdot p_j\} \quad \text{dla } i < j$$

Dygresja. Składnik $p_{i-1} \cdot p_k \cdot p_j$ to koszt *ostatniego* mnożenia, czyli pomnożenia macierzy będącej wynikiem $A_i \dots A_k$ przez macierz będącą wynikiem $A_{k+1} \dots A_j$. Rozmiar iloczynu ciągu macierzy odczytujemy „teleskopowo” – wewnętrzne wymiary (liczba kolumn poprzedniej macierzy = liczba wierszy następnej) skracają się, a zostają jedynie skrajne:

$$\begin{aligned} A_i \dots A_k : M_{p_{i-1}}^{p_i} \cdot M_{p_i}^{p_{i+1}} \dots M_{p_{k-1}}^{p_k} &\longrightarrow M_{p_{i-1}}^{p_k}, \\ A_{k+1} \dots A_j : M_{p_k}^{p_{k+1}} \cdot M_{p_{k+1}}^{p_{k+2}} \dots M_{p_{j-1}}^{p_j} &\longrightarrow M_{p_k}^{p_j}. \end{aligned}$$

Pozostaje pomnożyć macierz $M_{p_{i-1}}^{p_k}$ ¹ przez macierz $M_{p_k}^{p_j}$, a to – zgodnie ze wzorem na koszt mnożenia dwóch macierzy – kosztuje

$$p_{i-1} \cdot \underbrace{p_k}_{\text{wspólny wymiar}} \cdot p_j$$

mnożeń skalarnych.

Niech $s(i, j)$, dla $1 \leq i < j \leq n$, będzie wartością k , dla którego to minimum jest osiągane (czyli $s(i, j)$ wskazuje miejsce ostatniego mnożenia w optymalnym rozwiązaniu podproblemu $A_i \dots A_j$).

Jeśli zaimplementujemy po prostu tę formułę rekurencyjną otrzymamy alg. wykładniczy. Ale jest tylko $n + \binom{n}{2} = \mathcal{O}(n^2)$ podproblemów, więc rzędu $\mathcal{O}(n^2)$ liczb $m(i, j)$ i każdą z tych liczb wystarczy obliczyć jeden raz.

Pomysł programowania dynamicznego polega więc na zapamiętaniu tych wartości w tablicy zamiast liczenia ich wielokrotnie. Wprowadzamy dwie tablice indeksowane parą (i, j) , $1 \leq i \leq j \leq n$ (a ponieważ rozważamy tylko $i \leq j$, wypełniona zostaje jedynie górna połowa każdej z nich – jak w przykładzie poniżej):

- $m(i, j)$ – **koszt**: minimalna liczba mnożeń skalarnych dla podproblemu $A_i \dots A_j$. Ostateczną odpowiedzią jest $m(1, n)$.
- $s(i, j)$ – **cięcie**: miejsce k ostatniego mnożenia, na którym ten minimalny koszt jest osiągany. Sama tablica m podaje tylko *ile* mnożeń wystarczy, ale nie *jak* ustawić nawiasy; to s pozwala odtworzyć optymalne nawiasowanie (wykorzysta ją algorytm MATRIXCHAINMULTIPLY dalej).

Algorytm 7: Algorytm Matrix Chain Order

```

function MATRIXCHAINORDER( $p$ )
1:   $n \leftarrow \text{length}(p) - 1$ 
2:  for  $i \leftarrow 1$  to  $n$  do
3:     $m(i, i) \leftarrow 0$ 
4:    for  $l \leftarrow 2$  to  $n$  do
5:      for  $i \leftarrow 1$  to  $n - l + 1$  do
6:         $j \leftarrow i + l - 1$ 
7:         $m(i, j) \leftarrow \infty$ 
8:        for  $k \leftarrow i$  to  $j - 1$  do
9:           $q \leftarrow m(i, k) + m(k + 1, j) + p_{i-1} \cdot p_k \cdot p_j$ 
10:         if  $q < m(i, j)$  then
11:            $m(i, j) \leftarrow q$ 
12:            $s(i, j) \leftarrow k$ 
13:  return  $m, s$ 

```

$\triangleright p = (p_0, p_1, \dots, p_n)$ - ciąg rozmiarów
 $\triangleright A_i$ - macierz $p_{i-1} \times p_i$
 $\triangleright l$ - liczba macierzy w podproblemie
 $\triangleright l = 2$: $A_1 A_2, A_2 A_3, \dots, A_{n-1} A_n$
 $\triangleright l = 3$: $A_1 A_2 A_3, A_2 A_3 A_4, \dots, A_{n-2} A_{n-1} A_n$
 $\triangleright l = n$: $A_1 \dots A_n$

¹ M_a^b – przestrzeń liniowa macierzy o a wierszach i b kolumnach (wymiaru $a \times b$).

Dygresja. Algorytm wypełnia tablicę m *od dołu*: zaczyna od najmniejszych podproblemów i rośnie. Kluczowa jest kolejność, w jakiej wypełnimy komórki – tak dobrana, by w chwili liczenia $m(i, j)$ wszystkie potrzebne mniejsze wartości były już policzone.

- **Pierwsza pętla (po i)** ustawia przekątną $m(i, i) = 0$: pojedyncza macierz nie wymaga żadnego mnożenia.
- **Zmienna l** to *długość* podproblemu, czyli liczba macierzy w ciągu $A_i \dots A_j$. Wzór $m(i, j) = \min_k \{ m(i, k) + m(k+1, j) + \dots \}$ odwołuje się wyłącznie do podciągów *krótszych* niż $A_i \dots A_j$ (bo $k < j$ oraz $k+1 > i$). Dlatego idziemy po $l = 2, 3, \dots, n$: gdy liczymy ciągi długości l , wszystkie ciągi długości $< l$ są już w tablicy.
- **Przy ustalonym l** przesuwamy okno długości l wzdłuż ciągu: i to początek okna, a koniec wyznacza $j = i + l - 1$. Górna granica $i \leq n - l + 1$ pilnuje, by okno nie wyszło poza A_n (komentarze obok pętli pokazują, jak dla kolejnych l przesuwa się okno).
- **Wewnętrzna pętla po k** próbuje każdego miejsca ostatniego mnożenia $A_i \dots A_k \mid A_{k+1} \dots A_j$ i zostawia to o najmniejszym koszcie q . Przy każdej poprawie zapamiętujemy nie tylko koszt w $m(i, j)$, ale i zwycięskie cięcie w $s(i, j)$ – to ono pozwoli później odtworzyć nawiasowanie.

Innymi słowy: l mówi *jak duży* podproblem liczymy, i (a z nim j) *który* to podproblem, a k przeszukuje wszystkie sposoby jego rozcięcia.

Mamy 3 pętle (po l, i, k) i liczbę iteracji każdej z tych pętli można ograniczyć przez n , zatem złożoność czasowa to $\mathcal{O}(n^3)$.

Przykład 2.5 (Optymalna kolejność mnożenia macierzy dla $n = 5$).

$p = (4, 5, 2, 1, 2, 3)$.

$A_1 - 4 \times 5$, $A_2 - 5 \times 2$, $A_3 - 2 \times 1$, $A_4 - 1 \times 2$, $A_5 - 2 \times 3$.

$$m = \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & 0 & 40 & 30 & 38 & 48 \\ 2 & \times & 0 & 10 & 20 & 31 \\ 3 & \times & \times & 0 & 4 & 12 \\ 4 & \times & \times & \times & 0 & 6 \\ 5 & \times & \times & \times & \times & 0 \end{bmatrix}$$

$$s = \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & \times & 1 & 1 & 3 & 3 \\ 2 & \times & \times & 2 & 3 & 3 \\ 3 & \times & \times & \times & 3 & 3 \\ 4 & \times & \times & \times & \times & 4 \\ 5 & \times & \times & \times & \times & \times \end{bmatrix}$$

Prześledźmy, jak rosną obie tablice. Algorytm wypełnia je *przekątnymi*: najpierw $L = 1$ (przekątna główna), potem $L = 2$, $L = 3$, Komórki dopisane w danym kroku wyróżniono na **pomarańczowo**; puste pola to podproblemy jeszcze nieobliczone, a $\times$ – pola nieużywane ($i \geq j$ dla s , $i > j$ dla m).

Stan początkowy ($L = 1$, pojedyncze macierze, koszt 0):

$$m = \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & 0 & & & & \\ 2 & \times & 0 & & & \\ 3 & \times & \times & 0 & & \\ 4 & \times & \times & \times & 0 & \\ 5 & \times & \times & \times & \times & 0 \end{bmatrix}$$

$$s = \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & \times & & & & \\ 2 & \times & \times & & & \\ 3 & \times & \times & \times & & \\ 4 & \times & \times & \times & \times & \\ 5 & \times & \times & \times & \times & \times \end{bmatrix}$$

i	0	1	2	3	4	5
p_i	4	5	2	1	2	3

 $A_i = p_{i-1} \times p_i$

$L = 2$: $m(1, 2) = 4 \cdot 5 \cdot 2 = 40$

$$m(2, 3) = 5 \cdot 2 \cdot 1 = 10$$

$$m(3, 4) = 2 \cdot 1 \cdot 2 = 4$$

$$m(4, 5) = 1 \cdot 2 \cdot 3 = 6$$

po $L = 2$ (pary sąsiednich macierzy):

$$m \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & 0 & 40 & & & \\ 2 & \times & 0 & 10 & & \\ 3 & \times & \times & 0 & 4 & \\ 4 & \times & \times & \times & 0 & 6 \\ 5 & \times & \times & \times & \times & 0 \end{bmatrix}$$

$$s \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & \times & 1 & & & \\ 2 & \times & \times & 2 & & \\ 3 & \times & \times & \times & 3 & \\ 4 & \times & \times & \times & \times & 4 \\ 5 & \times & \times & \times & \times & \times \end{bmatrix}$$

i	0	1	2	3	4	5
p_i	4	5	2	1	2	3

 $A_i = p_{i-1} \times p_i$

$$\begin{aligned}
 L = 3 : \quad m(1, 3) &= \min \begin{cases} m(1, 1) + m(2, 3) + 4 \cdot 5 \cdot 1 \\ m(1, 2) + m(3, 3) + 4 \cdot 2 \cdot 1 \end{cases} = \min \begin{cases} 0 + 10 + 20 \\ 40 + 0 + 8 \end{cases} = \min \begin{cases} 30 \\ 48 \end{cases} = 30 \\
 m(2, 4) &= \min \begin{cases} m(2, 2) + m(3, 4) + 5 \cdot 2 \cdot 2 \\ m(2, 3) + m(4, 4) + 5 \cdot 1 \cdot 2 \end{cases} = \min \begin{cases} 0 + 4 + 20 \\ 10 + 0 + 10 \end{cases} = \min \begin{cases} 24 \\ 20 \end{cases} = 20 \\
 m(3, 5) &= \min \begin{cases} m(3, 3) + m(4, 5) + 2 \cdot 1 \cdot 3 \\ m(3, 4) + m(5, 5) + 2 \cdot 2 \cdot 3 \end{cases} = \min \begin{cases} 0 + 6 + 6 \\ 4 + 0 + 12 \end{cases} = \min \begin{cases} 12 \\ 16 \end{cases} = 12
 \end{aligned}$$

po $L = 3$:

$$m \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & 0 & 40 & 30 & & \\ 2 & \times & 0 & 10 & 20 & \\ 3 & \times & \times & 0 & 4 & 12 \\ 4 & \times & \times & \times & 0 & 6 \\ 5 & \times & \times & \times & \times & 0 \end{bmatrix}$$

$$s \begin{bmatrix} i \backslash j & 1 & 2 & 3 & 4 & 5 \\ 1 & \times & 1 & 1 & & \\ 2 & \times & \times & 2 & 3 & \\ 3 & \times & \times & \times & 3 & 3 \\ 4 & \times & \times & \times & \times & 4 \\ 5 & \times & \times & \times & \times & \times \end{bmatrix}$$

i	0	1	2	3	4	5
p_i	4	5	2	1	2	3

 $A_i = p_{i-1} \times p_i$

$$\begin{aligned}
 L = 4 : \quad m(1, 4) &= \min \begin{cases} m(1, 1) + m(2, 4) + 4 \cdot 5 \cdot 2 \\ m(1, 2) + m(3, 4) + 4 \cdot 2 \cdot 2 \\ m(1, 3) + m(4, 4) + 4 \cdot 1 \cdot 2 \end{cases} = \min \begin{cases} 0 + 20 + 40 \\ 40 + 4 + 16 \\ 30 + 0 + 8 \end{cases} = \min \begin{cases} 60 \\ 60 \\ 38 \end{cases} = 38 \\
 m(2, 5) &= \min \begin{cases} m(2, 2) + m(3, 5) + 5 \cdot 2 \cdot 3 \\ m(2, 3) + m(4, 5) + 5 \cdot 1 \cdot 3 \\ m(2, 4) + m(5, 5) + 5 \cdot 2 \cdot 3 \end{cases} = \min \begin{cases} 0 + 12 + 30 \\ 10 + 6 + 15 \\ 20 + 0 + 30 \end{cases} = \min \begin{cases} 42 \\ 31 \\ 50 \end{cases} = 31
 \end{aligned}$$

po $L = 4$:

m	$i \backslash j$	1	2	3	4	5
	1	0	40	30	38	
	2	×	0	10	20	31
	3	×	×	0	4	12
	4	×	×	×	0	6
	5	×	×	×	×	0

s	$i \backslash j$	1	2	3	4	5
	1	×	1	1	3	
	2	×	×	2	3	3
	3	×	×	×	3	3
	4	×	×	×	×	4
	5	×	×	×	×	×

i	0	1	2	3	4	5
p_i	4	5	2	1	2	3

$A_i = p_{i-1} \times p_i$

$$L = 5 : \quad m(1, 5) = \min \begin{cases} m(1, 1) + m(2, 5) + 4 \cdot 5 \cdot 3 \\ m(1, 2) + m(3, 5) + 4 \cdot 2 \cdot 5 \\ m(1, 3) + m(4, 5) + 4 \cdot 1 \cdot 3 \\ m(1, 4) + m(5, 5) + 4 \cdot 2 \cdot 3 \end{cases} = \min \begin{cases} 0 + 31 + 60 \\ 40 + 12 + 24 \\ 30 + 6 + 12 \\ 38 + 0 + 24 \end{cases} = \min \begin{cases} 91 \\ 76 \\ 48 \\ 62 \end{cases} = 48$$

po $L = 5$ (cały ciąg – ostatnia komórka):

m	$i \backslash j$	1	2	3	4	5
	1	0	40	30	38	48
	2	×	0	10	20	31
	3	×	×	0	4	12
	4	×	×	×	0	6
	5	×	×	×	×	0

s	$i \backslash j$	1	2	3	4	5
	1	×	1	1	3	3
	2	×	×	2	3	3
	3	×	×	×	3	3
	4	×	×	×	×	4
	5	×	×	×	×	×

Każdy przebieg pętli po l dopisuje dokładnie jedną przekątną: w komórce $m(i, j)$ łąduje koszt, a w bliźniaczej $s(i, j)$ – zwycięskie cięcie k . Ostatnią obliczoną wartością jest $m(1, 5) = 48$ w prawym górnym rogu – szukany koszt całego ciągu.

Oto algorytm znajdowania optymalnego rozwiązania:

Algorytm 8: Algorytm Matrix Chain Multiply

```

function MATRIXCHAINMULTIPLY( $A, s, i, j$ )                                ▷  $A = (A_1, \dots, A_n)$ 
1:   if  $j = i$  then
2:     return  $A_i$ 
3:    $X \leftarrow$  MATRIXCHAINMULTIPLY( $A, s, i, s(i, j)$ )
4:    $Y \leftarrow$  MATRIXCHAINMULTIPLY( $A, s, s(i, j) + 1, j$ )
5:   return MATRIXMULTIPLY( $X, Y$ )

```

W celu znalezienia rozwiązania wywołujemy: MATRIXCHAINMULTIPLY($A, s, 1, n$)

$$A_1 \cdot A_2 \cdot A_3 \cdot A_4 \cdot A_5$$

$$s(1, 5) = 3 \implies (A_1 \cdot A_2 \cdot A_3)(A_4 \cdot A_5)$$

$$s(1, 3) = 1 \implies (A_1 \cdot (A_2 \cdot A_3))(A_4 \cdot A_5) \quad s(4, 5) = 4 \implies \text{bez zmian}$$

$$s(2, 3) = 2 \implies (A_1 \cdot (A_2 \cdot A_3))(A_4 \cdot A_5)$$

Aby algorytm zadziałał dobrze, problem musi spełniać warunki:

1. Własność optymalnej podstruktury – optymalne rozwiązanie problemu można skonstruować z optymalnych rozwiązań podproblemów.

2. Własność wspólnych podproblemów – sytuacja, gdy prosty algorytm rekurencyjny obliczałby rozwiązania tych samych podproblemów wielokrotnie. Liczba podproblemów powinna być „mała”.

W klasycznej metodzie programowania dynamicznego rozwiązanie jest budowane od dołu do góry – od podproblemów najmniejszych do największych. Jest też podejście, w którym rozwiązanie jest budowane od góry do dołu, podobnie jak w prostym algorytmie rekurencyjnym, ale z tą różnicą, że unikamy obliczania tych samych podproblemów wielokrotnie. To podejście nazywa się spamiętywaniem (*memoization*).

Problem mnożenia ciągu macierzy ze spamiętywaniem Algorytm oblicza tablice m i s jak poprzednio, ale w inny sposób. Dopóki podproblem nie jest rozwiązany, $m(i, j)$ przechowuje ∞ . Po rozwiązaniu podproblemu (i, j) umieszczamy w $m(i, j)$ odpowiednią wartość i od tej pory używamy jej bez obliczania.

Algorytm 9: Algorytm Lookup Chain

function LOOKUPCHAIN(p, i, j) $\triangleright p = (p_0, \dots, p_n)$ - ciąg wymiarów; A_i - macierz $p_{i-1} \times p_i$

```

1:  if  $m(i, j) < \infty$  then
2:    return  $m(i, j), s(i, j)$ 
3:  if  $i = j$  then
4:     $m(i, j) \leftarrow 0$ 
5:  else
6:    for  $k \leftarrow i$  to  $j - 1$  do
7:       $q \leftarrow \text{LOOKUPCHAIN}(p, i, k) + \text{LOOKUPCHAIN}(p, k + 1, j) + p_{i-1} \cdot p_k \cdot p_j$ 
8:      if  $q < m(i, j)$  then
9:         $m(i, j) \leftarrow q$ 
10:        $s(i, j) \leftarrow k$ 
11:  return  $(m(i, j), s(i, j))$ 

```

Algorytm 10: Algorytm Memoized Matrix Chain

function MEMOIZEDMATRIXCHAIN(p)

```

1:   $n \leftarrow \text{length}(p) - 1$ 
2:  for  $i \leftarrow 1$  to  $n$  do
3:    for  $j \leftarrow i$  to  $n$  do
4:       $m(i, j) \leftarrow \infty$ 
5:  return LOOKUPCHAIN( $p, 1, n$ )

```

Złożoność czasowa:

- Linie 1–4 w MEMOIZEDMATRIXCHAIN zajmują $\Theta(n^2)$.
- Każdy z $\mathcal{O}(n^2)$ elementów tablicy m jest modyfikowany raz, później odczytanie wartości $m(i, j)$ zajmuje czas stały.
- Modyfikacja $m(i, j)$ zajmuje $\mathcal{O}(n)$ czasu (pętla w liniach 5–9 w LOOKUPCHAIN).

Ostatecznie złożoność algorytmu wynosi $\mathcal{O}(n^3)$.

Problem najdłuższego wspólnego podciągu

Niech $X = (x_1, \dots, x_m)$ – ciąg.

$Z = (z_1, \dots, z_k)$ jest podciągiem X , jeśli istnieje rosnący ciąg indeksów $1 \leq i_1 < i_2 < \dots < i_k \leq m$ takich, że dla każdego $j \in \{1, \dots, k\}$, $z_j = x_{i_j}$.

Przykład 2.6 (Podciąg).

$X = (A, B, C, B, D, A, B)$, $Z = (B, C, D, B)$. Indekszy: (2, 3, 5, 7).

Problem 2.7 (najdłuższego wspólnego podciągu).


Dane są ciągi $X = (x_1, \dots, x_m)$ oraz $Y = (y_1, \dots, y_n)$. Należy znaleźć najdłuższy wspólny podciąg (LCS – *Longest Common Subsequence*) X i Y , czyli najdłuższy ciąg, który jest podciągiem zarówno X , jak i Y .

Wszystkich podciągów X jest 2^m , więc algorytm sprawdzający wszystkie podciągi X działa w czasie wykładniczym.

Niech $X_i = (x_1, \dots, x_i)$ dla $i \in \{1, \dots, m\}$ i dodatkowo $X_0 = ()$ (ciąg pusty). Analogicznie dla Y .

Lemat 2.8. Niech $X = (x_1, \dots, x_m)$, $Y = (y_1, \dots, y_n)$ i niech $Z = (z_1, \dots, z_k)$ będzie LCS X i Y .

1. Jeśli $x_m = y_n$, to $z_k = x_m = y_n$ i Z_{k-1} jest LCS X_{m-1} i Y_{n-1} .
2. Jeśli $x_m \neq y_n$ i $z_k \neq x_m$, to Z jest LCS X_{m-1} i Y .
3. Jeśli $x_m \neq y_n$ i $z_k \neq y_n$, to Z jest LCS X i Y_{n-1} .



Rysunek 5: Trzy przypadki lematu o optymalnej podstrukturze LCS. Żółta komórka – dopasowany ostatni element ($x_m = y_n$), który wchodzi do LCS; szara, przekreślona komórka – element odrzucony, nienależący do tego LCS; przerywana pomarańczowa ramka – podproblem(y), do których redukuje się zadanie.

Dowód.

1. Załóżmy, że $x_m = y_n$. Gdyby $z_k \neq x_m$, to moglibyśmy wydłużyć podciąg Z przez dodanie $z_{k+1} = x_m = y_n$, co daje sprzeczność, bo $(z_1, \dots, z_{k+1})$ jest wspólnym podciągiem X i Y dłuższym niż Z . Zatem $z_k = x_m = y_n$ i Z_{k-1} jest wspólnym podciągiem X_{m-1} i Y_{n-1} . Gdyby istniał wspólny podciąg W ciągów X_{m-1} i Y_{n-1} długości $> k - 1$, to dodając na koniec W element $x_m = y_n$ otrzymalibyśmy wspólny podciąg X i Y długości $> k - 1 + 1 = k$. Sprzeczność, bo długość Z wynosi k .
2. Załóżmy, że $x_m \neq y_n$ i $z_k \neq x_m$. Wtedy Z jest wspólnym podciągiem ciągów X_{m-1} i Y . Gdyby istniał wspólny podciąg W ciągów X_{m-1} i Y o długości $> k$, to W byłby wspólnym podciągiem ciągów X i Y dłuższym niż Z . Sprzeczność.
3. Symetrycznie do punktu 2.

□

Rozwiązanie dla problemu (X, Y) można skonstruować z rozwiązań podproblemów (X_{m-1}, Y_{n-1}) , (X_{m-1}, Y) i (X, Y_{n-1}) – **własność optymalnej podstruktury**. Podproblem (X_{m-1}, Y_{n-1}) jest zawarty w podproblemach (X_{m-1}, Y) i (X, Y_{n-1}) – **własność wspólnych podproblemów**.

Niech $c(i, j)$ oznacza długość LCS ciągów X_i i Y_j .

$$c(i, j) = \begin{cases} 0 & \text{jeśli } i = 0 \text{ lub } j = 0 \\ c(i-1, j-1) + 1 & \text{jeśli } i, j > 0 \text{ i } x_i = y_j \\ \max\{c(i-1, j), c(i, j-1)\} & \text{jeśli } i, j > 0 \text{ i } x_i \neq y_j \end{cases}$$

Będziemy też używać tablicy $b(i, j)$, aby znaleźć sam podciąg LCS. Tablice mają wymiary: $c[0 \dots m, 0 \dots n]$ oraz $b[1 \dots m, 1 \dots n]$. Wartości w tablicy kierunków to $b(i, j) \in \{\nwarrow, \uparrow, \leftarrow\}$.

Algorytm 11: Algorytm obliczający długość LCS

```

function LCS( $X, Y$ )
1:   $m \leftarrow \text{length}(X)$ 
2:   $n \leftarrow \text{length}(Y)$ 
3:  for  $i \leftarrow 0$  to  $m$  do
4:     $c(i, 0) \leftarrow 0$ 
5:  for  $j \leftarrow 0$  to  $n$  do
6:     $c(0, j) \leftarrow 0$ 
7:  for  $i \leftarrow 1$  to  $m$  do
8:    for  $j \leftarrow 1$  to  $n$  do
9:      if  $x_i = y_j$  then
10:          $c(i, j) \leftarrow c(i-1, j-1) + 1$ 
11:          $b(i, j) \leftarrow \text{„}\nwarrow\text{”}$ 
12:      else if  $c(i-1, j) \geq c(i, j-1)$  then
13:          $c(i, j) \leftarrow c(i-1, j)$ 
14:          $b(i, j) \leftarrow \text{„}\uparrow\text{”}$ 
15:      else
16:          $c(i, j) \leftarrow c(i, j-1)$ 
17:          $b(i, j) \leftarrow \text{„}\leftarrow\text{”}$ 
18:  return ( $c, b$ )
    
```

Przykład: $X = (A, B, C, B, D, A, B)$, $Y = (B, D, C, A, B, A)$.
 $m = 7$, $n = 6$.

Tablica kosztów c :

	j	0	1	2	3	4	5	6
i	y_j	B	D	C	A	B	A	
0	x_i	0	0	0	0	0	0	0
1	A	0	0	0	0	1	1	1
2	B	0	1	1	1	1	2	2
3	C	0	1	1	2	2	2	2
4	B	0	1	1	2	2	3	3
5	D	0	1	2	2	2	3	3
6	A	0	1	2	2	3	3	4
7	B	0	1	2	2	3	4	4

Tablica strzałek b :

	j	0	1	2	3	4	5	6
i	y_j	B	D	C	A	B	A	
0	x_i							
1	A		$\uparrow$	$\uparrow$	$\uparrow$	$\nwarrow$	$\leftarrow$	$\nwarrow$
2	B		$\nwarrow$	$\leftarrow$	$\leftarrow$	$\uparrow$	$\nwarrow$	$\leftarrow$
3	C		$\uparrow$	$\uparrow$	$\nwarrow$	$\leftarrow$	$\uparrow$	$\uparrow$
4	B		$\nwarrow$	$\uparrow$	$\uparrow$	$\uparrow$	$\nwarrow$	$\leftarrow$
5	D		$\uparrow$	$\nwarrow$	$\uparrow$	$\uparrow$	$\uparrow$	$\uparrow$
6	A		$\uparrow$	$\uparrow$	$\uparrow$	$\nwarrow$	$\uparrow$	$\nwarrow$
7	B		$\nwarrow$	$\uparrow$	$\uparrow$	$\uparrow$	$\nwarrow$	$\uparrow$

Dygresja. Pełne wypełnienie tablicy to $7 \cdot 6 = 42$ powtórzenia tej samej reguły, więc prześledźmy tylko po jednej komórce na każdą z gałęzi rekurencji (pozostałe liczymy analogicznie). Indeksowanie: $X = (x_1, \dots, x_7)$, $Y = (y_1, \dots, y_6)$.

- **Dopasowanie ($\searrow$).** Komórka $c(2, 1)$: $x_2 = B$, $y_1 = B$, więc $x_i = y_j$. Bierzemy wartość z przekątnej i dodajemy 1: $c(2, 1) = c(1, 0) + 1 = 0 + 1 = 1$. Ostatnie znaki się zgadzają, więc element wchodzi do LCS i strzałka wskazuje $\searrow$.
- **Brak dopasowania, w górę ($\uparrow$).** Komórka $c(3, 1)$: $x_3 = C$, $y_1 = B$, więc $x_i \neq y_j$. Porównujemy sąsiadów: $c(2, 1) = 1$ (góra) oraz $c(3, 0) = 0$ (lewo). Ponieważ $c(i - 1, j) \geq c(i, j - 1)$, bierzemy $c(3, 1) = c(2, 1) = 1$ i strzałkę $\uparrow$.
- **Brak dopasowania, w lewo ($\leftarrow$).** Komórka $c(2, 2)$: $x_2 = B$, $y_2 = D$, więc $x_i \neq y_j$. Sąsiedzi: $c(1, 2) = 0$ (góra) oraz $c(2, 1) = 1$ (lewo). Tym razem $c(i - 1, j) < c(i, j - 1)$, więc $c(2, 2) = c(2, 1) = 1$ i strzałka $\leftarrow$.
- **Remis.** Komórka $c(1, 1)$: $x_1 = A \neq B = y_1$, a obaj sąsiedzi są równi: $c(0, 1) = c(1, 0) = 0$. Warunek $c(i - 1, j) \geq c(i, j - 1)$ jest spełniony (równość), więc algorytm wybiera $\uparrow$ – remis rozstrzygamy zawsze na korzyść góry.

Algorytm 12: Wypisywanie najdłuższego wspólnego podciągu

```

function PRINTLCS( $b, X, Y, i, j$ )
1:   if  $i = 0$  lub  $j = 0$  then
2:     return  $\epsilon$ 
3:   if  $b(i, j) = \text{„}\searrow\text{”}$  then
4:     PRINTLCS( $b, X, Y, i - 1, j - 1$ )
5:     print  $x_i$ 
6:   else if  $b(i, j) = \text{„}\uparrow\text{”}$  then
7:     PRINTLCS( $b, X, Y, i - 1, j$ )
8:   else
9:     PRINTLCS( $b, X, Y, i, j - 1$ )

```

▷ ciąg pusty

Żeby wypisać rozwiązanie, wywołujemy $\text{PRINTLCS}(b, X, Y, m, n)$.

Dla powyższego przykładu otrzymamy: (B, C, B, A) .

Dygresja. Prześledźmy to wywołanie. Zaczynamy od prawego dolnego rogu i podążamy za strzałkami z tablicy b aż do brzegu tablicy. Przy $\searrow$ schodzimy po przekątnej do $(i - 1, j - 1)$ i zaznaczamy znak x_i jako należący do LCS; przy $\uparrow$ idziemy do $(i - 1, j)$, a przy $\leftarrow$ do $(i, j - 1)$ (bez wypisywania).

$$\begin{aligned}
 (7, 6) &\xrightarrow{\uparrow} (6, 6) \xrightarrow{\searrow} (5, 5) \quad [x_6 = A] \\
 &\xrightarrow{\uparrow} (4, 5) \xrightarrow{\searrow} (3, 4) \quad [x_4 = B] \\
 &\xrightarrow{\leftarrow} (3, 3) \xrightarrow{\searrow} (2, 2) \quad [x_3 = C] \\
 &\xrightarrow{\leftarrow} (2, 1) \xrightarrow{\searrow} (1, 0) \quad [x_2 = B]
 \end{aligned}$$

W $(1, 0)$ mamy $j = 0$, więc rekurencja się zatrzymuje. Wypisywanie następuje *po* powrocie z wywołania rekurencyjnego, więc znaki pojawiają się od najgłębszego: B (z $(2, 1)$), potem C , B i A – czyli w kolejności (B, C, B, A) , zgodnie z lewym-do-prawego porządkiem oryginalnych ciągów.

Złożoność czasowa tego algorytmu wynosi $\Theta(m \cdot n)$.

Algorytmy zachłanne

Pomysł: Algorytm w każdym kroku dokonuje lokalnie najlepszego wyboru (najlepszego w danym momencie).

Problem 3.1 (wyboru zajęć).

$S = \{z_1, \dots, z_n\}$ – zbiór zajęć wymagający tych samych zasobów.

s_i – czas rozpoczęcia zajęcia z_i

$$s_i, t_i \in \mathbb{N}, \quad s_i < t_i$$

t_i – czas zakończenia zajęcia z_i

Zajęcia z_i i z_j nazywamy zgodnymi, jeśli $\langle s_i, t_i \rangle \cap \langle s_j, t_j \rangle = \emptyset$. Zadanie polega na znalezieniu podzbioru o największej liczności $A \subseteq S$ parami zgodnych zajęć.

Przykład 3.2. Przykładowy zbiór zajęć:

i	1	2	3	4	5	6
s_i	0	2	4	7	1	7
t_i	4	6	7	10	3	9

Porządkujemy zajęcia w czasie niemalejącym względem czasu zakończenia. To zajmuje $\mathcal{O}(n \log n)$ czasu. Od tej pory zakładamy $t_1 \leq t_2 \leq \dots \leq t_n$ (zajęcia są już posortowane).

Przykład 3.3. Zajęcia z przykładu 3.2 po posortowaniu względem czasu zakończenia:

i	1	2	3	4	5	6
s_i	1	0	2	4	7	7
t_i	3	4	6	7	9	10

Podjęście programowania dynamicznego Definiujemy zbiory zajęć:

$$S_{ij} = \{z_k \in S : t_i \leq s_k < t_k \leq s_j\}$$

(zbiór zajęć zaczynających się po czasie zakończenia zajęcia z_i i kończących się przed czasem rozpoczęcia zajęcia z_j).

Dodajemy 2 sztuczne zajęcia: z_0 z czasem $t_0 = 0$ i z_{n+1} z czasem $s_{n+1} = \infty$. Wtedy $S = S_{0,n+1}$. Jeśli $i \geq j$, to $S_{ij} = \emptyset$, bo $s_j < t_j \leq t_i$ (bo zajęcia są posortowane).

Dygresja. Pokażmy dokładniej, dlaczego $S_{ij} = \emptyset$ dla $i \geq j$. Przypuśćmy, że istnieje $z_k \in S_{ij}$. Z definicji S_{ij} mamy wtedy $t_i \leq s_k < t_k \leq s_j$, a ponieważ zajęcia są posortowane i $i \geq j$, to $t_j \leq t_i$, skąd $s_j < t_j \leq t_i$. Łącząc obie nierówności, otrzymujemy $s_j < t_i \leq s_k < t_k \leq s_j$, czyli $s_j < s_j$ – sprzeczność.

Problem: znaleźć podzbiór o największej liczności zbioru S_{ij} składający się z parami zgodnych zajęć dla $0 \leq i \leq j \leq n+1$.

Niech A_{ij} będzie jakimkolwiek podzbiorem największej liczności składającym się z parami zgodnych zajęć zbioru S_{ij} oraz niech $c(i, j) = |A_{ij}|$.

Podproblem S_{ij} : Załóżmy, że $z_k \in S_{ij}$. Jeśli wybierzemy z_k do zbioru rozwiązania, to otrzymamy dwa zbiory (podproblemy):

- S_{ik} (zbiór zajęć, które zaczynają się po zakończeniu zajęcia z_i i kończą się przed rozpoczęciem zajęcia z_k),
- S_{kj} (zbiór zajęć, które zaczynają się po zakończeniu zajęcia z_k i kończą przed rozpoczęciem zajęcia z_j).

Rozwiązanie dla S_{ij} będzie sumą rozwiązań dla S_{ik} oraz S_{kj} oraz elementu $\{z_k\}$.

Własność optymalnej podstruktury: Załóżmy, że $z_k \in A_{ij}$. Wtedy $A_{ij} = A_{ik} \cup \{z_k\} \cup A_{kj}$. Gdyby istniało rozwiązanie A'_{ik} dla S_{ik} takie, że $|A'_{ik}| > |A_{ik}|$, to zbiór $A'_{ij} = A'_{ik} \cup \{z_k\} \cup A_{kj}$ byłby rozwiązaniem dla S_{ij} takim, że $|A'_{ij}| > |A_{ij}|$. Sprzeczność. Analogicznie dla S_{kj} . Zatem A_{ik} oraz A_{kj} muszą być rozwiązaniami optymalnymi dla odpowiednio S_{ik} i S_{kj} .

Stąd wzór rekurencyjny:

$$\begin{cases} c(i, j) = 0 & \text{dla } i \geq j \\ c(i, j) = \max_{i < k < j} \{c(i, k) + c(k, j) + 1\} \end{cases}$$

Używając tego wzoru rekurencyjnego możemy skonstruować algorytm programowania dynamicznego. Mamy $\mathcal{O}(n^2)$ podproblemów. Dla $j > i$ mamy $j - i - 1$ wartości k do sprawdzenia, czyli rozwiązanie jednego podproblemu zajmie czas liniowy. Otrzymujemy algorytm o złożoności $\mathcal{O}(n^3)$.

Algorytm zachłanny

Lemat 3.4. Niech $z_m \in S_{ij}$ będzie zajęciem takim, że $t_m = \min\{t_k : z_k \in S_{ij}\}$. Wtedy:

1. Istnieje podzbiór o największej liczności składający się z parami zgodnych zajęć zbioru S_{ij} zawierający z_m .
2. $S_{im} = \emptyset$ (zatem po wybraniu z_m do zbioru rozwiązania zostaje co najwyżej 1 niepusty podproblem do rozwiązania – S_{mj}).

Dowód.

Ad 1. Niech A_{ij} będzie podzbiorem o największej liczności składającym się z parami zgodnych zajęć zbioru S_{ij} . Niech z_k będzie zajęciem z A_{ij} o najmniejszym czasie zakończenia. Jeśli $z_k = z_m$, to teza jest udowodniona. Przypuśćmy, że $z_k \neq z_m$ i rozważmy zbiór $A'_{ij} = A_{ij} \setminus \{z_k\} \cup \{z_m\}$. Skoro $t_m \leq t_k$ oraz zajęcia z A_{ij} są parami zgodne, to zajęcia z A'_{ij} również są parami zgodne. Mamy $|A_{ij}| = |A'_{ij}|$, więc A'_{ij} jest rozwiązaniem optymalnym zawierającym z_m .

Ad 2. Przypuśćmy, że nie. Niech $z_k \in S_{im}$. Wtedy $t_i \leq s_k < t_k \leq s_m < t_m \leq s_j$. Zatem $z_k \in S_{ij}$ oraz $t_k < t_m$ – sprzeczność z definicją zajęcia z_m . $\square$

Z lematu wynika, że nie musimy sprawdzać $j - i - 1$ wartości k , możemy wybrać zajęcie o najmniejszym czasie zakończenia $z_m \in S_{ij}$. Żeby rozwiązać podproblem S_{ij} możemy dodać z_m do zbioru rozwiązania a następnie dodać do zbioru rozwiązania rozwiązanie optymalne podproblemu S_{mj} . Zaczynamy z $S = S_{0,n+1}$ i $t_0 = 0$. W pierwszym kroku algorytm wybiera z_1 .

Algorytm 13: Zachłanny wybór zajęć

function GREEDYACTIVITYSELECTOR(s, t) 1: $n \leftarrow \text{length}(s)$ 2: $A \leftarrow \{z_1\}$ 3: $j \leftarrow 1$ 4: for $i \leftarrow 2$ to n do 5: if $s_i \geq t_j$ then 6: $A \leftarrow A \cup \{z_i\}$ 7: $j \leftarrow i$ 8: return A	$\triangleright$ zajęcia są posortowane po czasie zakończeń $\triangleright A$ - zbiór rozwiązań
--	---

Algorytm zachłanny w każdym kroku wybiera zajęcie zgodne ze wszystkimi zajęciami poprzednio wybranymi, o najmniejszym czasie zakończenia, aby zostawić jak najwięcej miejsca dla zajęć

następnych (algorytm zachłanny). Skoro one są posortowane, jeśli $j < k$ i z_k jest zgodne z z_j , to z_k jest też zgodne z z_i dla każdego $1 \leq i < j$.

Analiza poprawności: Algorytm zwraca zbiór parami zgodnych zajęć, bo dodaje do zbioru rozwiązania zajęcie tylko jeśli jest zgodne ze wszystkimi zajęciami dodanymi wcześniej.

Pokażemy przez indukcję po n , że algorytm znajduje rozwiązanie optymalne.

- Dla $n = 1$ oczywiste ✓
- Niech $n > 1$. Z lematu istnieje optymalne rozwiązanie A_1 takie, że $z_1 \in A_1$.
Rozważmy problem dla $S' = \{z_i \in S : s_i \geq t_1\}$. Oczywiście zachodzi $|S'| < |S|$.
Dla każdego $z_j \in A_1 \setminus \{z_1\}$, mamy $z_j \in S'$, bo $s_j \geq t_1$, co wynika z faktu, że A_1 jest rozwiązaniem dla S .
Pokażemy, że $A_1 \setminus \{z_1\}$ jest rozwiązaniem optymalnym dla S' .
Przypuśćmy, że istnieje rozwiązanie B dla S' takie, że $|B| > |A_1 \setminus \{z_1\}|$. Wtedy $\{z_1\} \cup B$ byłoby rozwiązaniem dla S takim, że:

$$|\{z_1\} \cup B| = 1 + |B| > 1 + |A_1 \setminus \{z_1\}| = |A_1|$$

Otrzymujemy sprzeczność, bo A_1 jest z założenia rozwiązaniem optymalnym.

Z założenia indukcyjnego nasz algorytm znajduje rozwiązanie optymalne B' dla S' . Wtedy $|B'| = |A_1 \setminus \{z_1\}| = |A_1| - 1$.

Zbiór $\{z_1\} \cup B'$ jest rozwiązaniem znalezionym przez algorytm dla S i:

$$|\{z_1\} \cup B'| = 1 + |B'| = 1 + |A_1| - 1 = |A_1|$$

Więc $\{z_1\} \cup B'$ jest rozwiązaniem optymalnym.

Złożoność czasowa

- linia 1 – $\mathcal{O}(n)$
- linia 2 – $\mathcal{O}(1)$
- iteracji pętli w linii 3 jest $n - 1$
- wewnątrz pętli zajmuje czas $\mathcal{O}(1)$

Całość zajmuje $\Theta(n)$, jeśli zajęcia są już posortowane po czasie zakończenia. Ostatecznie złożoność algorytmu wynosi (uwzględniając początkowe sortowanie):

$$\mathcal{O}(n \log n) + \Theta(n) = \mathcal{O}(n \log n)$$

Kody Huffmana

Często znaki są reprezentowane przy użyciu 8 bitów (np. ASCII). Skoro częstość znaków się różni, lepiej reprezentować znaki występujące często przy użyciu krótszych ciągów bitów, a znaki występujące rzadko przy użyciu dłuższych ciągów bitów.

częstość = liczba wystąpień

Przykład W pliku jest 58 znaków. Każdy znak jest elementem zbioru $\{a, e, i, s, t, r, n\}$.

		<i>a</i>	<i>e</i>	<i>i</i>	<i>s</i>	<i>t</i>	<i>r</i>	<i>n</i>
	częstość	10	15	12	3	4	13	1
kod 1	stała długość słowa kodowego	000	001	010	011	100	101	110
kod 2	zmienna długość słowa kodowego	001	01	10	00000	0001	11	00001
kod 3	zmienna długość słowa kodowego	001	01	10	00010	0001	11	00001

Jeśli użyjemy kodu o stałej długości słowa kodowego (kod 1) to zakodowany plik ma: $58 \cdot 3 = 174$ bity.

Jeśli użyjemy kodu o zmiennej długości słowa kodowego (kod 2 lub kod 3) to zakodowany plik ma:

$$10 \cdot 3 + 15 \cdot 2 + 12 \cdot 2 + 3 \cdot 5 + 4 \cdot 4 + 13 \cdot 2 + 1 \cdot 5 = 146 \text{ bitów.}$$

Jeśli używamy kodu o zmiennej długości słowa kodowego, to chcemy aby spełniony był warunek: **żadne słowo kodowe nie jest prefixem innego słowa kodowego.**

Takie kody nazywa się kodami prefixowymi (choć powinno być bezprefixowe).

Rozważmy kod 3. Ciąg 0001001 można odkodować na dwa sposoby:

- 00010 01 $\Rightarrow s e$
- 0001 001 $\Rightarrow t a$

Tutaj 0001 jest prefixem 00010, czyli słowo kodowe znaku *t* jest prefixem słowa kodowego znaku *s*.

Reprezentacja drzewowa kodów Słowo kodowe znaku jest ciągiem etykiet krawędzi na ścieżce od korzenia do wierzchołka zaetykietowanego tym znakiem.

Uwaga. Żadne słowo kodowe nie jest prefixem innego słowa kodowego $\iff$ wszystkie znaki są reprezentowane przez liście w reprezentacji drzewowej kodu.

Etykietujemy wierzchołki w następujący sposób: każdy wierzchołek *v* dostaje etykietę będącą sumą wystąpień znaków, które są reprezentowane przez liście poddrzewa ukorzonego w *v*.

Niech *C* będzie alfabetem, $f : C \rightarrow \mathbb{N}_+$, $f(c)$ = częstość znaku $c \in C$.

$d_T(c)$ – głębokość liścia reprezentującego znak $c \in C$ w drzewie *T*


$d_T(c)$ = długość słowa kodowego znaku $c \in C$ w kodzie reprezentowanym przez drzewo *T*

Liczba bitów w zakodowanym pliku (kod reprezentowany przez drzewo *T*) wynosi:

$$B(T) = \sum_{c \in C} f(c) \cdot d_T(c)$$


Kod prefixowy reprezentowany przez drzewo *T* nazywamy optymalnym, jeśli $B(T)$ jest najmniejsze możliwe.

Drzewo ukorzone nazywamy binarnym, jeśli każdy wierzchołek ma co najwyżej dwoje dzieci. Drzewo binarne nazywamy regularnym, jeśli każdy wierzchołek wewnętrzny ma dokładnie dwoje dzieci.



Twierdzenie 3.5. *Drzewo binarne reprezentujące optymalny kod jest regularne.*

Dowód. Niech T będzie drzewem binarnym reprezentującym optymalny kod prefixowy. Przy-
puśćmy, że T nie jest regularne. Wtedy istnieje wierzchołek wewnętrzny v z dokładnie jednym
dzieckiem w . Niech u będzie rodzicem v (jeśli v nie jest korzeniem T).



Niech T' będzie drzewem powstałym z T przez usunięcie v i dodanie krawędzi uw , jeśli v nie
był korzeniem T . T' reprezentuje kod prefixowy i $B(T') < B(T)$ – sprzeczność z optymalnością
 T . $\square$

Algorytm Huffmana

Algorytm konstruuje drzewo reprezentujące optymalny kod prefixowy dla (C, f) . Zaczynamy od
 $|C|$ wierzchołków izolowanych (które staną się liśćmi) i wykonujemy $|C| - 1$ operacji łączenia
zaczynając od najrzadszych znaków (będą miały największą głębokość w drzewie).

Będziemy używać kolejki priorytetowej z kluczem $f(c)$. Kolejkę priorytetową możemy zaimple-
mentować używając kopca binarnego. Wtedy koszty operacji wynoszą:

- INSERT – $\mathcal{O}(\log n)$
- EXTRACT_MIN – $\mathcal{O}(\log n)$
- CREATE – $\mathcal{O}(n)$

gdzie n jest liczbą elementów w kolejce.

Algorytm 14: Algorytm Huffmana

```

function HUFFMAN( $C, f$ )
1:   $n \leftarrow |C|$ 
2:   $Q \leftarrow \text{CREATE}(C, f)$ 
3:  for  $i \leftarrow 1$  to  $n - 1$  do
4:       $z \leftarrow \text{NEW\_NODE}$ 
5:       $x \leftarrow \text{LEFT}(z) \leftarrow \text{EXTRACT\_MIN}(Q)$ 
6:       $y \leftarrow \text{RIGHT}(z) \leftarrow \text{EXTRACT\_MIN}(Q)$ 
7:       $f(z) \leftarrow f(x) + f(y)$ 
8:      INSERT( $Q, z$ )
9:  return EXTRACT_MIN( $Q$ )

```

$\triangleright Q$ - kolejka priorytetowa

Algorytm konstruuje drzewo binarne. z - wierzchołek, *left, right* - dzieci.

Dygresja. Intuicyjnie algorytm działa zachłannie, budując drzewo *od dołu*. Każdy znak $c \in C$ jest na początku osobnym, izolowanym wierzchołkiem; będzie on liściem gotowego drzewa. Kolejka priorytetowa Q przechowuje korzenie wszystkich dotąd zbudowanych poddrzew, uporządkowane wg ich łącznej częstości f (im rzadszy znak, tym wcześniej zostanie wyjęty).

W każdej z $n - 1$ iteracji pętli wykonujemy jeden krok łączenia:

- EXTRACT_MIN(Q) dwukrotnie wybiera dwa korzenie o *najmniejszej* częstości (x oraz y);
- tworzymy nowy wierzchołek z i podpinamy x, y jako jego lewe i prawe dziecko;
- częstość nowego wierzchołka ustalamy jako $f(z) = f(x) + f(y)$, po czym wkładamy z z powrotem do kolejki przez INSERT(Q, z).

Łącząc zawsze dwa najrzadsze poddrzewa, spychamy najrzadsze znaki najgłębiej w drzewie – to one dostaną najdłuższe kody, a znaki częste pozostaną blisko korzenia i otrzymają kody krótkie. Każde łączenie zmniejsza liczbę poddrzew w Q o jeden (dwa wyjęcia, jedno wstawienie), więc po $n - 1$ iteracjach zostaje dokładnie jeden korzeń – całe drzewo kodu, które zwracamy.

Złożoność czasowa

- linia 1 – $\mathcal{O}(1)$
- linia 2 – $\mathcal{O}(n)$
- wewnątrz pętli z linii 3 wykona się $n - 1$ razy:
 - linia 4 – $\mathcal{O}(1)$
 - linie 5, 6 – $\mathcal{O}(\log n)$
 - linia 7 – $\mathcal{O}(1)$
 - linia 8 – $\mathcal{O}(\log n)$

Wewnątrz pętli zajmuje łącznie czas $\mathcal{O}(\log n)$.

$$\mathcal{O}(n) + (n - 1) \cdot \mathcal{O}(\log n) = \mathcal{O}(n \log n)$$

Złożoność czasowa algorytmu wynosi $\mathcal{O}(n \log n)$.


Przykład 3.6 (Konstrukcja drzewa Huffmana).

Zaczynamy ze zbiorem wierzchołków: $(n, 1), (s, 3), (t, 4), (a, 10), (i, 12), (r, 13), (e, 15)$.

1. Łączymy n i s .

Zostają:


$(t, 4), (a, 10), (i, 12), (r, 13), (e, 15)$.



2. Łączymy 4 i t .


Zostają:

$(a, 10), (i, 12), (r, 13), (e, 15)$.




3. Łączymy 8 i a .

Zostają: $(i, 12), (r, 13), (e, 15)$.




4. Łączymy i i r .


Zostaje: $(e, 15)$.



5. Łączymy e i 18.



6. Łączymy 25 i 33.
(ostateczne drzewo kodów)



Odczytany kod z drzewa w kroku 6:

$i \Rightarrow 00$
 $r \Rightarrow 01$
 $e \Rightarrow 10$
 $n \Rightarrow 11000$
 $s \Rightarrow 11001$
 $t \Rightarrow 1101$
 $a \Rightarrow 111$

Dowód optymalności algorytmu Huffmana

Kody prefiksowe $\iff$ regularne drzewa binarne.

C – alfabet, $f : C \rightarrow \mathbb{N}$ funkcja częstości, $d_T(c)$ – głębokość liścia reprezentującego c w drzewie T reprezentującym kod prefiksowy.

$$B(T) = \sum_{c \in C} f(c) \cdot d_T(c) \longleftarrow \min$$

Lemat 3.7. Niech x i y będą najrzadziej występującymi znakami z C . Istnieje optymalny kod prefiksowy, w którym słowa kodowe x i y mają tę samą długość i różnią się tylko na ostatnim bicie.

Dowód. Znajdziemy drzewo reprezentujące optymalny kod prefiksowy, w którym liście reprezentujące x i y mają wspólnego rodzica i mają największą głębokość w drzewie.

Niech T będzie dowolnym drzewem reprezentującym optymalny kod prefiksowy i niech a i b będą dwoma liśćmi o tym samym rodzicu i najmniejszej głębokości w T . Bez straty ogólności możemy przyjąć, że $f(x) \leq f(y)$ i $f(a) \leq f(b)$. $f(x)$ i $f(y)$ są najmniejszymi kluczami, więc $f(x) \leq f(a)$ i $f(y) \leq f(b)$.

Niech T' będzie drzewem powstałym z T przez zamianę liści x i a .

$$\begin{aligned}
 B(T) - B(T') &= \sum_{c \in C} f(c) \cdot d_T(c) - \sum_{c \in C} f(c) \cdot d_{T'}(c) = \\
 &= f(a) \cdot d_T(a) + f(x) \cdot d_T(x) - f(a) \cdot d_{T'}(a) - f(x) \cdot d_{T'}(x) =
 \end{aligned}$$


$$\begin{aligned}
 &= f(a) \cdot d_T(a) + f(x) \cdot d_T(x) - f(a) \cdot d_T(x) - f(x) \cdot d_T(a) = \\
 &= f(a)(d_T(a) - d_T(x)) - f(x)(d_T(a) - d_T(x)) = \\
 &= \underbrace{(f(a) - f(x))}_{\geq 0} \underbrace{(d_T(a) - d_T(x))}_{\geq 0} \geq 0
 \end{aligned}$$

Zatem $B(T) \geq B(T')$, ale $B(T)$ najmniejsze możliwe, więc $B(T') = B(T)$ czyli T' też reprezentuje optymalny kod prefiksowy. Analogicznie zamieniamy miejscami liście y i b i otrzymujemy drzewo T'' reprezentujące optymalny kod prefiksowy, które ma żądane własności. $\square$

Z lematu 3.7 wynika, że można zacząć konstrukcję optymalnego drzewa połączeniem dwóch symboli o najmniejszej częstości. **Zachłanny wybór** – w każdym kroku algorytm łączy dwa wierzchołki o najmniejszych kluczach.

Lemat 3.8. Niech A będzie alfabetem z funkcją częstości $f : A \rightarrow \mathbb{N}$, a $x, y \in A$ — dwoma znakami o najmniejszych częstościach. Zdefiniujmy zredukowany alfabet $A' = (A \setminus \{x, y\}) \cup \{z\}$, gdzie $z \notin A$, z funkcją częstości f' taką, że $f'(c) = f(c)$ dla $c \neq z$ oraz $f'(z) = f(x) + f(y)$.

Jeśli T' jest optymalnym drzewem kodu prefiksowego dla (A', f') , to drzewo T powstałe z T' przez zastąpienie liścia z wewnętrznym węzłem z dziećmi x i y jest optymalnym drzewem kodu prefiksowego dla (A, f) .



Dowód. Dla $c \in A \setminus \{x, y\}$, $d_T(c) = d_{T'}(c)$ a $d_T(x) = d_T(y) = d_{T'}(z) + 1$. Zatem:

$$\begin{aligned}
 B(T) &= \sum_{c \in A} f(c) \cdot d_T(c) = \sum_{c \in A \setminus \{x, y\}} f(c) \cdot d_T(c) + f(x) \cdot d_T(x) + f(y) \cdot d_T(y) = \\
 &= \sum_{c \in A \setminus \{x, y\}} f'(c) \cdot d_{T'}(c) + f(x)(d_{T'}(z) + 1) + f(y)(d_{T'}(z) + 1) = \\
 &= \sum_{c \in A \setminus \{x, y\}} f'(c) \cdot d_{T'}(c) + d_{T'}(z)(f(x) + f(y)) + f(x) + f(y) = \\
 &= \sum_{c \in A' \setminus \{z\}} f'(c) \cdot d_{T'}(c) + d_{T'}(z) \cdot f'(z) + f(x) + f(y) = \\
 &= \sum_{c \in A'} f'(c) \cdot d_{T'}(c) + f(x) + f(y) = B(T') + f(x) + f(y)
 \end{aligned}$$

Stąd $B(T') = B(T) - f(x) - f(y)$.

Przypuśćmy, że T nie reprezentuje optymalnego kodu dla (A, f) . Niech T'' będzie drzewem reprezentującym kod prefiksowy dla (A, f) takim, że $B(T'') < B(T)$. Z lematu 3.7 możemy wybrać T'' tak, aby x i y miały wspólnego rodzica i największą głębokość w T'' . Niech T''' będzie drzewem powstałym z T'' poprzez usunięcie liści x i y , nadanie ich rodzicowi etykiety z z kluczem $f(x) + f(y)$. T''' reprezentuje kod prefiksowy dla (A', f') .

Takim samym obliczeniem jak wcześniej (zamieniając wszystkie T na T'' , T' na T''') pokazujemy, że $B(T''') = B(T'') - f(x) - f(y)$. Mamy:

$$B(T''') = B(T'') - f(x) - f(y) < B(T) - f(x) - f(y) = B(T')$$

Sprzeczność z optymalnością T' dla (A', f') . Zatem T reprezentuje optymalny kod dla (A, f) . $\square$

Twierdzenie 3.9. *Algorytm Huffmana konstruuje drzewo reprezentujące optymalny kod prefiksowy.*

Dowód.

Indukcja po n = liczba symboli w alfabecie C . Dla $n = 1, 2$ teza jest oczywista $\checkmark$. Niech $n > 2$.

Po pierwszej operacji połączenia dostajemy alfabet $C' = (C \setminus \{x, y\}) \cup \{z\}$ i funkcję $f' : C' \rightarrow \mathbb{N}$ taką, że $f'(c) = f(c)$ dla wszystkich $c \in C' \setminus \{z\}$ i $f'(z) = f(x) + f(y)$, gdzie x i y są znakami z C o najmniejszych kluczach. Mamy $|C'| = n - 1$. Z założenia indukcyjnego algorytm znajduje drzewo T' reprezentujące optymalny kod prefiksowy dla (C', f') . Na mocy lematu 3.8, zastąpienie liścia z w T' wierzchołkiem z dziećmi x i y (co właśnie robi algorytm Huffmana) daje drzewo T będące optymalnym kodem prefiksowym dla (C, f) . $\square$

Szeregowanie zadań

Problem 3.10 (Szeregowanie zadań – jeden procesor).

Jak uszeregować zadania tak, aby średni czas ukończenia był jak najmniejszy?

i	zadanie	t_i
1	z_1	15
2	z_2	8
3	z_3	3
4	z_4	10

Przykład 3.11 (Szeregowanie zadań – jeden procesor).

Rozważmy uszeregowanie z_1, z_2, z_3, z_4 :

$$\frac{15 + (15 + 8) + (15 + 8 + 3) + (15 + 8 + 3 + 10)}{4} = \frac{15 + 23 + 26 + 36}{4} = \frac{100}{4} = 25$$

Rozważmy uszeregowanie z_3, z_2, z_4, z_1 :

$$\frac{3 + (3 + 8) + (3 + 8 + 10) + (3 + 8 + 10 + 15)}{4} = \frac{3 + 11 + 21 + 36}{4} = 17\frac{3}{4}$$

Rozwiązanie: Uszereguj zadania od najkrótszego do najdłuższego.

Problem 3.12 (Szeregowanie zadań – 3 procesory).

Mamy 3 procesory. Pytanie jak poprzednio (por. 3.11).

Zadanie	z_1	z_2	z_3	z_4	z_5	z_6	z_7	z_8	z_9
t_i	3	5	6	10	11	14	15	18	20

Przykład 3.13 (Szeregowanie zadań – trzy procesory).

Rozwiązanie: Przydzielaj zadania do pierwszego wolnego procesora w kolejności od najkrótszego do najdłuższego.

	3	5	6	13	16	20	28	34	40
P_1	z_1		z_4			z_7			
P_2	z_2		z_5			z_8			
P_3	z_3		z_6				z_9		

W problemie 3.11 dla uszeregowania $z_{i_1}, z_{i_2}, \dots, z_{i_n}$ suma zakończeń zadań wynosi:

$$\begin{aligned}
 \sum_{j=1}^n \sum_{k=1}^j t_{i_k} &= t_{i_1} + (t_{i_1} + t_{i_2}) + (t_{i_1} + t_{i_2} + t_{i_3}) + \dots + (t_{i_1} + \dots + t_{i_n}) = \\
 &= n \cdot t_{i_1} + (n-1)t_{i_2} + (n-2)t_{i_3} + \dots + 1 \cdot t_{i_n} = \sum_{j=1}^n (n+1-j)t_{i_j}
 \end{aligned}$$

W problemie 3.12 (dla $3 \mid n$) dla uszeregowania $z_{i_1}, z_{i_2}, \dots, z_{i_n}$ suma czasów zakończeń wynosi:

$$\begin{aligned}
 &\underbrace{t_{i_1} + t_{i_2} + t_{i_3}} + \underbrace{(t_{i_1} + t_{i_4}) + (t_{i_2} + t_{i_5}) + (t_{i_3} + t_{i_6})}_{+ \dots + (t_{i_1} + t_{i_4} + \dots + t_{i_{n-2}})} + \underbrace{(t_{i_1} + t_{i_4} + t_{i_7}) + (t_{i_2} + t_{i_5} + t_{i_8}) + (t_{i_3} + t_{i_6} + t_{i_9})}_{+ \dots + (t_{i_2} + t_{i_5} + \dots + t_{i_{n-1}})} + \dots + 1 \cdot (t_{i_{n-2}} + t_{i_{n-1}} + t_{i_n}) = \\
 &= \frac{n}{3}(t_{i_1} + t_{i_2} + t_{i_3}) + \left(\frac{n}{3} - 1\right)(t_{i_4} + t_{i_5} + t_{i_6}) + \left(\frac{n}{3} - 2\right)(t_{i_7} + t_{i_8} + t_{i_9}) + \dots + 1 \cdot (t_{i_{n-2}} + t_{i_{n-1}} + t_{i_n}) = \\
 &= \sum_{j=1}^n \left(\frac{n}{3} - \left\lfloor \frac{j-1}{3} \right\rfloor\right) t_{i_j} = \sum_{j=1}^n \left\lceil \frac{n+1-j}{3} \right\rceil \cdot t_{i_j}
 \end{aligned}$$

Lemat 3.14. Niech $A_1 \geq A_2 \geq \dots \geq A_n$. Dla dowolnej permutacji $\Pi = (i_1, \dots, i_n)$ zbioru $[n]$ niech $f(\Pi) = \sum_{j=1}^n A_j \cdot t_{i_j}$. Wtedy f osiąga minimum na każdej permutacji ustawiającej czasy niemalejąco, tzn. takiej, że $t_{i_1} \leq t_{i_2} \leq \dots \leq t_{i_n}$.

Dygresja. Współczynniki $A_1 \geq \dots \geq A_n$ są ustalone i zadane malejąco — są to wagi pozycji. Permutacja Π decyduje, który czas t_{i_j} trafi na pozycję j (o wadze A_j). Lemat to przypadek nierówności o przestawieniach: aby zminimalizować $\sum_j A_j t_{i_j}$, największą wagę łączymy z najmniejszym czasem, czyli ustawiamy czasy rosnąco względem malejących wag.

Dla naszych problemów współczynnikiem przy t_{i_j} jest $n+1-j$ (str. wcześniej) lub $\left\lceil \frac{n+1-j}{3} \right\rceil$ — oba maleją z j , więc odgrywają rolę A_j . Stąd minimalizacja sumy czasów zakończeń sprowadza się do szeregowania zadań od najkrótszego. „Każda” permutacja w tezie — bo przy remisach czasów istnieje kilka równie optymalnych uporządkowań.

Dowód. Niech $\Pi = (i_1, \dots, i_n)$ będzie permutacją minimalizującą f . Przypuśćmy, że dla pewnych $k, l \in [n]$, $k < l$ ale $t_{i_k} > t_{i_l}$. Niech $\Pi' = (i'_1, i'_2, \dots, i'_n)$ będzie permutacją powstałą z Π poprzez zamianę i_k z i_l , tzn.

$$\begin{cases} i'_k = i_l, & i'_l = i_k & (\text{zamieniane pozycje}) \\ i'_j = i_j & & \text{dla } j \in [n] \setminus \{k, l\} \end{cases}. \text{ Wtedy:}$$

$$\begin{aligned} f(\Pi) - f(\Pi') &= \sum_{j=1}^n A_j \cdot t_{i_j} - \sum_{j=1}^n A_j \cdot t_{i'_j} = \\ &= A_k \cdot t_{i_k} + A_l \cdot t_{i_l} - A_k \cdot t_{i'_k} - A_l \cdot t_{i'_l} = \\ &= A_k \cdot t_{i_k} + A_l \cdot t_{i_l} - A_k \cdot t_{i_l} - A_l \cdot t_{i_k} = \\ &= A_k(t_{i_k} - t_{i_l}) - A_l(t_{i_k} - t_{i_l}) = \\ &= \underbrace{(t_{i_k} - t_{i_l})}_{>0} \cdot \underbrace{(A_k - A_l)}_{\geq 0} \geq 0 \end{aligned}$$

Zatem $f(\Pi') \leq f(\Pi)$, ale Π minimalizuje f , więc $f(\Pi') = f(\Pi)$ i Π' też minimalizuje f . Po pewnej liczbie takich zamian otrzymujemy permutację $\Pi_0 = (j_1, \dots, j_n)$ minimalizującą f taką, że $t_{j_1} \leq t_{j_2} \leq \dots \leq t_{j_n}$. $\square$

Wniosek 3.15. *Nasze algorytmy szeregowania zadań są poprawne.*

Matroidy

Definicja 3.16. Matroid to para $M = (S, \mathcal{A})$ taka, że:

1. S – niepusty zbiór skończony,
2. $\mathcal{A} \subseteq 2^S$ i $\mathcal{A} \neq \emptyset$ – czyli $\mathcal{A}$ to niepusta rodzina podzbiorów S ,
3. $\forall A, B \subseteq S \quad A \in \mathcal{A} \wedge B \subseteq A \implies B \in \mathcal{A}$,
4. własność wymiany:

$$\forall A, B \subseteq S \quad A, B \in \mathcal{A} \wedge |B| > |A| \implies \text{istnieje } x \in B \setminus A \text{ taki, że } A \cup \{x\} \in \mathcal{A}.$$

$\mathcal{A}$ – rodzina zbiorów niezależnych matroidu M , elementy $\mathcal{A}$ – zbiory niezależne matroidu M .

Przykład 3.17.

1. A – macierz, S – zbiór wierszy A , $\mathcal{A} = \{R \subseteq S : R \text{ tworzy zbiór liniowo niezależny}\}$.
Wtedy $(S, \mathcal{A})$ to matroid.
2. $G = (V, E)$ – graf, $\mathcal{A} = \{F \subseteq E : G[F] \text{ jest acykliczny}\}$.
Wtedy $(E, \mathcal{A})$ to matroid zwany matroidem grafowym.

Z definicji $\emptyset \in \mathcal{A}$.

Lemat 3.18. Niech $M = (S, \mathcal{A})$. Wszystkie maksymalne zbiory niezależne M mają tę samą licznosc.

Dowód. Niech $A, B \in \mathcal{A}$ będą maksymalnymi zbiorami niezależnymi M . Przypuśćmy, że $|B| > |A|$.

Z własności 4. istnieje $x \in B \setminus A$ taki, że $A \cup \{x\} \in \mathcal{A}$ – sprzeczność z maksymalnością A . $\square$

Problem 3.19. $M = (S, \mathcal{A})$ – matroid, $w : S \rightarrow \mathbb{R}_+$ – funkcja wagi.

Dla $A \subseteq S$ niech $w(A) = \sum_{x \in A} w(x)$ – waga A .

Znaleźć zbiór niezależny o maksymalnej wadze w M .

$S = \{x_1, x_2, \dots, x_n\}$.

Algorytm 15: Algorytm Greedy

```

function GREEDY( $M, w$ )
1:   $n \leftarrow |S|$ 
2:   $A \leftarrow \emptyset$   $\triangleright A$  – rozwiązanie
3:  posortuj  $S$  w porządku nierosnącym względem wagi, tak żeby  $w(x_1) \geq w(x_2) \geq \dots \geq w(x_n)$ 
4:  for  $i \leftarrow 1$  to  $n$  do
5:    if  $A \cup \{x_i\} \in \mathcal{A}$  then
6:       $A \leftarrow A \cup \{x_i\}$ 
7:  return  $A$ 
    
```

Twierdzenie 3.20 (Rado, Edmonds).

Algorytm Greedy znajduje zbiór niezależny o maksymalnej wadze.

Dowód. Niech $A = \{x_{i_1}, x_{i_2}, \dots, x_{i_k}\}$ będzie zbiorem zwróconym przez algorytm i $w(x_{i_1}) \geq w(x_{i_2}) \geq \dots \geq w(x_{i_k})$.

Najpierw pokażemy, że A jest maksymalnym zbiorem niezależnym.

Przypuśćmy, że istnieje $x_j \in S \setminus A$ taki, że $A \cup \{x_j\} \in \mathcal{A}$. Wtedy $j < i_k$, bo w przeciwnym wypadku algorytm dodałby x_j do A jako $(k+1)$ -szy element.

Niech l będzie najmniejszą liczbą taką, że $j < i_l$. Wtedy $w(x_{i_1}) \geq w(x_{i_2}) \geq \dots \geq w(x_{i_{l-1}}) \geq w(x_j) \geq w(x_{i_l})$.

$A \cup \{x_j\} \in \mathcal{A}$, więc z własności 3. $\{x_{i_1}, x_{i_2}, \dots, x_{i_{l-1}}, x_j\} \subseteq A \cup \{x_j\}$ jest zbiorem niezależnym.

Ale wtedy algorytm dodałby x_j zamiast x_{i_l} jako l -ty element dodany do A – sprzeczność.

Zatem A jest maksymalnym zbiorem niezależnym.

Rozważmy zbiór niezależny $B = \{y_1, y_2, \dots, y_m\} \in \mathcal{A}$ i załóżmy, że $w(y_1) \geq w(y_2) \geq \dots \geq w(y_m)$.

Mamy $m \leq k$, bo A jest maksymalnym zbiorem niezależnym (Lemat 3.18).

Pokażemy, że $w(B) \leq w(A)$.

Pokażemy, że dla każdego $j \leq m$ $w(y_j) \leq w(x_{i_j})$.

Przypuśćmy, że $w(y_j) > w(x_{i_j})$.

Rozważmy zbiory niezależne $A_{j-1} = \{x_{i_1}, \dots, x_{i_{j-1}}\} \subseteq A$, $B_j = \{y_1, \dots, y_j\} \subseteq B$.

$|B_j| = j > |A_{j-1}| = j-1$, więc z własności 4. istnieje $y_s \in B_j \setminus A_{j-1}$ taki, że $A_{j-1} \cup \{y_s\} \in \mathcal{A}$.

Mamy $w(y_s) \geq w(y_j) > w(x_{i_j})$, więc istnieje $t \leq j$ takie, że $w(x_{i_1}) \geq w(x_{i_2}) \geq \dots \geq w(x_{i_{t-1}}) \geq w(y_s) > w(x_{i_t})$.

Z własności 3. $\{x_{i_1}, x_{i_2}, \dots, x_{i_{t-1}}, y_s\} \subseteq A_{j-1} \cup \{y_s\}$ jest zbiorem niezależnym.

Ale wtedy algorytm dodałby y_s zamiast x_{i_t} jako t -ty element dodany do A – sprzeczność.

$$\text{Zatem } \left. \begin{array}{l} w(y_1) \leq w(x_{i_1}) \\ w(y_2) \leq w(x_{i_2}) \\ \vdots \\ w(y_m) \leq w(x_{i_m}) \end{array} \right\} \Rightarrow w(B) = w(y_1) + \dots + w(y_m) \leq w(x_{i_1}) + \dots + w(x_{i_m}) \leq w(A). \quad \square$$

Złożoność czasowa algorytmu Greedy $n = |S|$

- linia 1: $\mathcal{O}(1)$
- linia 2: $\mathcal{O}(1)$
- linia 3: $\mathcal{O}(n \log n)$
- liczba iteracji pętli z linii 4 wynosi n
- linia 5: $f(n)$ – czas sprawdzenia warunku z linii 5
- linia 6: $\mathcal{O}(1)$
- linia 7: $\mathcal{O}(1)$

Problem szeregowania zadań

- $S = \{z_1, z_2, \dots, z_n\}$ – zbiór zadań o jednostkowym czasie wykonania
- $d_1, d_2, \dots, d_n$ – deadlines, $d_i \in \{1, \dots, n\}$ dla $i \in [n]$
- $w_1, w_2, \dots, w_n$ – kary, $w_i \geq 0$ dla $i \in [n]$

Płacimy karę w_i za zadanie z_i , jeżeli nie jest skończone w momencie d_i .

Problem 3.21 (szeregowania zadań z karami).

Znaleźć kolejność wykonania zadań minimalizującą sumę kar.

Założmy, że mamy pewien harmonogram. Zadanie z_i nazywamy terminowym w tym harmonogramie, jeśli jest zakończone do chwili d_i , w przeciwnym razie nazywamy je spóźnionym.

Nie płacimy kar za zadania terminowe, płacimy kary za zadania spóźnione.

Lemat 3.22. *Każdy harmonogram można przetransformować na harmonogram z taką samą sumą kar, w którym wszystkie zadania terminowe poprzedzają wszystkie zadania spóźnione oraz zadania terminowe są posortowane w kolejności niemalejącej względem deadline'ów.*

Dowód.

1. Niech z_i będzie zadaniem spóźnionym ukończonym w chwili $l_i > d_i$ i niech z_j będzie zadaniem terminowym ukończonym w chwili $l_j \leq d_j$ i niech z_i będzie przed z_j w harmonogramie, tzn. $l_i < l_j$.

Zamieniamy miejscami z_i i z_j . Po zamianie:

- z_i jest ukończone w chwili $l_j > l_i > d_i$, więc nadal jest spóźnione.
- z_j jest ukończone w chwili $l_i < l_j \leq d_j$, więc nadal jest terminowe.

Po pewnej liczbie takich zamian otrzymujemy harmonogram o tej samej sumie kar, w którym wszystkie zadania terminowe poprzedzają wszystkie zadania spóźnione.

2. Niech z_i, z_j będą zadaniami terminowymi takimi, że z_i jest ukończone w chwili $l_i \leq d_i$, z_j jest ukończone w chwili $l_j \leq d_j$, $l_i < l_j$, ale $d_i > d_j$.

Zamieniamy miejscami z_i i z_j . Po zamianie:

- z_i jest ukończone w chwili $l_j \leq d_j < d_i$, więc z_i jest nadal terminowe.
- z_j jest ukończone w chwili $l_i < l_j \leq d_j$, więc z_j jest nadal terminowe.

Po pewnej liczbie takich zamian otrzymujemy harmonogram spełniający warunki lematu. $\square$

Zbiór $A \subseteq S$ nazywamy wolnym od kar, jeśli istnieje harmonogram zbioru A , w którym wszystkie zadania są terminowe.

Dla $t \in \{0, 1, \dots, n\}$ niech

$$N_t(A) = |\{z_i \in A : d_i \leq t\}|$$

– liczba zadań w A o deadline $\leq t$.

Lemat 3.23. Niech $A \subseteq S$. Następujące warunki są równoważne:

1. A jest wolny od kar.
2. $N_t(A) \leq t$ dla każdego $t \in \{1, 2, \dots, n\}$.
3. Jeśli zadania z A są posortowane w kolejności niemalejącej ze względu na deadline, to żadne zadanie nie jest spóźnione.

Twierdzenie 3.24. Niech S – zbiór zadań o jednostkowym czasie wykonania, a $\mathcal{A}$ – rodzina zbiorów wolnych od kar. Wtedy $(S, \mathcal{A})$ jest matroidem.

Dowód. Sprawdzamy własności z definicji matroidu:

1. Oczywiście. ✓
2. Dla każdego $i \in [n]$ zachodzi $\{z_i\} \in \mathcal{A}$, więc $\mathcal{A} \neq \emptyset$. ✓
3. Niech $A \in \mathcal{A}$, $B \subseteq A$. Istnieje harmonogram zbioru A , w którym wszystkie zadania są terminowe. Harmonogram zbioru B powstały z usunięcia z tego harmonogramu zadań z $A \setminus B$ jest harmonogramem zbioru B , w którym wszystkie zadania są terminowe. Zatem $B \in \mathcal{A}$.
4. Niech $A, B \in \mathcal{A}$, $|B| > |A|$.
Niech $k \in \{0, 1, \dots, n\}$ będzie największą liczbą t taką, że $N_t(B) \leq N_t(A)$.
 k jest dobrze zdefiniowane, bo $N_0(B) = 0 = N_0(A)$.
Mamy $N_n(B) = |B| > |A| = N_n(A)$, więc $k < n$.
Dla $j \in \{k+1, k+2, \dots, n\}$ mamy $N_j(B) > N_j(A)$, więc $N_j(B) \geq N_j(A) + 1$.

$$\left. \begin{array}{l} N_{k+1}(B) > N_{k+1}(A) \\ N_k(B) \leq N_k(A) \end{array} \right\} \implies \text{istnieje zadanie } z \in B \setminus A \text{ o deadline } = k+1$$

Niech $A' = A \cup \{z\}$. Pokażemy, że A' jest wolny od kar, używając lematu 3.23.

- Dla $t \in \{1, 2, \dots, k\}$: $N_t(A') = N_t(A) \leq t$, bo A jest wolny od kar.
- Dla $t \in \{k+1, k+2, \dots, n\}$: $N_t(A') = N_t(A) + 1 \leq N_t(B) \leq t$, bo B jest wolny od kar.

Zatem A' jest wolny od kar.

Pokazaliśmy, że $(S, \mathcal{A})$ jest matroidem. $\square$

Możemy do rozwiązania problemu szeregowania zadań użyć algorytmu Greedy (Algorytm 15) dla matroidu $(S, \mathcal{A})$ maksymalizującego $\sum_{z_i \in A} w_i$ (czyli minimalizującego sumę kar zadań spóźnionych).

Z twierdzenia 3.20 (Rado, Edmonds) algorytm Greedy użyty do tego problemu zwraca rozwiązanie optymalne. Warunek z linii 5 algorytmu Greedy (tzn. czy $A \cup \{x_i\} \in \mathcal{A}$) można sprawdzić w czasie $\mathcal{O}(n)$ – lemat 3.23, warunek 3.

Złożoność czasowa algorytmu wynosi:

$$\mathcal{O}(n \log n + n \cdot n) = \mathcal{O}(n^2)$$

i	1	2	3	4	5	6	7	8
d_i	3	2	2	3	1	4	6	5
w_i	80	70	60	50	40	30	20	10

Przykład 3.25 (Szeregowanie zadań z deadlineami).

Zadania są już posortowane w porządku nierosnącym względem wagi ($w_1 \geq w_2 \geq \dots \geq w_8$). Kolejne iteracje algorytmu Greedy (poniżej A wypisane w kolejności niemalejącej po deadlineach):

1. $A = (z_1)$
2. $A = (z_2, z_1)$
3. $A = (z_2, z_3, z_1)$
4. $A = (z_2, z_3, z_1)$ (z_4 nie dodajemy, bo $N_3(A \cup \{z_4\}) = 4 > 3$)
5. $A = (z_2, z_3, z_1)$ (z_5 nie dodajemy, bo $N_2(A \cup \{z_5\}) = 3 > 2$)
6. $A = (z_2, z_3, z_1, z_6)$
7. $A = (z_2, z_3, z_1, z_6, z_7)$
8. $A = (z_2, z_3, z_1, z_6, z_8, z_7)$

Harmonogram (zadania terminowe posortowane po deadlineach, potem zadania spóźnione):

$(z_2, z_3, z_1, z_6, z_8, z_7, z_4, z_5)$

$$\text{Suma kar} = w_4 + w_5 = 50 + 40 = 90$$

Algorytmy aproksymacyjne

Algorytmy aproksymacyjne stosuje się do problemów, dla których jest mała szansa na znalezienie algorytmu dokładnego (np. wielomianowego). Zamiast szukać rozwiązania optymalnego, szukamy rozwiązania „prawie optymalnego”.

Niech Π – problem optymalizacyjny znalezienia maksimum lub minimum pewnej funkcji celu f .

- D_Π – zbiór instancji problemu Π .
- $I \in D_\Pi$ – instancja Π .
- $S(I)$ – zbiór rozwiązań dopuszczalnych dla instancji I .
- $f : \bigcup_{I \in D_\Pi} S(I) \rightarrow \mathbb{R}$ – funkcja celu. Możemy założyć, że

$$\forall I \in D_\Pi \forall s \in S(I) f(s) > 0$$

Niech $c^*(I)$ oznacza wartość rozwiązania optymalnego instancji I , $c^*(I) > 0$.

A – algorytm aproksymacyjny rozwiązujący Π .

$c(I)$ – wartość rozwiązania znalezionej przez algorytm A dla instancji I , $c(I) > 0$.

Definicja 4.1. Mówimy, że algorytm A ma współczynnik aproksymacji $\rho(n)$, jeśli dla każdej instancji $I \in D_{\Pi}$ rozmiaru n zachodzi

$$\max \left\{ \frac{c(I)}{c^*(I)}, \frac{c^*(I)}{c(I)} \right\} \leq \rho(n)$$

Wtedy A nazywamy algorytmem $\rho(n)$ -aproksymacyjnym.

Zauważmy, że:

$$\left. \begin{array}{l} \text{dla problemu maksymalizacji: } 0 < c(I) \leq c^*(I) \\ \text{dla problemu minimalizacji: } 0 < c^*(I) \leq c(I) \end{array} \right\} \Rightarrow \max \left\{ \frac{c(I)}{c^*(I)}, \frac{c^*(I)}{c(I)} \right\} \geq 1$$


Niech $\rho = \sup_{n \in \mathbb{N}} \{\rho(n)\}$. Wtedy mówimy, że współczynnik aproksymacji algorytmu A wynosi ρ i A nazywamy algorytmem ρ -aproksymacyjnym.

Problem pokrycia wierzchołkowego

Definicja 4.2. Niech $G = (V, E)$ – graf. Pokryciem wierzchołkowym (Vertex Cover, VC) grafu G nazywamy zbiór $W \subseteq V$ taki, że dla każdej krawędzi $e \in E$ zachodzi $W \cap e \neq \emptyset$ – czyli każda krawędź G ma co najmniej jeden koniec w W .

Problem 4.3 (pokrycia wierzchołkowego). • Instancja: graf G .

- Problem: znaleźć pokrycie wierzchołkowe grafu G o minimalnej liczbie wierzchołków.



Przykład 4.4 (Pokrycie wierzchołkowe).

$W = \{a, e, d, f\}$ jest pokryciem wierzchołkowym powyższego grafu G (zaznaczone wyróżnione wierzchołki).

Algorytm Approx Vertex Cover

Algorytm 16: Approx Vertex Cover

```

function AVC( $G$ )
1:   $C \leftarrow \emptyset$ 
2:   $F \leftarrow E(G)$ 
3:  while  $F \neq \emptyset$  do
4:    wybierz dowolną krawędź  $uv \in F$ 
5:     $C \leftarrow C \cup \{u, v\}$ 
6:    usuń z  $F$  wszystkie krawędzie incydentne z  $u$  lub z  $v$ 
7:  return  $C$ 
    
```

▷ C – rozwiązanie
▷ F – zbiór dotychczas niepokrytych krawędzi

Przykład 4.5 (Algorytm AVC – przykład).

Rozważmy graf z poprzedniego przykładu.

Pierwszy przebieg algorytmu może wybrać kolejno krawędzie ab i cd :

- Po wybraniu ab usuwamy z F krawędzie ab, ac, ae, bd, be , zostają cd, de, df .
- Po wybraniu cd usuwamy z F krawędzie cd, de, df – $F = \emptyset$.

Algorytm zwraca $C = \{a, b, c, d\}$.

Inny przebieg algorytmu może wybrać kolejno krawędzie df , be i ac :

- Po wybraniu df usuwamy z F krawędzie df, de, bd, cd .
- Po wybraniu be usuwamy z F krawędzie be, ae, ab .
- Po wybraniu ac usuwamy ostatnią krawędź ac – $F = \emptyset$.

Algorytm zwraca $C = \{d, f, e, b, a, c\}$.

Złożoność czasowa algorytmu AVC $n = |V(G)|$, $m = |E(G)|$.

- linia 1: $\mathcal{O}(1)$
- linia 2: $\mathcal{O}(m)$
- pętlę z linii 3–6 można zaimplementować, żeby działała w czasie $\mathcal{O}(m)$
- linia 7: $\mathcal{O}(1)$

Złożoność czasowa AVC wynosi $\mathcal{O}(m)$.

Twierdzenie 4.6. *AVC jest algorytmem 2-aproksymacyjnym.*

Dowód. Niech G – graf wejściowy.

$c^*(G)$ – najmniejsza liczba wierzchołków w pokryciu wierzchołkowym G .

$c(G)$ – liczba wierzchołków w pokryciu wierzchołkowym znalezionym przez AVC.

Niech B będzie zbiorem krawędzi wybranych przez AVC w linii 4.

B jest skojarzeniem (czyli zbiorem parami rozłącznych krawędzi), bo po wybraniu krawędzi uv algorytm usuwa z F wszystkie krawędzie incydentne z u lub v .


Żeby pokryć krawędzie z B potrzeba co najmniej $|B|$ wierzchołków. Stąd $c^*(G) \geq |B|$.

$c(G) = 2|B|$, bo algorytm dodaje do C oba końce każdej krawędzi z B .

$$c(G) = 2|B| \leq 2 \cdot c^*(G) \implies \frac{c(G)}{c^*(G)} \leq 2$$

□

Pokażemy, że ograniczenie 2 jest osiągnięte. Rozważmy graf złożony z m rozłącznych krawędzi:




AVC zwraca pokrycie złożone z $2m$ wierzchołków, natomiast optymalne pokrycie ma rozmiar m (po jednym końcu z każdej krawędzi). Stąd $\frac{c(G)}{c^*(G)} = 2$.

Problem pokrycia zbioru

Definicja 4.7. Niech X – zbiór skończony, $|X| = n$, $\mathcal{F} \subseteq 2^X$ – rodzina podzbiorów zbioru X taka, że $\bigcup_{S \in \mathcal{F}} S = X$ (każdy element X należy do co najmniej jednego zbioru z $\mathcal{F}$).

Rodzina $\mathcal{A} \subseteq \mathcal{F}$ jest pokryciem zbioru X , jeśli $\bigcup_{S \in \mathcal{A}} S = X$.



Przykład 4.8 (Pokrycie zbioru).

$\mathcal{F} = \{S_1, S_2, S_3, S_4, S_5, S_6\}$. $\{S_1, S_2, S_3\}$ – pokrycie.

Problem 4.9 (pokrycia zbioru). • Instancja: $(X, \mathcal{F})$, gdzie X – zbiór skończony, $|X| = n$, $\mathcal{F} \subseteq 2^X$ taki, że $\bigcup_{S \in \mathcal{F}} S = X$.
• Problem: znaleźć pokrycie $\mathcal{A} \subseteq \mathcal{F}$ minimalizujące $|\mathcal{A}|$.

Uwaga. VC jest szczególnym przypadkiem problemu pokrycia zbiorów. Dla $G = (V, E)$ kładziemy $X = E$, $\mathcal{F} = \{E(v) : v \in V\}$, gdzie $E(v) = \{e \in E : v \in e\}$.

Algorytm Greedy Set Cover

Algorytm 17: Greedy Set Cover

```

function GSC( $X, \mathcal{F}$ )
1:   $U \leftarrow X$ 
2:   $\mathcal{A} \leftarrow \emptyset$ 
3:  while  $U \neq \emptyset$  do
4:    wybierz  $S \in \mathcal{F}$  maksymalizujący  $|S \cap U|$ 
5:     $\mathcal{A} \leftarrow \mathcal{A} \cup \{S\}$ 
6:     $U \leftarrow U \setminus S$ 
7:  return  $\mathcal{A}$ 
    
```

▷ U – zbiór jeszcze niepokrytych elementów
▷ $\mathcal{A}$ – rozwiązanie

Poprawność Pętla obraca się dopóki są jeszcze niepokryte elementy, a w każdym obrocie pętli jakieś jeszcze niepokryte elementy zostają pokryte.

Złożoność czasowa

- linia 1: $\mathcal{O}(n)$
- linia 2: $\mathcal{O}(1)$
- liczba iteracji pętli 3–6 jest $\leq |X|$ i $\leq |\mathcal{F}|$, więc jest $\leq \min\{|X|, |\mathcal{F}|\}$. Wnętrze pętli:

- linia 4: $\mathcal{O}(|X| \cdot |\mathcal{F}|)$
- linia 5: $\mathcal{O}(1)$
- linia 6: $\mathcal{O}(|X|)$
- łącznie $\mathcal{O}(|X| \cdot |\mathcal{F}|)$.
- linia 7: $\mathcal{O}(1)$

Ostatecznie złożoność GSC wynosi $\mathcal{O}(|X| \cdot |\mathcal{F}| \cdot \min\{|X|, |\mathcal{F}|\})$.

Twierdzenie 4.10. *GSC jest algorytmem $H(\max\{|S| : S \in \mathcal{F}\})$ -aproxymacyjnym, gdzie*

$$H(0) = 0, \quad H(m) = 1 + \frac{1}{2} + \frac{1}{3} + \dots + \frac{1}{m} \text{ dla } m \geq 1$$

Dowód. Niech $(X, \mathcal{F})$ będzie instancją wejściową.

$\mathcal{A}^*$ – optymalne pokrycie dla $(X, \mathcal{F})$.

$\mathcal{A}$ – pokrycie dla $(X, \mathcal{F})$ znalezione przez GSC.

Niech S_i będzie zbiorem wybranym przez algorytm w linii 4 w i -tej iteracji pętli. Przyznajemy koszt

$$c_x = \frac{1}{|S_i \setminus (S_1 \cup S_2 \cup \dots \cup S_{i-1})|}$$

każdemu elementowi $x \in S_i \setminus (S_1 \cup \dots \cup S_{i-1})$ ($S_i \setminus (S_1 \cup \dots \cup S_{i-1})$ to zbiór elementów pokrytych po raz pierwszy w i -tej iteracji pętli). Całkowity koszt przyznany podczas jednej iteracji pętli wynosi 1. Skoro $|\mathcal{A}|$ jest liczbą iteracji pętli, to

$$|\mathcal{A}| = \sum_{x \in X} c_x$$

Rozważmy sumę $\sum_{S \in \mathcal{A}^*} \sum_{x \in S} c_x$. Skoro $\mathcal{A}^*$ jest pokryciem, każdy $x \in X$ występuje w tej sumie co najmniej raz, więc

$$\sum_{S \in \mathcal{A}^*} \sum_{x \in S} c_x \geq \sum_{x \in X} c_x = |\mathcal{A}|$$

Pokażemy, że $\sum_{x \in S} c_x \leq H(|S|)$ dla każdego $S \in \mathcal{F}$.

Niech $S \in \mathcal{F}$. Dla $i \in \{1, 2, \dots, |\mathcal{A}|\}$ niech $n_i = |S \setminus (S_1 \cup \dots \cup S_i)|$ (liczba elementów w S , które nie są pokryte po i -tej iteracji pętli) i niech $n_0 = |S|$.

Niech k będzie najmniejszą liczbą taką, że $n_k = 0$. Wtedy S jest pokryty przez $S_1 \cup S_2 \cup \dots \cup S_k$. Oczywiście $n_{i-1} \geq n_i$ dla $i \in [k]$, a $n_{i-1} - n_i$ to liczba elementów z S pokrytych po raz pierwszy przez S_i .

Zatem

$$\sum_{x \in S} c_x = \sum_{i=1}^k (n_{i-1} - n_i) \cdot \frac{1}{|S_i \setminus (S_1 \cup \dots \cup S_{i-1})|}$$

Na podstawie wyboru zachłannego w linii 4 mamy $|S_i \setminus (S_1 \cup \dots \cup S_{i-1})| \geq |S \setminus (S_1 \cup \dots \cup S_{i-1})| = n_{i-1}$ dla każdego $S \in \mathcal{F} \setminus \{S_1, \dots, S_{i-1}\}$.

Mamy:

$$\sum_{x \in S} c_x = \sum_{i=1}^k (n_{i-1} - n_i) \cdot \frac{1}{|S_i \setminus (S_1 \cup \dots \cup S_{i-1})|} \leq \sum_{i=1}^k (n_{i-1} - n_i) \cdot \frac{1}{n_{i-1}}$$

$$\begin{aligned}
 &= \sum_{i=1}^k \sum_{j=n_i+1}^{n_{i-1}} \frac{1}{n_{i-1}} \leq \sum_{i=1}^k \sum_{j=n_i+1}^{n_{i-1}} \frac{1}{j} = \sum_{i=1}^k \left(\sum_{j=1}^{n_{i-1}} \frac{1}{j} - \sum_{j=1}^{n_i} \frac{1}{j} \right) \\
 &= \sum_{i=1}^k (H(n_{i-1}) - H(n_i)) \\
 &= (H(n_0) - H(n_1)) + (H(n_1) - H(n_2)) + \dots + (H(n_{k-1}) - H(n_k)) \\
 &= H(n_0) - H(n_k) = H(|S|) - H(0) = H(|S|).
 \end{aligned}$$

Ostatecznie mamy:

$$\begin{aligned}
 |\mathcal{A}| &= \sum_{x \in X} c_x \leq \sum_{S \in \mathcal{A}^*} \sum_{x \in S} c_x \leq \sum_{S \in \mathcal{A}^*} H(|S|) \leq \sum_{S \in \mathcal{A}^*} \max\{H(|S|) : S \in \mathcal{A}^*\} \\
 &= |\mathcal{A}^*| \cdot \max\{H(|S|) : S \in \mathcal{A}^*\} \\
 &\leq |\mathcal{A}^*| \cdot \max\{H(|S|) : S \in \mathcal{F}\} = |\mathcal{A}^*| \cdot H(\max\{|S| : S \in \mathcal{F}\}),
 \end{aligned}$$

więc $\frac{|\mathcal{A}|}{|\mathcal{A}^*|} \leq H(\max\{|S| : S \in \mathcal{F}\})$. □

Wniosek 4.11. *GSC jest algorytmem $(\ln |X| + 1)$ -aproksymacyjnym.*

Dowód. $H(n) \leq \ln n + 1$, więc

$$H(\max\{|S| : S \in \mathcal{F}\}) \leq H(|X|) \leq \ln |X| + 1$$

□

VC jest szczególnym przypadkiem problemu pokrycia zbiorów. Dla $G = (V, E)$ kładziemy $X = E$, $\mathcal{F} = \{E(v) : v \in V\}$, gdzie $E(v) = \{e \in E : v \in e\}$, $|E(v)| = d(v)$. Wtedy $\max\{|E(v)| : E(v) \in \mathcal{F}\} = \Delta(G)$, więc GSC zastosowany do VC ma współczynnik aproksymacji $H(\Delta(G))$.

Dla grafów o maksymalnym stopniu ≤ 3 ($H(3) < 2 < H(4)$) oszacowanie współczynnika aproksymacyjnego GSC jest lepsze niż oszacowanie dla AVC.

Schematy aproksymacyjne

Niech Π – problem (NP-trudny).

Definicja 4.12. Algorytm A jest schematem aproksymacyjnym dla Π , jeśli dla dowolnego wejścia (I, ϵ) , gdzie I jest instancją Π i $\epsilon > 0$, A jest algorytmem $(1 + \epsilon)$ -aproksymacyjnym.

Definicja 4.13. Schemat aproksymacyjny A nazywamy wielomianowym schematem aproksymacyjnym, jeśli jego złożoność czasowa może być ograniczona wielomianową funkcją względem $|I|$ dla każdego ustalonego $\epsilon > 0$.

Złożoność czasowa wielomianowego schematu aproksymacyjnego może wynosić np. $\Theta(2^{1/\epsilon} \cdot n^2)$, gdzie $n = |I|$. Wtedy zmniejszanie precyzji (czyli zmniejszanie ϵ) jest kosztowne czasowo.

Definicja 4.14. Schemat aproksymacyjny A nazywamy w pełni wielomianowym schematem aproksymacyjnym, jeśli jego złożoność czasowa może być ograniczona funkcją wielomianową względem $|I|$ i $\frac{1}{\epsilon}$.

Problem sumy podzbiorów

Problem 4.15 (sumy podzbiorów (Subset-Sum)).

$S = \{x_1, x_2, \dots, x_n\} \subseteq \mathbb{N}$, $t \in \mathbb{N}$.

Wersja decyzyjna

- Instancja: (S, t) .
- Problem: czy istnieje $S' \subseteq S$ takie, że $\sum_{x_i \in S'} x_i = t$?

Wersja optymalizacyjna

- Instancja: (S, t) .
- Problem: znaleźć $S' \subseteq S$ takie, że $\sum_{x_i \in S'} x_i$ jest największą możliwą liczbą $\leq t$.

Dla zbioru $P \subseteq \mathbb{N}$ i $x \in \mathbb{N}$ oznaczamy $P + x = \{s + x : s \in P\}$.

np. dla $P = \{1, 2, 3, 6\}$ i $x = 2$: $P + x = \{3, 4, 5, 8\}$.

Dla listy L liczb naturalnych i $x \in \mathbb{N}$ przez $L + x$ oznaczamy listę powstałą z L przez dodanie x do każdego elementu.

np. $L = (3, 5, 8)$ i $x = 3$: $L + x = (6, 8, 11)$.

Lemat 4.16. Niech $S = \{x_1, \dots, x_n\} \subseteq \mathbb{N}$. Niech $P_0 = \{0\}$ i $P_i = P_{i-1} \cup (P_{i-1} + x_i)$ dla $i \in [n]$. Zbiór P_n składa się ze wszystkich możliwych sum podzbiorów zbioru S .

Dowód. Pokażemy przez indukcję po i , że zbiór P_i składa się ze wszystkich możliwych sum elementów ze zbioru $\{x_1, x_2, \dots, x_i\}$.

$i = 0$: $P_0 = \{0\}$ i $\sum_{x_i \in \emptyset} x_i = 0$. ✓

Założmy, że P_{i-1} składa się ze wszystkich możliwych sum elementów z $\{x_1, \dots, x_{i-1}\}$.

Niech $S' \subseteq \{x_1, \dots, x_i\}$.

- Jeśli $x_i \notin S'$, to $S' \subseteq \{x_1, \dots, x_{i-1}\}$, więc $\sum_{x_k \in S'} x_k \in P_{i-1} \subseteq P_i$.
- Jeśli $x_i \in S'$, to $S' \setminus \{x_i\} \subseteq \{x_1, \dots, x_{i-1}\}$, więc

$$\sum_{x_k \in S'} x_k = \sum_{x_k \in S' \setminus \{x_i\}} x_k + x_i \in P_{i-1} + x_i \subseteq P_i$$

Zatem P_i zawiera wszystkie możliwe sumy elementów z $\{x_1, \dots, x_i\}$.

P_i nie zawiera innych elementów, bo P_{i-1} składa się z sum elementów z $\{x_1, \dots, x_{i-1}\}$ a $P_{i-1} + x_i$ zawiera tylko sumy elementów z $\{x_1, \dots, x_{i-1}, x_i\} \subseteq \{x_1, \dots, x_i\}$.

Dla $i = n$ mamy tezę. □

Założmy, że mamy procedurę MERGELists(L, L'), która dla posortowanych list liczb naturalnych L, L' zwraca posortowaną listę elementów z L i L' i usuwa duplikaty. Złożoność czasowa MERGELists(L, L') wynosi $\Theta(|L| + |L'|)$.

Algorytm 18: Exact Subset Sum

```

function EXACTSUBSETSUM( $\mathcal{S}, t$ )
1:   $n \leftarrow |\mathcal{S}|$ 
2:   $L_0 \leftarrow (0)$ 
3:  for  $i \leftarrow 1$  to  $n$  do
4:     $L_i \leftarrow \text{MERGE}(\text{LISTS}(L_{i-1}, L_{i-1} + x_i))$ 
5:    usuń z  $L_i$  wszystkie liczby  $> t$ 
6:  return największy element  $L_n$ 

```

Poprawność wyniku z lematu 4.16.

Złożoność czasowa Długość listy L_i może być wykładnicza względem i , nawet 2^i . Dla $I = (S, t)$:

$$|I| = \Theta\left(\log t + \sum_{i=1}^n \log x_i\right)$$

Jeśli liczby t i x_i są n -cyfrowe, to $\log t, \log x_i = \Theta(n)$ i wtedy $|I| = \Theta(n + n^2) = \Theta(n^2)$. Skoro L_n może mieć długość 2^n , to ExactSubsetSum jest algorytmem wykładniczym.

Jeśli liczba t jest ograniczona przez funkcję wielomianową od $n = |S|$, czyli $t = \mathcal{O}(n^p)$ dla jakiegoś $p \in \mathbb{N}$, to długość L_i jest ograniczona przez $\mathcal{O}(t) = \mathcal{O}(n^p)$ i w tym przypadku algorytm działa w czasie wielomianowym.

Schemat aproksymacyjny Pokażemy w pełni wielomianowy schemat aproksymacyjny dla tego problemu.

Pomysł: będziemy skracać listy L_i . Dla $0 < \delta < 1$ z listy L robimy krótszą listę L' taką, że dla każdego elementu y usuniętego z L istnieje element z w L' , który jest blisko niego, dokładnie $\frac{y}{1+\delta} \leq z \leq y$.

Przykład 4.17 (Procedura Trim).

$L = (15, 16, 17, 25, 27, 28, 35, 36, 37)$, $\delta = 0,1$.

$L' = (15, 17, 25, 28, 35)$.

Następująca procedura TRIM(L, δ) realizuje ten pomysł.

$L = (y_1, \dots, y_m)$ – posortowana rosnąco lista, $0 < \delta < 1$.

Algorytm 19: Trim

```

function TRIM( $L, \delta$ )
1:   $m \leftarrow |L|$ 
2:   $L' \leftarrow (y_1)$ 
3:   $last \leftarrow y_1$ 
4:  for  $i \leftarrow 2$  to  $m$  do
5:    if  $y_i > last \cdot (1 + \delta)$  then
6:      dołącz  $y_i$  na koniec  $L'$ 
7:       $last \leftarrow y_i$ 
8:  return  $L'$ 

```

Czas działania TRIM(L, δ) wynosi $\Theta(|L|)$.

Oto schemat aproksymacyjny:

Algorytm 20: Approx Subset Sum	
function APPROXSUBSETSUM($\mathcal{S}, t, \epsilon$)	
1:	$n \leftarrow \mathcal{S} $
2:	$L_0 \leftarrow (0)$
3:	for $i \leftarrow 1$ to n do
4:	$L_i \leftarrow \text{MERGE}(\text{LISTS}(L_{i-1}, L_{i-1} + x_i))$
5:	usuń z L_i liczby $> t$
6:	$L_i \leftarrow \text{TRIM}(L_i, \frac{\epsilon}{2^n})$
7:	return największy element $z \in L_n$

$\triangleright \delta = \frac{\epsilon}{2^n}$
 $\triangleright z^*$

NP-zupełność problemu sumy podzbiorów

Twierdzenie 4.18. *Problem sumy podzbiorów jest NP-zupełny.*

Dowód. Problem jest w NP. Dla instancji $(\mathcal{S}, t)$ i $\mathcal{S}' \subseteq \mathcal{S}$ można sprawdzić w czasie wielomianowym czy $\sum_{x_i \in \mathcal{S}'} x_i = t$.

Pokażemy redukcję $3\text{-SAT} \leq_p \text{SUBSET-SUM}$.

Φ – formuła 3-SAT w CNF, $x_1, x_2, \dots, x_n$ – zmienne, $C_1, C_2, \dots, C_m$ – klauzule. Załóżmy, że żadna klauzula nie zawiera zmiennej i jej zaprzeczenia (wpp. jest spełniona) oraz każda zmienna występuje w co najmniej jednej klauzuli.

Utworzymy instancję $(\mathcal{S}, t)$ problemu SUBSET-SUM dla Φ .

Dla każdej zmiennej x_i mamy w $\mathcal{S}$ dwie liczby r_i i r'_i , $(n+m)$ -cyfrowe.

Dla każdej klauzuli C_j mamy w $\mathcal{S}$ dwie liczby s_j i s'_j , $(n+m)$ -cyfrowe.

t jest liczbą $(n+m)$ -cyfrową: $\underbrace{11 \dots 1}_n \underbrace{44 \dots 4}_m$.

Pierwsze n cyfr etykietowane jest zmiennymi, ostatnie m cyfr etykietowane jest klauzulami.

- r_i, r'_i mają 1 na pozycji x_i i 0 na innych pozycjach etykietowanych zmiennymi.
- 1 na pozycji C_j : jeśli x_i występuje w C_j to w r_i , jeśli $\bar{x}_i$ to w r'_i .
Na pozostałych pozycjach etykietowanych klauzulami r_i i r'_i mają 0.
- s_j ma na pozycji C_j 1, a na reszcie pozycji 0.
- s'_j ma na pozycji C_j 2, a na reszcie pozycji 0.

Liczby r_i, r'_i, s_j, s'_j są różne – z konstrukcji i założeń o Φ .

Na każdej pozycji suma wszystkich liczb ≤ 6 , więc nie ma przeniesień.

Redukcja jest w czasie wielomianowym: $|\mathcal{S}|$ jest $2(n+m)$ liczb $(n+m)$ -cyfrowych, utworzenie t zajmuje czas liniowy względem $n+m$, utworzenie każdej z nich jest w czasie wielomianowym względem $n+m$.

Φ spełnialna $\implies$ istnieje spełniające wartościowanie.

Jeśli $x_i = 1$, to do $\mathcal{S}'$ bierzemy r_i .

Jeśli $x_i = 0$, to do $\mathcal{S}'$ bierzemy r'_i .

C_j spełniona $\implies$ suma $r_i, r'_i \in \mathcal{S}'$ ma na pozycji C_j 1 lub 2 lub 3.

Dokładamy do $\mathcal{S}'$ odpowiednio s_j i s'_j lub s'_j lub s_j .

Wtedy $\mathcal{S}'$ ma sumę równą t .

$\mathcal{S}' \subseteq \mathcal{S}$ ma sumę równą $t \implies$ do $\mathcal{S}'$ należy dokładnie jedna z liczb r_i, r'_i :

- jeśli $r_i \in \mathcal{S}'$, to $x_i = 1$,

- jeśli $r'_i \in S'$, to $x_i = 0$.

C_j jest spełniona, bo $s_j + s'_j \leq 3$ na pozycji $C_j \implies$ co najmniej 1 jest z r_i, r'_i należących do S' mająca 1 na pozycji C_j :

- $r_i \in S'$ to x_i jest w C_j , a mamy $x_i = 1$,
- $r'_i \in S'$ to $\bar{x}_i$ jest w C_j , a mamy $x_i = 0$.

□

Przykład 4.19 (Redukcja 3-SAT do SUBSET-SUM).

$$C_1 = (x_1 \vee \bar{x}_2 \vee \bar{x}_3), \quad C_2 = (\bar{x}_1 \vee \bar{x}_2 \vee \bar{x}_3),$$

$$C_3 = (\bar{x}_1 \vee \bar{x}_2 \vee x_3), \quad C_4 = (x_1 \vee x_2 \vee x_3).$$

$$\Phi = C_1 \wedge C_2 \wedge C_3 \wedge C_4. \quad n = 3, m = 4.$$

	x_1	x_2	x_3	C_1	C_2	C_3	C_4
t	1	1	1	4	4	4	4
r_1	1	0	0	1	0	0	1
r'_1	1	0	0	0	1	1	0
r_2	0	1	0	0	0	0	1
r'_2	0	1	0	1	1	1	0
r_3	0	0	1	0	0	1	1
r'_3	0	0	1	1	1	0	0
s_1	0	0	0	1	0	0	0
s'_1	0	0	0	2	0	0	0
s_2	0	0	0	0	1	0	0
s'_2	0	0	0	0	2	0	0
s_3	0	0	0	0	0	1	0
s'_3	0	0	0	0	0	2	0
s_4	0	0	0	0	0	0	1
s'_4	0	0	0	0	0	0	2

Dla wartościowania $x_1 = 1, x_2 = 0, x_3 = 0$ otrzymujemy:

$$S' = \{r_1, r'_2, r'_3, s_1, s'_2, s_3, s_4, s'_4\}$$

$$\text{i } \sum_{x \in S'} x = t.$$

Problem sumy podzbioru

Dane: $S = \{x_1, x_2, \dots, x_n\} \subseteq \mathbb{N}, t \in \mathbb{N}$.

Znaleźć: $S' \subseteq S$ takie, że $\sum_{x_i \in S'} x_i$ jest największa możliwa, ale $\leq t$.

Algorytm 21: Aproksymacja sumy podzbioru

function APPROXSUBSETSUM(S, t, ϵ)

- 1: $n \leftarrow |S|$
- 2: $L_0 \leftarrow (0)$
- 3: $\delta \leftarrow \frac{\epsilon}{2n}$

```

4:   for  $i \leftarrow 1$  to  $n$  do
5:      $L_i \leftarrow \text{MERGE\_LISTS}(L_{i-1}, L_{i-1} + x_i)$ 
6:     usuń z  $L_i$  wszystkie elementy  $> t$ 
7:      $L_i \leftarrow \text{TRIM}(L_i, \delta)$   $\triangleright \delta = \frac{\epsilon}{2n}$ 
8:   return największy element z  $L_n$   $\triangleright z^*$  – liczba zwrócona przez algorytm

```

Algorytm 22: Procedura Trim

```

function TRIM( $L, \delta$ )  $\triangleright L = (y_1, \dots, y_m)$ 
1:    $m \leftarrow |L|$ 
2:    $L' \leftarrow (y_1)$ 
3:    $last \leftarrow y_1$ 
4:   for  $i \leftarrow 2$  to  $m$  do
5:     if  $y_i > last \cdot (1 + \delta)$  then
6:       dodaj  $y_i$  na koniec  $L'$ 
7:        $last \leftarrow y_i$ 
8:   return  $L'$ 

```

Przykład 4.20 (Aproksymacja sumy podzbioru).

$S = \{205, 203, 400, 200\}$, $t = 650$, $\epsilon = 0.4$. $n = 4$, $\delta = \frac{\epsilon}{2n} = \frac{0.4}{8} = 0.05$.

$$L_0 = (0)$$

$$L_1 = (0, 205)$$

$$L_2 = (0, 203, 205, 408)$$

(po linii 4)

$$L_2 = (0, 203, 205, 408)$$

(po linii 5)

$$L_2 = (0, 203, 408)$$

(po linii 6)

$$L_3 = (0, 203, 400, 408, 603, 808)$$

$$L_3 = (0, 203, 400, 408, 603)$$

$$L_3 = (0, 203, 400, 603)$$

$$L_4 = (0, 200, 203, 400, 403, 600, 603, 803)$$

$$L_4 = (0, 200, 203, 400, 403, 600, 603)$$

$$L_4 = (0, 200, 400, 600)$$

$$z^* = 600 \quad (600 = 400 + 200)$$

Optymalne rozwiązanie: $205 + 203 + 200 = 608$.

$$\frac{608}{600} \leq 1.4 = 1 + \epsilon$$

Twierdzenie 4.21. Algorytm APPROXSUBSETSUM jest w pełni wielomianowym schematem aproksymacyjnym dla problemu sumy podzbioru.

Dowód. Użyjemy faktów z analizy:

Fakt 1 $\left(1 + \frac{\epsilon}{2n}\right)^n$ jest ciągiem rosnącym.

Fakt 2 $e^x \leq 1 + x + x^2$ dla $0 \leq x \leq 1$.

Fakt 3 $\frac{x}{1+x} \leq \ln(1+x)$ dla $x \geq 0$.

Oczywiście $z^* \in P_n$, więc z^* jest sumą elementów z S .

Niech $y^* \in P_n$ będzie optymalną sumą elementów $\leq t$.

Oczywiście $y^* \geq z^*$. Pokażemy, że $\frac{y^*}{z^*} \leq 1 + \epsilon$.

Pokażemy przez indukcję po i , że dla każdego $y \in P_i$, $y \leq t$ istnieje $z \in L_i$ taki, że:

$$\frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^i} \leq z \leq y \quad (\text{po } i\text{-tym obrocie pętli}) \quad (2)$$

Dla $i = 1$: $P_1 = \{0, x_1\}$, $L_1 = (0, x_1)$ – zachodzi oczywiście.

Założmy, że (2) zachodzi dla jakiegoś $i < n$. Pokażemy, że (2) zachodzi dla $i + 1$.

Niech $y \in P_{i+1} = P_i \cup (P_i + x_{i+1})$.

Przypadek 1: $y \in P_i$.

Z założenia indukcyjnego istnieje $z \in L_i$ takie, że $\frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^i} \leq z \leq y$.

Jeśli $z \in L_{i+1}$, to $\frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^{i+1}} \leq \frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^i} \leq z \leq y$, więc (2) zachodzi.

Jeśli $z \notin L_{i+1}$ (został usunięty przez Trim), to istnieje $z' \in L_{i+1}$ takie, że $z' \leq z \leq z' \left(1 + \frac{\epsilon}{2n}\right)$, więc $\frac{z}{1 + \frac{\epsilon}{2n}} \leq z' \leq z$.

Mamy:

$$\frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^{i+1}} = \frac{1}{1 + \frac{\epsilon}{2n}} \frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^i} \stackrel{\text{zał. ind.}}{\leq} \frac{z}{1 + \frac{\epsilon}{2n}} \leq z' \leq z \leq y,$$

więc (2) zachodzi.

Przypadek 2: $y \in P_i + x_{i+1}$.

Wtedy $y = y' + x_{i+1}$, gdzie $y' \in P_i$.

Z założenia indukcyjnego istnieje $z \in L_i$ takie, że $\frac{y'}{\left(1 + \frac{\epsilon}{2n}\right)^i} \leq z \leq y'$.

Jeśli $z + x_{i+1} \in L_{i+1}$, to

$$\frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^{i+1}} \leq \frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^i} = \frac{y' + x_{i+1}}{\left(1 + \frac{\epsilon}{2n}\right)^i} \leq \frac{y'}{\left(1 + \frac{\epsilon}{2n}\right)^i} + x_{i+1} \leq z + x_{i+1} \leq y' + x_{i+1} = y,$$

więc (2) zachodzi.

Jeśli $z + x_{i+1} \notin L_{i+1}$ (został usunięty przez Trim), to istnieje $z' \in L_{i+1}$ takie, że $z' \leq z + x_{i+1} \leq z' \left(1 + \frac{\epsilon}{2n}\right)$, więc $\frac{z + x_{i+1}}{1 + \frac{\epsilon}{2n}} \leq z' \leq z + x_{i+1}$.

Mamy:

$$\begin{aligned} \frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^{i+1}} &= \frac{1}{1 + \frac{\epsilon}{2n}} \frac{y}{\left(1 + \frac{\epsilon}{2n}\right)^i} = \frac{1}{1 + \frac{\epsilon}{2n}} \frac{y' + x_{i+1}}{\left(1 + \frac{\epsilon}{2n}\right)^i} \\ &\leq \frac{1}{1 + \frac{\epsilon}{2n}} \left(\frac{y'}{\left(1 + \frac{\epsilon}{2n}\right)^i} + x_{i+1} \right) \stackrel{\text{zał. ind.}}{\leq} \frac{1}{1 + \frac{\epsilon}{2n}} (z + x_{i+1}) \\ &\leq z' \leq z + x_{i+1} \leq y' + x_{i+1} = y \end{aligned}$$

Więc (2) zachodzi.

W szczególności (2) zachodzi dla $y^* \in P_n$. Zatem istnieje $z \in L_n$ takie, że $\frac{y^*}{\left(1 + \frac{\epsilon}{2n}\right)^n} \leq z \leq y^*$, więc

$$\frac{y^*}{z} \leq \left(1 + \frac{\epsilon}{2n}\right)^n.$$

Ale $z^* \geq z$, więc $\frac{y^*}{z^*} \leq \frac{y^*}{z} \leq \left(1 + \frac{\epsilon}{2n}\right)^n$.

$$\frac{y^*}{z^*} \leq \left(1 + \frac{\epsilon}{2n}\right)^n \stackrel{\text{Fakt 1}}{\leq} \lim_{n \rightarrow \infty} \left(1 + \frac{\epsilon}{2n}\right)^n = \lim_{n \rightarrow \infty} \left(\left(1 + \frac{\epsilon}{2n}\right)^{\frac{2n}{\epsilon}}\right)^{\frac{\epsilon}{2}} = e^{\frac{\epsilon}{2}}$$

□

Pokażemy, że algorytm działa w czasie wielomianowym względem $|I| = \Theta(\log t + \sum_{i=1}^n \log x_i)$ i $\frac{1}{\epsilon}$.

Na każdej liście L_i po linii 6 elementy $z_0 = 0, z_1, \dots, z_k$ spełniają warunek $z_{j+1} > z_j \left(1 + \frac{\epsilon}{2n}\right)$ dla $j \geq 1$. Ile różnych liczb naturalnych $z_1, \dots, z_k$ spełniających ten warunek może się tu zmieścić w przedziale $[1, t]$?

Przez indukcję po i mamy, że $z_{i+1} > z_1 \left(1 + \frac{\epsilon}{2n}\right)^i$ dla $1 \leq i \leq k-1$. Zatem

$$z_1 \left(1 + \frac{\epsilon}{2n}\right)^{k-1} < z_k \leq t$$

Skoro $z_1 \geq 1$, to

$$\left(1 + \frac{\epsilon}{2n}\right)^{k-1} \leq t \quad \Big| \ln$$

$$(k-1) \ln \left(1 + \frac{\epsilon}{2n}\right) \leq \ln t$$

$$k-1 \leq \frac{\ln t}{\ln \left(1 + \frac{\epsilon}{2n}\right)} \quad \Big| + 2$$

$$k+1 \leq \frac{\ln t}{\ln \left(1 + \frac{\epsilon}{2n}\right)} + 2 \stackrel{\text{Fakt 3}}{\leq} \frac{\ln t \cdot \left(1 + \frac{\epsilon}{2n}\right)}{\frac{\epsilon}{2n}} + 2 = \frac{2n + \epsilon}{2n} \cdot \frac{2n}{\epsilon} \ln t + 2 \leq \frac{3n \ln t}{\epsilon} + 2$$

Skoro długość L_i po linii 6 wynosi $k+1 \leq \frac{3n \ln t}{\epsilon} + 2$, a po $(i+1)$ -szej linii 4 może być co najwyżej 2 razy dłuższa i $|I| = \Omega(\ln t + n)$, to złożoność czasowa algorytmu jest wielomianowa względem $|I|$ i $\frac{1}{\epsilon}$.

Skojarzenia w grafach


Najliczniejsze skojarzenie w grafach dwudzielnych $G = (V, E)$ – graf.

G jest dwudzielny jeśli istnieje podział V na dwa niepuste podzbiory V_1, V_2 takie, że dla każdej krawędzi $e = v_1 v_2 \in E$ mamy $v_1 \in V_1$ i $v_2 \in V_2$. Oznaczamy to jako $G = (V_1, V_2, E)$.

Skojarzenie w G to zbiór parami rozłącznych krawędzi.

Skojarzenie jest najliczniejsze jeśli ma największą liczbę.

Przykład 5.1.




Przykładowe skojarzenie: $\{ae, df, bc\}$

Jeśli M jest skojarzeniem, to każdy wierzchołek należy do co najwyżej jednej krawędzi z M .


Niech M będzie ustalonym skojarzeniem w G .

- wierzchołek jest skojarzony jeśli należy do jakiejś krawędzi z M (mówimy też, że M pokrywa ten wierzchołek),
- wierzchołek jest wolny jeśli nie jest skojarzony,
- krawędź jest skojarzona jeśli należy do M ,
- krawędź jest wolna jeśli nie należy do M .

Ścieżka powiększająca (względem M) to naprzemienna ścieżka składająca się z wolnych i skojarzonych krawędzi o wolnych końcach.



$$M' = M \div E(P) = (M - E(P)) \cup (E(P) - M)$$



Możemy użyć ścieżki powiększającej i różnicy symetrycznej do zwiększenia liczności skojarzenia.

Twierdzenie 5.2 (Berge'a).

Niech $G = (V, E)$ – graf, M – skojarzenie w G .

M jest najliczniejszym skojarzeniem w $G \iff$ nie istnieje ścieżka powiększająca względem M .

Dowód. $\implies$ Przypuśćmy, że istnieje ścieżka powiększająca P względem M .

Wtedy $M' = M \div E(P)$ jest skojarzeniem i $|M'| > |M|$, więc M nie jest skojarzeniem najliczniejszym.

$\Leftarrow$ Przypuśćmy, że M nie jest najliczniejszym skojarzeniem w G .

Niech M' będzie skojarzeniem takim, że $|M'| > |M|$.

Niech H będzie podgrafem G indukowanym przez $M' \div M$, czyli $H = (V(G), M' \div M)$.

M, M' to skojarzenia, więc stopień wierzchołka $d_H(v) \leq 2$ dla każdego $v \in V(G)$.

Każda składowa H jest ścieżką lub cyklem.

M, M' to skojarzenia, więc nie ma cykli nieparzystych w H .

Każda składowa H jest ścieżką lub cyklem parzystym.

Skoro $|M'| > |M|$, to istnieje składowa H , która jest ścieżką zawierającą więcej krawędzi z M' niż z M , więc ta ścieżka zaczyna się i kończy krawędzią z M' . Ta ścieżka jest ścieżką powiększającą względem M . $\square$

Kontynuujemy temat najliczniejszego skojarzenia w grafach dwudzielnych.

Dane: $G = (V_1, V_2; E)$ – graf dwudzielny.

Znaleźć: najliczniejsze skojarzenie w G .

Niech M będzie skojarzeniem w G .

Definiujemy graf skierowany $G_M = (V_1 \cup V_2, E_M)$, gdzie

$$E_M = \{(u, v) : uv \in E - M, u \in V_1, v \in V_2\} \cup \{(v, u) : uv \in M, u \in V_1, v \in V_2\}.$$

Innymi słowy, krawędzie wolne kierujemy z V_1 do V_2 , a krawędzie skojarzone z V_2 do V_1 .

Przykład 5.3.



Procedura do znajdowania ścieżki powiększającej — *Augmenting Path Search* (APS).

Algorytm 23: Augmenting Path Search

function APS(G, M)

$\triangleright G = (V_1, V_2; E)$, M – skojarzenie w G

- 1: $V'_1 \leftarrow$ zbiór wierzchołków wolnych z V_1
- 2: $V'_2 \leftarrow$ zbiór wierzchołków wolnych z V_2
- 3: skonstruuj graf skierowany $G_M = (V_1 \cup V_2, E_M)$
- 4: znajdź ścieżkę $\vec{P}$ z V'_1 do V'_2 w G_M
- 5: **if** $\vec{P}$ istnieje **then**
- 6: **return** P
- 7: **else**
- 8: **return** NULL

$\triangleright P$ – nieskierowana $\vec{P}$

Lemat 5.4. Procedura APS zwraca ścieżkę $P \iff$ istnieje ścieżka powiększająca względem M w G . Ponadto ścieżka P zwrócona przez APS jest ścieżką powiększającą względem M .

Dowód.

$\implies$ Jeśli APS zwraca ścieżkę P , to skierowana ścieżka $\vec{P}$ znaleziona w linii 4 zaczyna się w wierzchołku z V'_1 (a więc wolnym) i kończy się w wierzchołku z V'_2 (a więc wolnym). Z definicji grafu G_M wynika, że pierwsza krawędź P jest wolna, druga krawędź P jest skojarzona, trzecia krawędź P jest wolna, ..., ostatnia krawędź P jest wolna. Zatem P jest ścieżką powiększającą względem M .

$\impliedby$ Jeśli istnieje ścieżka powiększająca względem M w G , to ścieżka skierowana otrzymana z takiej ścieżki powiększającej przez skierowanie krawędzi zgodnie z E_M jest ścieżką skierowaną z V'_1 do V'_2 w G_M . Taką ścieżkę skierowaną znajduje APS.

□

Algorytm znajdowania najliczniejszego skojarzenia — *Maximum Matching* (MM).

Algorytm 24: Maximum Matching

function MM(G)

$\triangleright G = (V_1, V_2; E)$

- 1: $M \leftarrow \emptyset$
- 2: **repeat**

```

3:    $P \leftarrow \text{APS}(G, M)$ 
4:   if  $P \neq \text{NULL}$  then
5:      $M \leftarrow M \div E(P)$ 
6:   until  $P = \text{NULL}$ 
7:   return  $M$ 

```

Poprawność Wynika z twierdzenia Berge’a.

Złożoność czasowa Złożoność czasowa APS:

- Linie 1, 2: $\mathcal{O}(|V|)$.
- Linia 3: $\mathcal{O}(|E|)$.
- Linia 4: $\mathcal{O}(|E|)$ (używamy algorytmu BFS).
- Linie 5–8: $\mathcal{O}(|V|)$.

Złożoność APS wynosi zatem $\mathcal{O}(|E|)$.


Złożoność czasowa MM:

- Linia 1: $\mathcal{O}(1)$.
- Pętla 2–6 wykona się co najwyżej $\frac{|V|}{2}$ razy, bo w każdej iteracji $|M|$ zwiększa się o 1, a maksymalna liczność skojarzenia jest $\leq \frac{|V|}{2}$.
- Wnętrze pętli:
 - Linia 3: $\mathcal{O}(|E|)$.
 - Linia 5: $\mathcal{O}(|V|)$.
 Razem $\mathcal{O}(|E|)$.
- Linia 7: $\mathcal{O}(|V|)$.



Ostateczna złożoność MM wynosi $\mathcal{O}(|V| \cdot |E|)$.

Przykład 5.5 (Działanie algorytmu Maximum Matching).



Prześledźmy działanie algorytmu MM na poniższym grafie G :





Iteracja 1:





Iteracja 2:



Iteracja 3:



Iteracja 4:



Iteracja 5:

